

Itinerario anual integrado: Sistemas de Big Data y Big Data aplicado

Programacion coordinada de Sistemas de Big Data y Big Data aplicado

Curso 2026-2027

Propósito

Este documento organiza los dos módulos como un único proyecto progresivo durante el curso:

- **Sistemas de Big Data (SBD): 90 horas, 3 horas semanales.** Define el problema, selecciona y valora datos, explica la arquitectura y extrae conclusiones mediante análisis y visualización.
- **Big Data aplicado (BDA): 150 horas, 5 horas semanales.** Implementa, automatiza, despliega, mide y mejora la solución.

La premisa de trabajo es simple: **SBD va medio paso por delante de BDA**. Lo que se razona y diseña en SBD se construye y comprueba en BDA durante esa misma semana o la siguiente. No se imparte un módulo entero antes del otro.

El plan está pensado para unas 30 semanas lectivas. Si el calendario real cambia, se conservan las fases y se ajustan sus sesiones.

Decisión de formación personal

Bloque 0 - base personal imprescindible (semanas 0-8, en paralelo)

Esta es la única mejora necesaria para un profesorado que parte de cero. No añade una unidad al alumnado ni retrasa el calendario: se estudia en paralelo durante las primeras ocho semanas para poder preparar con seguridad las prácticas de BDA.

0.1 Python funcional para datos

- Coursera / IBM - **Python for Data Science, AI & Development** (<https://www.coursera.org/learn/python-for-applied-data-science-ai>).
- Trabajar: variables, colecciones, condicionales, bucles, funciones, ficheros, Jupyter, pandas y consumo básico de APIs.
- Meta antes de la semana 5: cargar un CSV o JSON, limpiar un DataFrame sencillo y guardar un resultado reproducible.

0.2 SQL para consultar y comprobar datos

- Coursera / IBM - **Databases and SQL for Data Science with Python** (<https://www.coursera.org/learn/sql-data-science>).
- Trabajar: SELECT, filtros, agregaciones, GROUP BY, JOIN, creación básica de tablas y consultas desde Jupyter/Python.
- Meta antes de la semana 9: consultar varias tablas con JOIN y GROUP BY, y usar SQL para comprobar la calidad de una carga.

Resultado exigible del bloque 0. Antes de comenzar PySpark, poder leer datos CSV/JSON con Python, escribir una función sencilla, transformar un DataFrame y responder a una pregunta con SQL. Git se enseña en BDA desde la primera semana y Docker se incorpora cuando el proyecto lo necesita; no son prerequisites previos.

Itinerario principal

1. Coursera / UC San Diego - **Big Data Specialization: cursos 1 y 2.**
 - *Introduction to Big Data* (18 h).
 - *Big Data Modeling and Management Systems* (15 h).
 - Aporta la base conceptual: problema Big Data, HDFS y MapReduce como referencia histórica, almacenamiento, NoSQL, modelado y gestión.

2. **Coursera / IBM - Introduction to Big Data with Spark and Hadoop**
(<https://www.coursera.org/learn/introduction-to-big-data-with-spark-hadoop>).
 - Sustituye al tercer curso de UCSD.
 - Aporta Hadoop y HDFS, MapReduce, Hive/HBase y una entrada práctica y más actual a Spark, DataFrames y Spark SQL.
3. **Coursera - Open Source Data Engineering with Spark, dbt & Airflow** (6 cursos; estimación de la plataforma: 4 semanas a 10 h/semana).
 - Aporta la parte moderna y operacional: Spark, dbt, Airflow, Docker, cargas incrementales, calidad, rendimiento, reintentos, SLA y CI/CD.
4. **Udemy - The Complete Hands-On Introduction to Apache Airflow 3** (4 h 37 min).
 - Refuerzo práctico para no depender solo de la abstracción de la especialización: Docker, DAG, tareas, operadores, ejecutores y uso de Airflow dentro de un ecosistema de datos.
5. **Confluent - Apache Kafka 101** (1 h 16 min, gratuito).
 - Cápsula optativa para modelar eventos, topics, particiones, consumidores, replicación y conexión de fuentes de streaming.

Qué se descarta de forma deliberada

- El tercer curso de UCSD (*Big Data Integration and Processing*) se omite porque el curso de IBM lo sustituye con una progresión más directa hacia Spark y Hadoop. Así se evita duplicar contenido y se conserva tiempo para preparar prácticas propias.
- Los cursos 4 y 5 de la especialización UCSD (*Machine Learning With Big Data* y *Graph Analytics*) no son necesarios para estos dos módulos. Sirven como cultura general y coordinación con los módulos de IA, pero no entran en la secuencia obligatoria.
- El capstone de UCSD se usa como referencia metodológica, no como práctica literal: utiliza herramientas y una máquina virtual históricas. El proyecto de este documento emplea una pila actual, reproducible y manejable en aula.
- Hadoop, Pig, Hive, Flume y Sqoop se explican como parte del ecosistema y del currículo, pero no se convierten en el centro de las prácticas. El alumnado debe comprender qué problema resuelven y su evolución hacia alternativas actuales.

Ritmo personal sostenible

La carga recomendada es de **4 a 6 horas semanales de preparación propia durante las primeras ocho semanas** y de **unas 4 horas después**, con un pequeño colchón de dos o tres semanas respecto al alumnado:

Semanas	Formación personal	Meta
0-8	Bloque 0: Python y SQL (en paralelo)	Autonomía suficiente para preparar y corregir las prácticas
1-3	UCSD, curso 1	Fundamentos y arquitectura clásica/moderna
4-7	UCSD, curso 2	Selección de almacenamiento, modelos y datos heterogéneos
8-12	IBM, Spark y Hadoop	Procesamiento distribuido, DataFrames y Spark SQL
13-22	Open Source Data Engineering	Pipeline moderno, Spark, calidad, orquestación y rendimiento
21-25	Airflow 3	Automatización aplicada al proyecto
26	Kafka 101 (opcional)	Streaming y eventos, sin convertirlo en un bloque central

Semanas	Formación personal	Meta
27-30	Consolidación	Adaptar materiales, pruebas de fallos y evaluación final

No hace falta terminar una formación antes de iniciar el bloque de aula correspondiente: se estudia por delante de cada fase y se convierte en material propio, no se reproduce tal cual.

Proyecto vertebrador

Caso: Observatorio de movilidad y actividad turística

Cada equipo construye una plataforma analítica para una organización ficticia que necesita planificar recursos y comprender demanda. Se parte de datos públicos o cuidadosamente simulados, sin datos personales:

- movilidad o llegadas por fecha y zona;
- datos meteorológicos en JSON;
- ocupación, actividad económica o eventos en CSV;
- reseñas agregadas o eventos simulados en JSON Lines.

El caso permite responder preguntas de negocio y técnicas:

- ¿Qué zonas y periodos muestran mayor demanda?
- ¿Qué relación existe entre clima, movilidad y ocupación?
- ¿Qué fuentes son poco fiables y cómo se detecta el problema?
- ¿Qué indicador permitiría tomar una decisión operativa?
- ¿Qué ocurre si una fuente cambia de esquema o deja de llegar?

Entregable final de cada equipo

1. Repositorio reproducible.
2. Documento breve de objetivo, fuentes, límites y riesgos.
3. Diccionario de datos y linaje.
4. Pipeline de ingesta y transformación.
5. Arquitectura desplegable con Docker Compose.
6. Cuadro de mando con indicadores y recomendación.
7. Métricas, alerta y simulación documentada de un incidente.
8. Defensa técnica y de negocio de 8-10 minutos.

Pila tecnológica del curso

No se pretende enseñar todas las herramientas del ecosistema. Estas son las mínimas para que el proyecto sea realista y pueda funcionar en un aula:

Necesidad	Herramienta principal	Alternativa razonable
Control de versiones	Git + GitHub/GitLab	Repositorio interno del centro
Exploración	Python, Jupyter, pandas	VS Code + scripts Python
Base de datos relacional	PostgreSQL	SQLite al inicio

Necesidad	Herramienta principal	Alternativa razonable
Almacenamiento de objetos	MinIO	Sistema local de carpetas para la primera práctica
Procesamiento	PySpark	pandas solo para comparación inicial
Transformación SQL versionada	dbt Core	SQL documentado si no hay tiempo
Orquestación	Airflow	scripts programados para una versión reducida
Visualización	Metabase o Power BI	Apache Superset si ya existe experiencia en el centro
Observabilidad	Prometheus + Grafana	logs estructurados y panel de Airflow en un mínimo viable

Regla de estabilidad: el profesorado prepara una única configuración `compose.yaml` y una imagen probada. No se instala un clúster diferente en cada ordenador ni se exige la antigua VM de UCSD. Antes de llevar cualquier laboratorio al alumnado se prueba desde una cuenta limpia.

Calendario integrado de 30 semanas

Fase 0 - Arranque y contrato de proyecto (semanas 1-3)

SBD - 9 h

- Qué problema es realmente Big Data y qué no lo es.
- Tipos de datos, V de Big Data, datos estructurados, semiestructurados y no estructurados.
- Caso de negocio, actores, decisiones e indicadores iniciales.

BDA - 15 h

- Diagnóstico de Python, SQL, Git y JSON.
- Uso del repositorio plantilla.
- Arranque de los servicios mínimos y exploración de datos.
- Convenciones: ramas, commits, README, nombres de ficheros y datos de prueba.

Formación docente asociada

- Bloque 0 en paralelo: Python para datos y SQL. No se traslada como materia adicional; permite al profesorado preparar y resolver las prácticas de esta fase.
- UCSD curso 1, bloques sobre panorama, casos de uso, arquitectura y HDFS/MapReduce como referencia histórica.
- JupyterBook de Fortinux: definición, características, gobierno y calidad del dato.

Evidencia

- Acta de equipo: pregunta de negocio, tres fuentes y dos KPI iniciales.
- Repositorio que puede ejecutarse y contiene un README.

Fase 1 - Fuentes, ingesta y calidad (semanas 4-7)

SBD - 12 h

- Ciclo de vida del dato y trazabilidad.
- Batch frente a streaming; latencia, coste, frecuencia y volumen.
- Formatos CSV, JSON, JSON Lines y Parquet: cuándo elegir cada uno.

- Dimensiones de calidad: completitud, validez, unicidad, actualidad y consistencia.

BDA - 20 h

- Ingesta de CSV, JSON y una API o una fuente simulada.
- Capa raw inmutable y registro de metadatos de carga.
- Validaciones de esquema, tipos, nulos, rangos y duplicados.
- Separación de registros válidos y errores sin perder el original.

Formación docente asociada

- UCSD curso 2, selección de modelos, operaciones de datos y datos en tiempo real.
- Open Source Data Engineering, introducción al diseño de pipelines y a la integración de bases de datos, APIs y streams.

Evidencia

- Diccionario de datos v1.
- Script de ingesta idempotente: ejecutarlo dos veces no genera duplicados no controlados.
- Informe de calidad de una página.

Fase 2 - Arquitectura, almacenamiento y modelado (semanas 8-11)

SBD - 12 h

- OLTP, almacén de datos, data lake y lakehouse.
- Almacenamiento distribuido, redundancia, particionado y coste.
- Modelado para análisis: hechos, dimensiones y granularidad.
- Justificación de arquitectura, seguridad y protección de datos.

BDA - 20 h

- PostgreSQL para datos estructurados y MinIO para datos crudos/Parquet.
- Capas bronze/raw, silver/clean y gold/analytics.
- Conversión a Parquet y particionado por fecha o zona.
- Modelo dimensional mínimo para el consumo analítico.

Formación docente asociada

- UCSD curso 2, almacenamiento, gestión y selección de sistemas.
- Open Source Data Engineering, contenido de data lake transaccional, Delta/lakehouse y evolución de esquemas.

Evidencia

- Diagrama de arquitectura v1.
- Decisión técnica justificada: dónde vive cada dato y por qué.
- Datos disponibles en las tres capas acordadas.

Fase 3 - Integración y procesamiento distribuido (semanas 12-16)

SBD - 15 h

- Integración de fuentes y resolución de claves, fechas y unidades.
- Complejidad, particiones, paralelismo y coste del procesamiento.
- Spark frente a procesamiento local: qué cambia y qué no.

- Métricas y preparación de una tabla analítica.

BDA - 25 h

- PySpark: lectura de Parquet/JSON, esquemas y DataFrames.
- Filtros, columnas derivadas, joins, agregaciones y ventanas básicas.
- Spark SQL y comparación controlada con pandas.
- Particionado, caché cuando proceda y escritura de la capa gold.

Formación docente asociada

- IBM, *Introduction to Big Data with Spark and Hadoop*: Hadoop/HDFS como contexto, y Spark, DataFrames y Spark SQL como núcleo práctico.
- Open Source Data Engineering, optimización de Spark por particionado, caché y acceso a datos.

Evidencia

- Pipeline que transforma raw en gold de extremo a extremo.
- Tabla de pruebas: entradas, resultado esperado y resultado obtenido.
- Breve nota sobre una decisión de rendimiento.

Fase 4 - BI, visualización y decisión (semanas 17-20)

SBD - 12 h

- Pregunta, métrica, visualización y decisión: cadena completa.
- Cuadro de mando: audiencia, KPI, filtros y narrativa.
- Visualizaciones engañosas, incertidumbre, datos faltantes y límites de inferencia.
- CRISP-DM/KDD como estructura para documentar el análisis.

BDA - 20 h

- Conexión de Metabase o Power BI a la capa gold.
- Creación de 4-6 KPI y al menos tres visualizaciones justificadas.
- Refresco documentado de datos y dashboard.
- Prueba de consistencia entre consulta de origen y visualización.

Formación docente asociada

- JupyterBook de Fortinux: consultas, calidad, linaje y visualización.
- Capstone de UCSD únicamente como patrón de exploración, análisis, informe y presentación; no se reproducen sus herramientas.

Evidencia

- Dashboard v1.
- Informe de decisión: recomendación, evidencia, limitaciones y siguiente dato necesario.

Fase 5 - Automatización, integridad y observabilidad (semanas 21-25)

SBD - 15 h

- Fiabilidad, integridad, checksums, linaje y contratos de datos.
- Monitorización de sistema frente a monitorización de calidad de datos.
- Alertas útiles: qué medir, umbrales, falsos positivos y respuesta.
- Ética, RGPD, mínimos privilegios y conservación de datos.

BDA - 25 h

- Airflow: DAG, tareas, dependencias, parámetros, reintentos y logs.
- Ejecución programada de ingesta, transformación y publicación.
- Métricas de filas, duración, errores, frescura y calidad.
- Panel de Airflow y, si el entorno lo permite, Prometheus + Grafana.
- Simulación: cambio de esquema, fichero corrupto o caída del almacenamiento.

Formación docente asociada

- Open Source Data Engineering: DAG, reintentos, SLA, calidad automatizada y CI/CD.
- Curso Udemy Airflow 3 completo.
- Kafka 101 solo si se añade una fuente de eventos; no es requisito del proyecto.

Evidencia

- DAG ejecutable y documentado.
- Una alerta demostrable.
- Informe de incidente: detección, impacto, recuperación y prevención.

Fase 6 - Integración, mejora y defensa (semanas 26-30)

SBD - 15 h

- Evaluación de la solución por coste, calidad, seguridad y valor de negocio.
- Revisión entre iguales de arquitectura y dashboard.
- Preparación de defensa: decisión, evidencia, límites y mejora priorizada.

BDA - 25 h

- Limpieza de repositorio y ejecución desde una instalación nueva.
- Pruebas finales y documentación operativa.
- Refuerzo opcional: Kafka para eventos o una segunda fuente incremental.
- Demostración final de flujo, dashboard y recuperación ante fallo.

Formación docente asociada

- Consolidación, no incorporación de nuevas herramientas.
- Revisión de qué partes de las plataformas externas han sido realmente útiles para el siguiente curso.

Evidencia

- Entrega final de los ocho artefactos del proyecto.
- Defensa y coevaluación.

Rutina semanal recomendada

No importa qué días concretos se impartan las horas. La secuencia sí importa:

1. **SBD (3 h):** plantea la decisión, el criterio de diseño o la pregunta analítica; analiza ejemplos y define una entrega breve.
2. **BDA (5 h):** implementa esa decisión sobre el proyecto compartido.
3. **Cierre:** cada equipo registra qué funcionó, qué falló y qué decisión necesita revisar.

Ejemplo: SBD justifica que nunca se debe sobrescribir el dato de origen y define trazabilidad; BDA construye raw, clean y analytics, registra el origen y conserva los errores.

Hitos de evaluación

Hito	Semana	Peso orientativo	Evidencia
H1. Diseño y fuentes	3-4	15 %	Pregunta, KPI, fuentes, riesgos y diccionario v1
H2. Ingesta y arquitectura	10-11	25 %	Capas de datos, validaciones, diagrama y justificación
H3. Procesamiento y BI	19-20	30 %	Pipeline Spark, tabla gold, dashboard y recomendación
H4. Operación y defensa	29-30	30 %	Airflow, alerta, incidente, documentación y defensa

Rúbrica transversal:

- 35 % funcionamiento técnico y reproducibilidad;
- 20 % calidad, seguridad, documentación y trazabilidad;
- 20 % análisis, KPI y comunicación visual;
- 15 % observabilidad, incidencias y mejora;
- 10 % defensa y trabajo profesional.

Preparación antes de empezar

Material que debe existir antes de la primera semana

- Repositorio plantilla con README, licencia, estructura de carpetas y guía de arranque.
- `compose . yaml` probado y versión de las imágenes fijada.
- Tres o cuatro conjuntos de datos pequeños, documentados y estables.
- Generador de datos defectuosos para las prácticas de calidad e incidencias.
- Plantillas de diccionario de datos, diagrama de arquitectura e informe de incidente.
- Rúbrica publicada desde la primera semana.

Estructura propuesta del repositorio

```
proyecto-big-data/  
  README.md  
  compose.yaml  
  data/  
    raw/  
    clean/  
    analytics/  
  docs/  
    diccionario-datos.md  
    arquitectura.md  
    incidentes/  
  notebooks/  
  src/  
    ingest/  
    transform/  
    quality/  
  airflow/dags/  
  dashboards/  
  tests/
```

Riesgos previsibles y decisiones preventivas

Riesgo	Decisión
Perder semanas configurando equipos	Un entorno único con Docker Compose; práctica de instalación antes de necesitar Spark o Airflow.
Aprender demasiadas herramientas	La pila mínima es obligatoria; Kafka, dbt completo, Grafana o cloud se usan como extensión.
Repetir teoría en los dos módulos	SBD diseña y evalúa; BDA implementa y opera. Cada entrega se hace una sola vez, con dos perspectivas.
Convertir el proyecto en tareas de copiar/pegar	Cada equipo recibe una variación de datos o pregunta; se evalúan decisiones, pruebas y defensa.
Dependencia de cursos externos o material de pago	Las plataformas guían al profesorado. Las actividades del aula son propias y reproducibles.
Tecnologías antiguas de UCSD	Se enseñan para entender el ecosistema y el currículo, pero las prácticas se actualizan con Spark, almacenamiento de objetos y orquestación.

Enlaces de referencia

- Currículo oficial: [Real Decreto 279/2021 - Inteligencia Artificial y Big Data](https://www.boe.es/eli/es/rd/2021/04/20/279) (<https://www.boe.es/eli/es/rd/2021/04/20/279>)
- [Big Data Specialization - University of California San Diego](https://www.coursera.org/specializations/big-data) (<https://www.coursera.org/specializations/big-data>)
- [Introduction to Big Data - UC San Diego](https://www.coursera.org/learn/big-data-introduction?specialization=big-data) (<https://www.coursera.org/learn/big-data-introduction?specialization=big-data>)
- [Big Data Modeling and Management Systems - UC San Diego](https://www.coursera.org/learn/big-data-management?specialization=big-data) (<https://www.coursera.org/learn/big-data-management?specialization=big-data>)
- [Python for Data Science, AI & Development - IBM](https://www.coursera.org/learn/python-for-applied-data-science-ai) (<https://www.coursera.org/learn/python-for-applied-data-science-ai>)
- [Databases and SQL for Data Science with Python - IBM](https://www.coursera.org/learn/sql-data-science) (<https://www.coursera.org/learn/sql-data-science>)
- [Introduction to Big Data with Spark and Hadoop - IBM](https://www.coursera.org/learn/introduction-to-big-data-with-spark-hadoop) (<https://www.coursera.org/learn/introduction-to-big-data-with-spark-hadoop>)

- Open Source Data Engineering with Spark, dbt & Airflow
(<https://www.coursera.org/professional-certificates/open-source-data-engineering-with-spark-dbt-and-airflow>)
- The Complete Hands-On Introduction to Apache Airflow 3
(<https://www.udemy.com/course/the-complete-hands-on-course-to-master-apache-airflow/>)
- Apache Kafka 101 - Confluent (<https://developer.confluent.io/courses/apache-kafka/events/>)
- JupyterBook "Introducción a Big Data" - Marcelo Horacio Fortino (<https://fortinux.github.io/bigdata-book/intro.html>)

Próxima acción recomendada

Antes de crear unidades didácticas, preparar el **repositorio plantilla y la práctica 0**. Con eso se valida que el entorno, los datos y el reparto entre módulos funcionan desde el primer día.