

La fase de Transformación: Limpieza

Big Data Aplicado

Julio Alberto López Gómez
JulioAlberto.Lopez@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Transformación

Concepto:


- OLTP → OLAP
- Preprocesamiento
 - Limpieza
- Transformación
 - Manipulación



Transformación

Preprocesamiento:

- “El propósito fundamental de la preparación de los datos es la manipulación y transformación de los datos sin refinar para que la información contenida en el conjunto de datos pueda ser descubierta o estar accesible de forma más fácil.”



Transformación


Lenguaje R:

- Lenguaje de programación
- Interpretado
- Estadística/Computación
- Licencia GNU
- Instalación R:
 - <https://cran.r-project.org/bin/windows/base/>
- Instalación RStudio:
 - <https://www.rstudio.com/products/rstudio/download/>

Transformación

Limpieza:

- Data Cleaning
- Datos incompletos
- Datos incorrectos
- Datos inconsistentes



Transformación

Limpieza:

- Ejemplo 1

- **Datos originales**

[illegible]

- **Datos limpios**

[illegible]

- Ejemplo 2

- Edad = "42"
- FNac = "03/07/1997"

Transformación

Datos perdidos:

- Datos no disponibles para alguna/s variables de una instancia
- Filtrado

```
datos <- data("iris")

res <- apply(datos, 1, function(x)
  sum(is.na(x))) / ncol(datos) * 100

mal <- (res > 5)

filtrados <- datos[!mal,]
```

- Asignación de valores fijos o de referencia



Transformación

Datos perdidos:

- Imputación: uso de técnicas estadísticas o de aprendizaje automático para “adivinar” los valores perdidos

```
install.packages("mice")  
requiere(mice)
```

```
datos <- airquality
```


```
aggr_plot <- aggr(datos[,1:4],  
col=c('blue','red'), numbers=TRUE,  
sortVars=TRUE, labels=names(data),  
cex.axis=.5, gap=1, ylab=c("Gráfico  
de datos perdidos","Patrón"))
```



Transformación

Datos perdidos:

- Imputación: uso de técnicas estadísticas o de aprendizaje automático para “adivinar” los valores perdidos



Transformación

Datos perdidos:

- Imputación: uso de técnicas estadísticas o de aprendizaje automático para “adivinar” los valores perdidos

```
requiere(mice)
```

```
datos <- airquality
```

```
imputados <- mice(datos)
```

```
datos_imputados <- complete(imputados)
```



Transformación

Datos anómalos:

- Datos dispersos
- Valores fuera de la distribución de los datos

```
requiere(outlier)
requiere(mvoutlier)


datos <- airquality
# solo en variables continuas
anomalos <- outlier(datos)

resultados <- uni.plot(datos)
```



Transformación

Datos anómalos:



La fase de Transformación

Big Data Aplicado

Julio Alberto López Gómez
JulioAlberto.Lopez@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data