

Sistemas de Archivos Distribuidos

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado




Curso Especialización
Inteligencia_Artificial y
Big_Data

Sistema de archivos distribuidos

- Sistema de archivos con ficheros compartidos en recursos de almacenamiento dispersos en una red.
- Facilita la compartición de archivos entre clientes de forma controlada y autorizada.
- Localizar todos los archivos compartidos dentro de un único servidor o nombre de dominio.



Sistema de archivos distribuidos



Sistema de archivos distribuidos

Trasparencia

- Ocultar el hecho de que los procesos y recursos están físicamente distribuidos en la red
- Proporcionar una visión común de un sistema de archivos centralizado.



Sistema de archivos distribuidos

Replicación

- Los DFS utilizan la replicación haciendo varias copias de un archivo de datos en diferentes servidores.
- Cuando un cliente solicita el archivo, accede de forma transparente a una de las copias.
- Las réplicas se almacenan en diferentes servidores según un esquema de colocación.



Sistema de archivos distribuidos


Random Replication

- Las réplicas se almacenan aleatoriamente:
 - en diferentes nodos,
 - en diferentes racks,
 - en diferentes ubicaciones geográficas,
- de modo que si se produce un fallo en cualquier parte del sistema, los datos siguen estando disponibles




HDFS

Name Node



Resource
Manager




HDFS

- HDFS sistema de ficheros de Hadoop.
- Maneja grandes volúmenes de datos a gran velocidad y de diferentes fuentes.
- Almacena los datos en forma de bloque donde el tamaño de cada bloque de datos es de 128MB de tamaño



HDFS



HDFS

NameNode

- Único nodo de nombres (**maestro**):
 - gestiona el espacio de nombres del sistema de archivos.
 - Regula el acceso a los archivos por parte de los clientes.
- **NameNode** secundario
 - copia persistente del Namenode.
 - manejar los fallos del maestro mediante restauración.




HDFS

DataNode

- El flujo de datos se divide en bloques distribuidos entre los datanodes.
 - Los datanodes gestionan el almacenamiento adjunto a los nodos en los que se ejecutan.
 - Lectura, Escritura.
 - Creación, borrado y replicación de bloques.
- 

HDFS

Replicación



- Los bloques se replican a través de los datanodes.
- Cada datanode tiene como máximo una copia de un bloque
- Cada rack tiene como máximo dos copias del bloque.


HDFS

Gestión de fallos

- Cada datanode compara la versión del software y el ID del espacio de nombres con los del nodo de nombres.
 - Si no coinciden, el datanode se apaga para preservar la integridad del sistema.
- Los datanodes envían *latidos* al namenode.
- el namenode considera los datanodes como fallidos si no recibe ningún *latido* durante 10 minutos

HDFS

Ventajas



■ Rentabilidad



■ Grandes
Volúmenes de
datos.



Recuperación
ante fallos.



Portabilidad.



Acceso a los
datos en flujo.

Sistemas de Archivos Distribuidos

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data