

Tolerancia a fallos

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es




Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Tolerancia a fallos

Contexto



Tolerancia a fallos

Contexto

- Todos los sistemas de big data necesitan tolerar los fallos de software y hardware que quedan en el sistema.
- La tolerancia a fallos es una configuración que evita que un ordenador o dispositivo de red falle en caso de un problema o error inesperado
- Dos casos diferentes: batch y streaming.



Tolerancia a fallos

Batch

- Es posible calcular la capacidad de almacenamiento y el tamaño de los elementos almacenados.
- Almacenamiento antes del cálculo, la demanda en tiempo real no es alta.
- La precisión y la integridad de los datos son más importantes,



Batch Computing

Replicación de Datos

- Una copia de los datos estará en varios nodos diferentes.
- Recuperación instantánea de fallos.
- Consumo de grandes cantidades de recursos.
- Posibles inconsistencias.



Batch Computing

Mecanismo de Rollback

- El ***copy report*** se guardará un intervalo de tiempo fijo.
- Si se produce un fallo el sistema se limita a hacer una copia de seguridad en un **checkpoint**, y luego vuelve a iniciar la operación desde ese punto.
- Aumento del tiempo: copia + verificación de consistencia.
- Menos recursos



Tolerancia a fallos

Streaming


- No podemos determinar el momento y orden de llegada de todos los datos.
- Sin almacenamiento previo.
- Datos directamente al cálculo.
- Tiempo real.
- Exactitud de los datos no crítica.



Tolerancia a fallos

Streaming

- Un flujo de datos (stream) es una secuencia de datos que se generan continuamente en tiempo real y que deben ser procesadas a su llegada.



Stream

Passive Standby

- Backup periódico del estado del MasterNode a la réplica.
- Restauración de backup tras fallo.
- Admite mayor volumen de datos.
- Tiempo de recuperación mayor.
- Utilizar HDFS para mejorar tiempos.
- Recuperar los datos con precisión.



Stream

Active Standby

- Cuando se recogen datos en el nodo maestro se transmiten a su réplica.
- Ante fallo el nodo réplica asume el trabajo.
- Reparto de recursos entre nodos.
- Tiempo más corto, pero rendimiento de datos menor.
- Más uso de recursos.



Stream

Upstream Backup

- Reduce significativamente la sobrecarga de tiempo de ejecución.
- Los nodos upstream actúan como copias de seguridad para sus downstream abajo preservando datos en sus colas de salida mientras sus vecinos downstream las procesan.
- Si un servidor falla, sus nodos upstream reproducen los datos registrados en un nodo de recuperación



Stream

Operator State Management

- Cada operador es una unidad de procesamiento que:
 - recibe datos de entrada a través de sus colas de entrada (una por cada flujo de entrada)
 - produce datos de salida de salida en función de su semántica de ejecución.



Stream

Operator State Management

- El estado del operador se copia en los nodos upstream.
- El sistema reemplazará al nodo que falle y se recuperará el estado upstream.
- Tiempo de reconstrucción más corto.
- Menos recursos



Tolerancia a fallos

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data