

Introducción a Hadoop

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data


Hadoop

¿Qué es?

- Framework capaz de soportar aplicaciones de forma distribuida
 - Trabajar con grandes cantidades de datos
 - Características:
 - Escalabilidad
 - Alta disponibilidad
 - Poder de cómputo (alta velocidad)
 - Flexibilidad y bajo coste
- 

Hadoop

¿Qué es?



Map-Reduce

¿Qué es?

- Framework de programación, núcleo de Hadoop
- Objetivo: procesar grandes cantidades de información
- **Map**: divide y vencerás. Repartes la ejecución de una tarea entre los diferentes nodos.
- **Reduce**: recibir los resultados de map y combinar los resultados



HDFS

¿Qué es?

- Hadoop Distributed File System
 - Sistema de ficheros distribuido de Hadoop.
 - Proviene de GFS (Google File System) 2003
 - Capaz de almacenar cientos de petabytes por máquina
 - Ficheros distribuidos en bloques de 128MB y 256MB
 - Redundancia
- 

HDFS

Elementos

- Los archivos en HDFS se dividen en **bloques** que se almacenan como unidades independientes.
 - **Namenode**: gestiona el acceso a los datos y el almacenamiento de metadatos
 - **Datanode**: Almacenamiento de datos.
 - **BlockCaching**: Cacheo de bloques para permitir un acceso rápido.
 - **Federación**: escalado agregando name nodes.
- 


Hadoop

Distribuciones



Hadoop

Ecosistema



Hadoop

Ecosistema

- **Pig:** es un lenguaje de alto nivel que traduce a “MapReduce”.
- **Hive:** Convierte una transformación en lenguaje SQL en Pig o directamente MapReduce.
- **Ambari, Ganglia, Nagios** ofrecen una interfaz de acceso al clúster
- **Sqoop:** Permite ejecutar aplicaciones MapReduce que introducen o extraen información de bases de datos SQL.

Hadoop

Ecosistema

- **Flume:** sirve para introducir datos en streaming en Hadoop.
 - **Oozie:** permite programar la ejecución de los Jobs de MapReduce.
 - **Storm:** Proceso de flujos de datos en tiempo real con Apache Hadoop. Reproducción de los datos que no se han procesado correctamente la primera vez
 - **Mahout:** librería de Machine Learning que permite escribir aplicaciones MapReduce
- 

Conclusiones

- Hadoop es una de las herramientas más potentes para realizar trabajos en entornos Big Data
- **HDFS**: almacenamiento distribuido y redundante
- **Map-Reduce**: modelo de programación para el procesamiento paralelo de grandes conjuntos de datos.
- **YARN**: Un framework para la programación de la gestión de recursos del cluster



HDFS

MapReduce

Yarn

Hive

Pig

Avro

Scoop

Oozie

Flume

Storm

ZooKeeper

Introducción a Hadoop

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data