

Introducción a Spark

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data




Spark

Ecosistema

- Spark proporciona únicamente un motor de cómputo
 - Spark es agnóstico respecto al sistema de almacenamiento
 - Casos de uso frecuentes:
 - Transformación de datos ,
 - Consultas de datos masivas
 - Aplicación de streaming,
 - Machine Learning.
- 

Spark

Ecosistema



Spark


Arquitectura

- Maestro/Esclavo
- El proceso driver (**Driver Node**) gestiona la ejecución e informa al usuario
- Los procesos ejecutores (**Workers Nodes**) procesan las tareas asignadas por el driver
- Esta arquitectura es independiente del sistema de gestión del cluster (spark, yarn...)




Spark

Arquitectura




Spark

Arquitectura



Spark

Modelo de Ejecución



- **Particiones:** Fragmento distribuido de los datos
- **Trabajos (job):** Operación sobre un conjunto de datos distribuido
- **Tareas (tasks):** Operación en paralelo sobre una partición

Spark

RDDs

- Es el concepto básico de trabajo en Spark
 - Son inmutables. Es decir una vez creados no se pueden modificar.
 - Se pueden transformar para crear nuevos RDDs o realizar acciones sobre ellos pero no modificar.
 - Se guarda la secuencia de transformaciones para poder recuperar RDDs de forma eficiente si alguna máquina se cae
 - Están distribuidos en el clúster en los nodos workers
- 

Spark

Transformaciones

- **Transformaciones**
 - Convierten cada registro del RDD en uno, varios o ninguno.
 - Transforman un RDD en otro RDD
- Las transformaciones en Spark son **perezosas**
 - no computan sus resultados inmediatamente
 - Recuerdan las transformaciones aplicadas a algún conjunto de datos base


Spark

Acciones


- Calculan valores sobre todo el RDD o recopilan datos para enviarlos al driver.
- Transforman un RDD en datos secuenciales

Actions

```
reduce(func)  
collect()  
count()  
first()  
take(n)  
saveAsTextFile(path)  
countByKey()  
foreach(func)  
...
```



Spark



Introducción a Spark

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data