

Computación Paralela con Spark

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data



Ejemplo 5.3 - Computación paralela con Spark ☆

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda Guardado por última vez: 10:04

+ Código + Texto

servidor de Spark. Además configuraremos el entorno Spark con las variables que sean necesarias.

NOTA:

1. la última versión de PySpark es la 3.1.2 [link](#)
2. Puede tardar un poco tiempo en hacer todos los procesos de descarga de datos pyspark tardar en

```
[1] # Install spark-related dependencies
!apt-get install openjdk-8-jdk-headless -qq > /dev/null
!wget -q http://apache.osuosl.org/spark/spark-3.1.2/spark-3.1.2-bin-hadoop2.7.tgz
!tar xzf spark-3.1.2-bin-hadoop2.7.tgz

!pip install -q findspark
!pip install pyspark

# Set up required environment variables

import os
os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
os.environ["SPARK_HOME"] = "/content/spark-3.1.2-bin-hadoop2.7"
```

https://colab.research.google.com/drive/1DDCw_cu7uwALT560vGQ9twmiyqESPOET?usp=sharing



Big_Data
Aplicado



Curso Especialización
Inteligencia Artificial y
Big Data