

Map/Reduce

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

MapReduce

- Tratamiento de grandes volúmenes de datos.
 - Reto: ¿Cómo distribuir el cálculo o /procesamiento?
 - La programación distribuida/paralela es complicada.
 - MapReduce intenta superar estos inconvenientes.
 - Modelo de manipulación de datos y cálculos de Google
 - Forma “elegante” de trabajar y manipular Big Data.
- 

MapReduce

Ejemplo

- Disponemos de un documento muy grande.
- Necesitamos contar el número de veces que una palabra aparece en el fichero.
- **Ejemplo:** Analizar el log de un servidor web para buscar URLs populares.

```
words(doc.txt) | sort | uniq -c
```



MapReduce


Pasos

- Leer secuencialmente el volumen de datos.
 - **Map:** extraer algo relacionado con el problema.
 - **Group by key:** ordenar y mezclar.
 - **Reduce:** agregar, resumir, filtrar o transformar.
 - Salida del resultado.
 - Map/Reduce se implementan para el problema.
- 

Map/Reduce

Map


- Entrada: valores atributo valor (key-value)
- $\text{Map}(k, v) \rightarrow \langle k', v' \rangle *$



Map/Reduce

Group by key


- Recoger todos los pares con misma clave
- Fusión Hash, Barajar, ordenar, dividir.



Map/Reduce

Reduce

- Recoger todos los valores pertenecientes a la clave y la salida



MapReduce

WordCount

The crew of the space shuttle Endeavor recently returned to Earth as ambassadors, harbingers of a new era of space exploration. Scientists at NASA are saying that the recent assembly of the Dextre bot is the first step in a long term space based man/machine partnership. "The work we're doing now -- the robotics we're doing - is what we're going to need

Big document

(The, 1)
(crew, 1)
(of, 1)
(the, 1)
(space, 1)
(shuttle, 1)
(Endeavor, 1)
(recently, 1)
....

(key, value)




(crew, 1)
(crew, 1)
(space, 1)
(the, 1)
(the, 1)
(the, 1)
(shuttle, 1)
(recently, 1)
...

(key, value)

MapReduce

WordCount




(crew, 1)
(crew, 1)
(space, 1)

(the, 1)
(the, 1)
(the, 1)

(shuttle, 1)
(recently, 1)
...

(key, value)



(crew, 2)
(space, 1)
(the, 3)
(shuttle, 1)
(recently, 1)
...

(key, value)

MapReduce

WordCount


```
def map(key,value) :  
    # key: document name  
    # value: text of the document  
  
    for each word w in value:  
        emit(w,1)  
  
def reduce(key,values) :  
    # key: a Word  
    # value: recuentos (lista...)  
    result = 0  
    for each count v in values:  
        result += v  
    emit(key,result)
```



MapReduce

Distribución

- Todas las fases se distribuyen con muchas tareas que realizan el trabajo



MapReduce

Resumen

- Particionar los datos de entrada.
- Programar la ejecución del programa en un conjunto de máquinas.
- Realizar el paso de “*group by key*”
 - cuello de botella práctico.
- Gestión de los fallos de las máquinas
- Gestionar la comunicación necesaria entre máquinas



Map/Reduce

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data