

Apache Hive

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data


Apache Hive



- Procesar datos estructurados en Hadoop.
- Consultas y análisis sobre datos estructurados.
- Almacena el esquema en una base de datos y los datos en HDFS.
- Proporciona un lenguaje basado en SQL (HiveQL, HQL).
- Procesamiento distribuido + SQL.
- Rápido, escalable y extensible.


Apache Hive

Arquitectura



Apache Hive


Arquitectura



Apache Hive


Metastore

- Almacenamiento de Metadatos
- Bases de datos, tablas, columnas
- Particionado, usuarios, etc.
- Se basa en una BD relacional embebida.
- Pueden usarse otras bases de datos relacionales




Apache Hive

Metastore



Apache Hive


Driver



- Obtiene la información necesaria del Metastore
- Traduce las sentencias SQL a Jobs MapReduce
- Lanza los Jobs en el cluster.

Apache Hive

Tablas Hive



- Una tabla Hive se almacena en un conjunto de archivos HDFS
- Una tabla se particiona en distintos subdirectorios
- Los archivos están en un directorio configurable.

`hive.metastore.warehouse.dir`

Hive vs Impala



■ Hive

- Se basa en MapReduce
- Más lento
- Más robusto
- Para procesos por lotes



■ Impala

- No usa MapReduce
- Más rápido
- Menos robusto
- Consultas interactivas

Apache Hive

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data