

HiveQL

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

HiveQL

- Hive Query Language (HiveQL) es un lenguaje de consulta de Hive para procesar y analizar datos estructurados en un **Metastore**.



Hive

Tipos de Datos

- **Integer:** TINYINT, SMALLINT, INT, BIGINT
 - **DecimalType:** FLOAT , DOUBLE
 - **Date/Time:** TIMESTAMP, DATES
 - **STRING:** STRING, VARCHAR, CHAR
 - **COMPLEX:** STRUCT, MAP, ARRAY
- 

HiveQL

Bases de datos

```
hive> create database banco;  
hive> create database if not exists  
banco;
```

```
hive> create database banco WITH  
DBPROPERTIES (...)
```

```
hive> describe database extended  
demo;
```

```
hive> drop database if not exists  
banco;
```



HiveQL

Tablas


- Se utilizan las convenciones similares al SQL.
 - Gran flexibilidad en el almacenamiento de los archivos de datos de las tablas.
 - **Tablas internas** (gestionadas): Se elimina tanto datos como metadatos.
 - **Tablas externas**: para compartir con otras herramientas.
- 

HiveQL

Tablas Internas

```
hive> create table emplist  
      (Id int, Name string,  
       Salary float)  
      row format delimited  
      fields terminated by ',';
```

```
hive> describe bd.employee ;
```



HiveQL

Tablas Internas

- Una vez creada la tabla interna, el siguiente paso es cargar los datos en ella.
- Podemos cargar fácilmente los datos de cualquier archivo a la base de datos.

```
hive> load data local inpath  
' /home/data/hive/emp_details'  
into table demo.employee;
```



HiveQL

Tablas Externas

- Nos permite crear y acceder a una tabla y a unos datos de forma externa.
- Los datos no están presentes en el directorio Hive.
- Si intentamos eliminar la tabla, se borrarán los metadatos de la misma, pero los datos siguen existiendo.



HiveQL

Tablas


```
hive>Alter table emp rename to emp_data;
```

```
hive>Alter table emp_data add columns  
      (age int);
```

```
hive> Alter table emp_data  
      replace columns  
      ( id string, first_name string, age int);
```

```
hive> Alter table emp_data  
      change name first_name string;
```

```
hive> drop table emp_data;
```



Hive

Particionamiento

- Dividir la tabla en algunas partes en función de los valores de una columna concreta.
- Dado que los datos se almacenan en trozos, el tiempo de respuesta de la consulta es más rápido.
- Se puede hacer de forma **estática** o **dinámica**



Hive

Particionamiento Estático

- Es necesario pasar los valores de las columnas particionadas manualmente mientras se cargan los datos en la tabla.
- El archivo de datos no contiene las columnas particionadas.

```
CREATE TABLE student (id int, name  
string, age int, institute string)  
partitioned by (couse string)  
Row format delimited  
Fields terminated by ','
```



Hive

Particionamiento Dinámico

- Los valores de las columnas particionadas existen dentro de la tabla.
- No es necesario pasar los valores de las columnas particionadas manualmente.

```
hive>set hive.exec.dynamic.partition=true;
```

```
hive>set hive.exec.dynamic.partition.mode=nonstrict;
```



Hive

Bucketing


- Técnica de organización de datos.
- Divide grandes conjuntos de datos en partes más manejables conocidas como **buckets**.
- Útil cuando la implementación del particionamiento se hace difícil.
- También se pueden dividir las particiones en **buckets**



Hive

Bucketing

- Está basado en un proceso de hashing.
- Se calculan los módulos del valor de la columna actual y el número de cubos necesarios.
- Los datos se almacenan en el cubo correspondiente.



Hive

Bucketing

```
hive> set  
hive.enforce.bucketing = true;  
  
hive> create table emp_bucket(  
    id int, Name string ,  
    Salary float)  
    clustered by (id)  
    into 3 buckets  
    row format delimited  
    fields terminated by ',';
```



HiveQL

SELECT

- Se utiliza para recuperar los datos de una tabla.
 - **WHERE:** Filtra los datos utilizando el estado y te da un resultado finito.
 - Los operadores y funciones generar una expresión que satisface la condición.
- 
- Two overlapping teal circles are located in the bottom right corner of the slide, serving as a decorative element.

HiveQL

SELECT

```
SELECT [ALL | DISTINCT] select_expr,  
select_expr, ...  
FROM table_reference  
[WHERE where_condition]  
[GROUP BY col_list]  
[HAVING having_condition]  
[CLUSTER BY col_list | [DISTRIBUTE BY  
col_list] [SORT BY col_list]]  
[LIMIT number];
```



HiveQL

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data