

# Apache Impala

## Big Data Aplicado

Francisco Pascual Romero  
FranciscoP.Romero@uclm.es



**Big\_Data**  
Aplicado



Curso Especialización  
Inteligencia\_Artificial y  
Big\_Data

# Impala

## ¿Qué es?

- Motor SQL de propósito general.
- Analítico y Transaccional.
- Consultas de cualquier duración.
- Se ejecuta directamente sobre Hadoop.
  - Formatos de ficheros
  - Gestores de Almacenamiento
  - Nodos de procesamiento.
- Alto rendimiento
  - C++
  - No MapReduce.


# Impala

## Objetivos

- Se ejecuta como un servicio distribuido en cluster
    - Impalad
    - StateStore/CatalogStore
  - Recibe consultas de los usuarios.
  - Estas consultas son distribuidas a los nodos con datos sobre la consulta.
  - Si algún nodo falla, la consulta falla.
  - Conecta con el metastore de Hive.
- 


# Impala

## Arquitectura



# Impala

## Arquitectura



# Impala

## Clientes

- Hue
- Clientes JDBC
- Impala Shell
- Ejecución de Consultas
- Tareas Administrativas



# Impala

## Impalad

- Se ejecuta en los DataNodes.
  - Coordina y ejecuta las consultas.
  - Cada instancia de Impala puede recibir, planificar y coordinar las consultas de los clientes de Impala.
  - Las consultas se distribuyen entre los nodos Impala
  - Estos nodos actúan entonces como workers, ejecutando fragmentos de consultas en paralelo.
- 

# Impala

## Statestored

- Comprueba la disponibilidad de cada *impalad*
- Transmite el estado de salud de cada nodo a los demás nodos con frecuencia.
- Se utiliza esta información con el fin de optimizar la distribución de consultas.
- Notificación de fallos.





# Impala


## Catalogd

- Metastore: información de tablas y columnas y definiciones. (Hive)
  - ¿qué bases de datos están disponibles y cuál es la estructura de esas bases de datos?
  - Almacenamiento en bases de datos relacionales.
  - Cada nodo Impala almacena en caché todos los metadatos a nivel local.
  - Este Daemon notifica los cambios relevantes en los esquemas
- 

# Impala

## Ejecución de Consultas


- Llega la petición procedente de diferentes procedencias.



# Impala

## Ejecución de Consultas


- **Planner** transforma la petición en colecciones de fragmentos de planes.
- **Coordinador** inicia la ejecución de los daemons remotos



# Impala

## Ejecución de Consultas

- Los resultados intermedios son intercambiados por los impalad's
- Coordinador los combina y los envía al cliente.



# Apache Impala

## Big Data Aplicado

Francisco Pascual Romero  
FranciscoP.Romero@uclm.es



**Big\_Data**  
Aplicado



Curso Especialización  
Inteligencia\_Artificial y  
Big\_Data