

Pig: Conceptos Básicos

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Pig

¿Qué es?



Apache Pig

- Plataforma para analizar grandes conjuntos de datos.
- Lenguaje de alto nivel para expresar programas de análisis de datos.
- Infraestructura para evaluar estos programas
- Paralelización Masiva

Pig

¿Qué es?




Apache Pig

- Infraestructura: Compilador que produce secuencias de programas Map-Reduce.
- Lenguaje: Pig Latin
 - Facilitad de programación.
 - Optimización
 - Extensibilidad

Pig

Arquitectura



PigLatin

Ejemplo

```
messages = LOAD 'messages' ;  
  
warns = FILTER messages BY  
        $0 MATCHES '.*WARN+.*' ;  
  
STORE warns INTO 'warnings' ;
```



PigLatin

Conceptos

- **Bag:** relación/tabla, conjunto de tuplas.
- **Statement:** operación que toma un bag de entrada y genera uno de salida.
- **Script**
 - (E): Los datos se leen desde el sistema de archivos
 - (T): Una cantidad de operaciones se realizan en los datos
 - (L): Se escribe de vuelta en el sistema de archivos

PigLatin

Ejemplo

```
messages = LOAD 'messages' ;  
  
warns = FILTER messages BY  
        $0 MATCHES '.*WARN+.*' ;  
  
STORE warns INTO 'warnings' ;
```



PigLatin

Tipos de Datos

- **Simples:**
 - int, long, float, double,
 - chararray, bytearray
- **Complejos**
 - Una relación es una bolsa (bag)
 - Una bolsa es una colección de tuplas (tuples).
 - Una tupla es un conjunto ordenado de campos (field).
 - Un campo es un dato.

PigLatin

Operadores

- **Aritméticos:**
 - add, subtract, multiply
 - divide, module,
- **Condicionales:** bincond, Case
- **Lógicos**
- **Comparación**
 - Expresiones regulares



PigLatin

Operaciones

- **LOAD:** Carga datos desde el sistema de archivos
 - **ORDER:** Clasifica una relación basado en uno o más campos.
 - **SPLIT:** Particiona una relación en una o más relaciones.
 - **STORE:** Almacena datos en el sistema de archivos
- 

PigLatin

Operaciones

- **FILTER:** Selecciona un conjunto de tuplas de una relación basado en una condición.
- **FOREACH:** Itera las tuplas de una relación generando una transformación de datos.
- **GROUP:** Agrupa los datos en una o más relaciones
- **JOIN:** Une dos o más relaciones (unión interna o externa)



PigLatin

Operaciones

- **DESCRIBE** Retorna el esquema de una relación.
- **DUMP:** Vuelca los contenidos de una relación en la pantalla.
- **EXPLAIN:** Exhibe los planes de ejecución de MapReduce



Pig

Resumen

- Se basa en **flujos de datos**
 - Secuencias encadenadas sobre los datos.
- **Lenguaje procedural**
 - ¿cómo lo hago?
- **Expresividad.**
- **Extracción, Transformación y Carga**
- **Exploración rápida de datos**
 - Creación flexible de tuplas

Pig: Conceptos Básicos

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data