

Ingestar datos con Flume

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Flume




- Ingestar información (no estructurada) desde diferentes fuentes al cluster hadoop
- Fuentes de Datos no estructuradas:
 - Logs de servidores Web
 - Redes Sociales
 - Correos electrónicos
- Distribuido, eficiente, fiable y con alta disponibilidad.

Flume



- La arquitectura de Flume se basa en **Agentes**.
- Los agentes son procesos Java.
- Funcionan como **pipeline** canalizando eventos de un lugar a otro.



Flume

Agentes

- **Fuente (source):** Consume los eventos enviados por una fuente externa.
 - Ej: twitter, servidor web
- **Canal (channel):**
 - Almacena cada evento recibido
 - Guarda los datos hasta que sigue el flujo.
- **Sumidero (sink):** del canal al repositorio externo (HDFS)


Flume

Configuración

```
# nombres de componentes
a1.sources = r1
a1.sinks = k1
a1.channels = c1

# configuración de la fuente
a1.sources.r1.type = netcat
a1.sources.r1.bind = localhost
a1.sources.r1.port = 44444

# describir el sumidero
# logger en consola
a1.sinks.k1.type = logger
```




Flume

Configuración

```
# canal: buffer en memoria
a1.channels.c1.type = memory
a1.channels.c1.capacity = 1000
a1.channels.c1.transactionCapacity = 100

# conexiones
a1.sources.r1.channels = c1
a1.sinks.k1.channel = c1
```




Flume

Ejecución

```
# nombre del agente  
# directorio de configuración  
# fichero de configuración
```


```
bin/flume-ng agent  
    --conf conf  
    --conf-file example.conf  
    --name a1  
    -Dflume.root.logger=INFO,console
```



Flume

Ejecución

```
# podemos entonces hacer telnet
# en el puerto 44444
# y enviar a Flume un evento:
$ telnet localhost 44444
Trying 127.0.0.1...
Connected to localhost.localdomain
(127.0.0.1).
Escape character is '^]'.
Hello world! <ENTER>
OK
```



Flume

Ejecución

La terminal de Flume mostraría:

12/06/19 15:32:19 INFO

source.NetcatSource: Source starting

12/06/19 15:32:19 INFO

source.NetcatSource: Created

serverSocket:sun.nio.ch.ServerSocketChannelImpl[/127.0.0.1:44444]

12/06/19 15:32:34 INFO

sink.LoggerSink: Event: { headers:{}
body: 48 ... Hello world!. }





Ingestar datos con Flume

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data