



Planificación de Flujos de Trabajo

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Planificador de tareas

- Hay muchos trabajos que son interdependientes entre sí
- El inicio de un trabajo solo se puede hacer tras la finalización de otro.
- Un trabajo de Hive (almacenamiento) recibe la entrada de la salida de MapReduce.
- Organizar el trabajo y programar las tareas.
- Planificador de tareas





¿Qué es?

- **Apache Oozie:** ejecución y gestión de trabajos Hadoop.
- Combinación de diferentes tipos de trabajo en una “pipeline” de ejecución.
- Secuenciar Tareas.
 - Sqoop, Flume
 - MapReduce, Pig
 - Hive, Impala
- Se pueden paralelizar dos o más trabajos al mismo tiempo.
- Extensible, fiable y escalable



¿Qué hace?

- Desencadena las acciones en el flujo de trabajo.
- Inicia la tarea en el flujo de trabajo.
- Motor de Ejecución de Hadoop.
- Detección de finalización de la tarea.
 - URL de callback al inicio.
 - Oozie notifica la devolución
 - Sondeo (polling) de estado.




Tipo de Trabajos

- **Oozie Workflow Jobs** - La ejecución de las acciones en la secuencia se especifica mediante grafos acíclicos dirigidos (DAGs).
- **Oozie Bundles:** - Agrupaciones de *Jobs* en múltiples flujos de trabajo y paquetes de coordinación.
- **Oozie Coordinator Jobs:** - Se activan de acuerdo a la disponibilidad de datos y en momentos concretos.



DAG


- El grafo acíclico dirigido (DAG) ordena las acciones que deben realizarse en una secuencia en el flujo de trabajo de Hadoop.





**Nodos de
Acción**


- Tarea del flujo de trabajo.
- Mover archivos a HDFS, ejecutar un trabajo de MapReduce, Pig o Hive, importar datos usando Sqoop, ejecutar shell scripts, etc.





Nodos de Control


- Controla la ejecución del flujo de trabajo entre las acciones.
- Se pueden seguir diferentes ramas dependiendo del resultado del nodo de acción anterior





Nodos de
Control


- **Start:** Inicio del Trabajo
- **End:** Final del trabajo
- **Error:** Aparición del error y mensajes/acciones al efecto.





DAG


- Secuencias de acciones dependientes unas de otras mediante entradas/salida.





DAG


- Tipos de acciones: Java, Shell, MapReduce, Hive, Pig.





DAG

- Se pueden establecer condiciones para ejecutar unas opciones o no según las salidas de procesos previos.





Resumen

- API de cliente y una interfaz de línea de comandos.
- Lanzar, controlar y monitorizar trabajos desde una aplicación Java.
- API Web Service: Control Remoto
- Ejecución de trabajos de forma periódica.
- Envío de notificaciones cuando finalizan los trabajos.



Planificación de Flujos de Trabajo

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data