

¿Cómo gestionamos la Calidad de Datos?

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado





Curso Especialización
Inteligencia_Artificial y
Big_Data

Data Quality Analysis

- Analiza archivos de datos incrementales y por lotes guardados en HDFS
- Analizar TB's de de datos en un tiempo bajo encontrando anomalías
- Validaciones.: Null, Regex y Tipo de datos.
- Crea informes que muestran las discrepancias en los datos de HDFS
- Validar los datos de HDFS contra las restricciones de violación de datos.


Data Quality Analysis






Data Validation & Quality Metering

- Planificado e incremental
- Formatos de Datos
- Validación de Reglas de Negocio
- Limpieza de datos




Data Cleaning

- Detectar y eliminar inconsistencias
- Comprobaciones basadas en reglas y expresiones regulares.
- “limbo” de datos inconsistentes.
- Informe de Limpieza



Data Profiling

- Descubrimiento de conocimiento preliminar
- Estructura de nuestros datos.
- Extracción de metadatos
- Datos HDFS procesados mediante reglas rápidas.



¿Cómo gestionamos la Calidad de Datos?

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data