

Sumas de Verificación

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Integridad de Datos

Repaso

- **Garantía de la exactitud y coherencia de los datos a lo largo de su ciclo de vida.**
- Garantizar la integridad de los datos es una necesidad básica en un entorno big data.
- Clave en el movimiento de datos entre aplicaciones (ETL, etc.)
- En entornos Big Data (volumen, variedad, velocidad) la integridad de datos es un reto.
- Bloques de datos corruptos HDFS (red, disco duro, etc.)

Checksum

¿Qué són?

- Una suma de comprobación (**checksum**) es una cadena de caracteres y números generada al ejecutar una función hash criptográfica contra un archivo
- Sirve para verificar que un archivo es fiel, no tiene errores y no ha sido modificado desde su fuente original.



Checksum

Características

- El resultado suele ser mucho más pequeño que el tamaño de la fuente.
- El resultado es casi único
- Un pequeño cambio en la fuente origina muchos cambios en el resultado.



CheckSum

Algoritmos

- **b2sum** - Utiliza el resumen de mensajes BLAKE2b
- **cksum** - Comprueba las sumas y cuenta los bytes de un archivo
- **sum** - Comprueba y cuenta los bloques de un archivo.
- **md5sum** - Utiliza el resumen de mensajes MD5
- **sha1sum, sha224sum, sha256sum, sha384sum, sha512sum** - Utiliza compendios de mensajes SHA-1/SHA-2

Ejecución en Linux

```
$ md5sum quijote.txt
```

```
5ec9ea693fafdad2379b838f392b631e  quijote.txt
```

```
$ sha256sum quijote.txt
```

```
5f110a42988f80e119de8aec4a0a1ec399e53c60b7027b  
63996c3e0458192f95  quijote.txt
```

```
$ sha512sum quijote.txt
```

```
5a3bfb9f283f940c9d383381eccb265a06f0e18a0ca4fe  
0b699d850054259cca0abdad5cfb8d94c70dbd2e95def0  
298bb4042f5bc764e8d9b223f61d1e1fc2de  
quijote.txt
```



HDFS

- Utiliza la suma de comprobación para la integridad de los datos.
- Calcula las sumas de comprobación para cada bloque de datos y finalmente las almacena en un archivo oculto separado en el mismo espacio de nombres de HDFS.
- **ChecksumException**

HDFS

- Los algoritmos tradicionales requieren la lectura secuencial de todo el fichero. Imposible en Big Data.
 - HDFS utiliza la comprobación de redundancia cíclica de 32 bits (CRC32)
 - El tamaño total del CRC de primer nivel es aproximadamente $1/128$ del tamaño de los datos.
 - El segundo nivel de CRC es aproximadamente $1/16384$ del tamaño de los datos. Es el que se usa
- 

HDFS

- Al recibir los DataNode los datos se calcula, almacena y comprueba el checksum.
- Cada nodo de datos individual mantiene un registro persistente de la verificación de la suma de comprobación
- Se puede desactivar la verificación de la suma de comprobación al enviar un trabajo al clúster.



Ejecución en HDFS

```
$ hdfs dfs -checksum /project1/file.txt  
000002000000000000000000000000003e50be59553b2ddaf  
401c575f8df6914
```

```
$ hdfs dfs -checksum /project2/file.txt  
000002000000000000000000000000001952d653ccba138f0  
c4cd4209fbf8e2e
```



Sumas de Verificación

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data