

Movimiento de datos entre clústers con distcp

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Distcp

- Es una herramienta utilizada para realizar grandes copias inter/intra-clúster
- Utiliza MapReduce para llevar a cabo su distribución, la gestión y recuperación de errores y la elaboración de informes.
- Expande una lista de archivos y directorios en la entrada a las tareas de map, cada una de las cuales copiará una partición de los archivos especificados en la lista de origen.


Distcp

Ejecución

```
bash$ hadoop distcp  
hdfs://nn1:8020/foo/bar \  
hdfs://nn2:8020/bar/foo
```

```
bash$ hadoop distcp  
hdfs://nn1:8020/source/first \  
hdfs://nn1:8020/source/second \  
hdfs://nn2:8020/target
```

```
bash$ hadoop distcp -update  
hdfs://nn1:8020/source/first \  
hdfs://nn1:8020/source/second \  
hdfs://nn2:8020/target
```



Distcp

Posibles Errores

- Colisiones entre varias fuentes.
 - Se abortan las copias
 - Informe de archivos omitidos.
 - Cada NodeManager pueda alcanzar y comunicarse con los sistemas de archivos de origen y destino
 - Tanto el origen como el destino deben ejecutar la misma versión del protocolo o utilizar un protocolo compatible con versiones anteriores.
- 

Distcp

Funcionamiento


- DistCp utiliza trabajos MapReduce para copiar archivos entre clusters, o dentro del mismo cluster en paralelo.
1. Construir la lista de archivos a copiar (conocida como lista de copias)
 2. Ejecutar un trabajo MapReduce para copiar archivos, con la lista de copias como entrada.



Distcp

Funcionamiento

1. Construir la lista de archivos a copiar (conocida como lista de copias)
2. Ejecutar un trabajo MapReduce para copiar archivos, con la lista de copias como entrada.



Distcp


Snapshots

- HDFS Snapshots son copias puntuales de solo lectura de HDFS.
- Se tarda $O(1)$ en crearlas y se pueden hacer en paralelo. de copias como entrada.
- Informe de diferencias entre snapshots.
 - Diferencias entre dos instantáneas en base a operaciones básicas.



Distcp

Snapshots



Distcp

Arquitectura

- **DistCp Driver:** El controlador de DistCp analiza los argumentos pasados al comando DistCp en la línea de comandos.
 - **CopyGenerators:** responsables de crear la lista de elementos que se van a copiar desde el origen.
 - **InputFormats/MapReduce:** Responsables de la copia real de los archivos y directorios de la ruta de origen a la de destino.
- 

Movimiento de datos entre clústers con distcp

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data