

Clúster Hadoop en Amazon EMR

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data

Amazon EMR



- Plataforma de clúster administrado que simplifica la ejecución de los marcos de trabajo de Big Data
- Servicio de Amazon para crear clústeres.
- Cuenta necesaria en AWS/AWS Educate.

Amazon EMR


Características

- Facilidad de uso (y aprovisionamiento)
- Bajo coste: pay-as-you-go
- Elasticidad: escalable en nodos y almacenamiento
- Seguridad: VPCs, grupos de seguridad, encriptación cliente/servidor
- Confiabilidad: monitorización, reemplazo de nodos



Amazon EMR

Arquitectura



Amazon EMR

Pricing

Tipo instancia	Precio de Amazon EC2	Precio de Amazon EMR
m4.large	0,10 USD por hora	0,03 USD por hora
p3.16xlarge	24,48 USD por hora	0,27 USD por hora

3 instancias/día

~1782 USD/día

3 instancias/mes

~53460 USD/mes

3 instancias/año

~650000 USD/año

Amazon EMR

Creación

Configuración general

Nombre del clúster

☐ Registro ⓘ

Modo lanzamiento ☒ Clúster ⓘ ☐ Ejecución de pasos ⓘ

Configuración de software

Versión ⓘ

- Aplicaciones ☒ Core Hadoop: Hadoop 2.8.5 with Ganglia 3.7.2, Hive 2.3.6, Hue 4.4.0, Mahout 0.13.0, Pig 0.17.0, and Tez 0.9.2
- ☐ HBase: HBase 1.4.10 with Ganglia 3.7.2, Hadoop 2.8.5, Hive 2.3.6, Hue 4.4.0, Phoenix 4.14.3, and ZooKeeper 3.4.14
- ☐ Presto: Presto 0.227 with Hadoop 2.8.5 HDFS and Hive 2.3.6 Metastore
- ☐ Spark: Spark 2.4.4 on Hadoop 2.8.5 YARN with Ganglia 3.7.2 and Zeppelin 0.8.2

☐ Usar el catálogo de datos de AWS Glue para metadatos de tabla ⓘ

Amazon EMR

Creación

Configuración de hardware

Tipo de instancia m4.large

Número de instancias 3 Nodos maestros: (1 y Nodos principales: 2)

Seguridad y acceso

Par de claves EC2 hpc-key

Permisos ☒ Predeterminado ☐ Personalizado

Use las funciones de IAM predeterminadas. Si las funciones predeterminadas no son adecuadas, puede crear funciones personalizadas. Si las funciones personalizadas no están presentes, se crearán automáticamente para usted con la política de administración de políticas administradas para las actualizaciones de las políticas administradas.

Rol de EMR [EMR_DefaultRole](#) ⓘ

Perfil de instancia de EC2 [EMR_EC2_DefaultRole](#) ⓘ

Clúster Hadoop en Amazon EMR

Big Data Aplicado

Francisco Pascual Romero
FranciscoP.Romero@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data