

Big Data Aplicado

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

Capítulo 15

Modelos de Inteligencia de Negocios

José Angel Olivas Varela

Este capítulo está dedicado a describir la implantación de modelos de Inteligencia de Negocios, describiendo con más profundidad aquellas herramientas más usadas, como son los ‘cuadros de mandos’ o Dashboards.

Como se ha visto, la Inteligencia de Negocios no es más que el conjunto de sistemas, estrategias y herramientas cuyas funcionalidades están orientadas al apoyo a la toma de decisiones en una organización con el fin del desarrollo exitoso de su negocio. Intentan potenciar la disponibilidad y el análisis oportuno e inteligente de los datos clave para el negocio. Su adecuada implantación y uso exigen una visión integradora y estratégica del funcionamiento de la entidad, así como el dominio de los procesos y flujos de información que la caracterizan.

De forma independiente o combinada, las principales soluciones actuales de inteligencia de negocios son:

- **Dashboards (Cuadros de mando).**
- **Sistemas Data Warehouse (almacenes de datos).**
- **Data Marts** (repositorios personalizados para el análisis de datos de interés para un grupo específico de trabajadores o área).
- **Query Reporting Tools** (herramientas de consulta e informes).
- **On Line Analytical Processing: OLAP** (procesamiento analítico en línea).
- **KDD y Data Mining** (minería de datos).
- **Executive Information Systems: EIS** (sistemas de información ejecutiva).
- **Decision Support Systems: DSS** (sistemas de ayuda a la decisión).
- **Recommender Systems** (sistemas recomendadores).

- **Sentiment Analysis Opinion Mining** (análisis de sentimientos y minería de opiniones).

15.1. Origen: Los datos

15.1.1. Datos, información, conocimiento

Como ya se ha visto anteriormente, debemos distinguir claramente entre **datos** (contenido bruto), **información** (resúmenes, datos “presentables”) y **conocimiento** (mayor nivel de abstracción que nos permite tomar decisiones ante nuevas situaciones). Habitualmente hoy en día la gestión de datos se queda en un análisis descriptivo, es decir, la visualización de gráficos o lo que se suelen llamar “cuadros de mandos” o “*dashboards*”, que veremos detalladamente en el próximo tema, que ayudan a la persona responsable a tomar decisiones. Por ejemplo, esto puede venir muy bien en un entorno médico, porque permite a los profesionales tener una información más completa y procesada de los pacientes, historias clínicas, pruebas... para poder tomar decisiones. Pero no debemos quedarnos ahí, se debe ir hacia la analítica predictiva y prescriptiva, modelos que permitan extraer conocimiento a partir de los datos y la información que podamos usar para mejorar sustancialmente la práctica clínica.

15.1.2. Tipos de Datos

Como hemos visto, de forma resumida las diferentes organizaciones y empresas suelen clasificar los datos según su origen y tipo de la siguiente forma:

- **Fuentes de datos.** Dónde se originan los datos, habitualmente se consideran las siguientes:
 - *Externas:* no dependen directamente de la organización. Muchas veces puede haber problemas y limitaciones para su uso o acceso, y en otros casos pueden resultar caros.
 - *Internas:* dependen directamente de la organización, no suele haber problemas y limitaciones para su uso o acceso, y normalmente no suponen ningún tipo de coste para la organización.
- **Tipos de datos.** Normalmente se suele hablar de datos:
 - *Estructurados:* datos con formato o esquema fijo que poseen campos fijos. Por ejemplo las clásicas bases de datos relacionales. Suelen ser los más usados como origen de los procesos de Minería de datos.
 - *Semi-estructurados:* no tienen formato fijo pero contienen etiquetas u otros marcadores que permiten separar los diferentes elementos, por ejemplo: los Weblogs o algunos campos de tipo texto en muchas bases de datos.

- *No estructurados*: también se suelen denominar desestructurados. Datos sin tipo predefinido. Se almacenan como documentos u objetos sin una estructura uniforme, por ejemplo: documentos de texto o multimedia.

Por lo tanto, se puede establecer una taxonomía básica inicial de los tipos de datos que suelen ser considerados en Inteligencia de Negocios (Business Intelligence), principalmente para los procesos de Análisis:

■ **Datos Internos estructurados:**

Suele ser la categoría más abundante y mejor entendida actualmente en las organizaciones, pero cada vez parece más necesario cambiar el enfoque hacia los datos externos desestructurados. Como ejemplos se pueden considerar los Perfiles Web, registros de clientes, usuarios, inventario, recursos humanos, financieros, ventas. . .

■ **Datos Externos estructurados:**

Extensión de los anteriores, pero con restricciones de existencia, disponibilidad y accesibilidad. Como ejemplos se pueden considerar los historiales de créditos o viajes, registros de morosos, censales, telefónicos. . .

■ **Datos Internos no estructurados:**

Pueden suponer una excelente fuente para extraer conocimiento y un buen campo de pruebas para las técnicas y herramientas analíticas. Como ejemplos se pueden considerar cualquier tipo de documentos de texto o multimedia, datos de sensores, foros, comentarios en las propias webs. . .

■ **Datos Externos no estructurados:**

La mayor área de estudio y oportunidad actualmente, sobre todo para recoger las opiniones de los consumidores y usuarios. Como ejemplos se pueden considerar los sensores externos, blogs y todas las consideradas “redes sociales” (social media): Twitter, Facebook, Instagram, Google+. . .

También hoy en día es frecuente hablar de Bases de datos relacionales o *SQL* frente a las *No SQL*. En las primeras, el volumen de los datos si crece lo hace poco a poco y de forma previsible y controlada, las necesidades de proceso se suelen poder asumir en un único servidor y no suele haber picos de uso del sistema imprevistos. En las segundas el volumen de los datos puede crecer puntualmente de forma descontrolada o no prevista, las necesidades de proceso tampoco se pueden prever y se pueden tener picos de uso del sistema en diferentes ocasiones.

15.1.3. Cómo se consiguen y dónde residen los datos

Los datos se pueden conseguir o generar de muy diferentes formas. Entre las más habituales podríamos destacar las siguientes:

- **Sistemas Transaccionales:** operadores que recogen las peticiones a través de Call-Centers...
- **Transacciones** que se generan en las Webs (ficheros weblogs)...
- **Los sensores** permiten capturar las magnitudes físicas o químicas y convertirlas en datos, por ejemplo: temperatura, luz, distancia, aceleración, inclinación, desplazamiento, presión, fuerza, humedad, sonido, movimiento o el pH.
- **Redes sociales, etc.**

Es interesante destacar la relevancia actual de la adquisición, manejo, transmisión, uso y almacenamiento de lo que se suelen denominar Datos en Tiempo Real (Real Time Data). Se producen en tiempo inmediato, algunos provienen de sensores y muchos suelen ser no estructurados (por ejemplo, los provenientes de redes sociales), lo que provoca diversas necesidades específicas y problemas para su tratamiento.

Hasta hace muy pocos años, cuando se hablaba de “bases de datos”, los profesionales del ámbito podían tener una idea bastante aproximada y conocimiento sobre casi todos los soportes y herramientas existentes, porque eran relativamente pocas y conocidas. En los últimos años ha habido una explosión en tipos, herramientas y productos disponibles, los que imposibilita un conocimiento completo de los mismos y obliga a los profesionales a una actualización permanente y muy rápida en estas tecnologías. Cada día aparecen nuevos sistemas de soporte para diferentes bases de datos. Sirvan como ejemplos:

- **Bases de datos documentales** (Document Databases):
MarkLogic, Couchdatabase, MongoDB...
- **Bases de datos de columna ancha** (Wide Column Stores):
Aerospike, Redis, Riak, Amazon DynamoDB...
- **Bases de datos gráficas** (Graph Databases):
Neo4j, Infinite Graph...
- **Bases de datos Valor-Llave** (Key-Value Databases):
Accumulo, Hypertable, Cassandra, Apache Hbase, Amazon SimpleDB...




Figura 15.1: Diferentes tipos de Bases de Datos. Fuente: <http://www.aryannava.com>

Esta gran diversidad de sistemas de almacenamiento para los muy variados tipos de datos provoca que cada vez sea más importante y usado el concepto de **Lago de Datos** o *Data Lake*, que podríamos describir como un repositorio para grandes cantidades y variedades de datos, tanto estructurados como no estructurados. El lago acepta entradas desde diversas fuentes y puede preservar tanto la fidelidad de los datos originales como las diversas transformaciones que se les van haciendo, incluso simultáneamente desde diferentes departamentos, lo que puede generar diferentes evoluciones en paralelo de los mismos datos originales, por ejemplo desde el departamento de publicidad y del de ventas. Los programadores podrían actuar directamente sobre los datos que se están transmitiendo para una analítica en tiempo real. El lago puede servir como zona de montaje del *Data Warehouse*, la ubicación de los datos tratados con más cuidado para reportes y análisis en modo *Batch*.

Por lo tanto, se debe abandonar la forma clásica de partir únicamente de una base de datos relacional (y habitualmente numérica) para un determinado proceso de análisis de datos, que es lo que se hace casi en la totalidad de los casos en la actualidad, y comenzar a pensar en usar como origen un contenido más amplio y heterogéneo del *Data Lake*.

What is a data lake?

A repository for large quantities and varieties of data, both structured and unstructured.




Figura 15.2: ¿Qué es un "Lago de datos"?

Esto, desde mi punto de vista, provoca la necesidad de evolucionar desde lo que se suele hacer ahora, un mero análisis estadístico o con una única técnica de aprendizaje automático sobre una única base de datos numérica hacia una Minería de Datos que parta de un conjunto de datos variado y heterogéneo y que use diversas técnicas en diferentes momentos con el objetivo de obtener un conocimiento común, según los objetivos que se pretendan conseguir. Pero esto no es una tarea fácil, requiere un extenso conocimiento sobre tipos de datos y su tratamiento, técnicas de análisis e Ingeniería del Conocimiento. Quizá esta debería ser la formación requerida para un auténtico "*Científico de Datos*" o en común del equipo de análisis. Pero creo que actualmente la realidad en las organizaciones dista mucho de esta concepción.

15.2. Herramientas actuales (en entornos Big Data) para implementar estas soluciones

El crecimiento exponencial de generación de datos en todos los ámbitos de la ciencia y la sociedad ha dado lugar al fenómeno denominado Big Data: capacidad de gestionar (almacenar, acceder, procesar, interpretar, transmitir, analizar...) grandes volúmenes de datos que exceden las capacidades de lo que podríamos denominar "software convencional" para hacerlo [1]. Estos datos pueden proceder de muy diversas fuentes como sensores (IoT *Internet of Things*, *Smart Cities*...), redes sociales, bases de datos de pacientes, estudios epidemiológicos... Son de naturaleza heterogénea, lo que hace necesario usar nuevas herramientas para poder gestionarlos, frente a lo que habitualmente se almacenaba en bases de datos relacionales (estructuradas) tradicionales. Como se ha comentado, se suele hablar de

“data lake” refiriéndose a un repositorio para grandes cantidades y variedades de datos, tanto estructurados como no estructurados. Consisten en nuevos modelos de bases de datos, como *mongoDB*, *InfiniteGraph*, *amazonDynamoDB*, *apacheHBASE*, *Cassandra*, *etc.* que permiten cumplir estas funciones.

Para ello, hoy en día hay diversos “ecosistemas” Big Data [2], como *Spark* (apache) o los de *Google*, *IBM*, *amazon* o *Microsoft*, que permiten combinar bases de datos avanzadas con herramientas de procesado. Para visualización son muy usadas herramientas como *QlikView* (<http://global.qlik.com/>), *Microsoft Power BI* (<http://powerbi.microsoft.com/>) o *Tableau* (<http://www.tableau.com>). Pero, como se ha dicho, se debe tender a la predicción y prescripción, como proponen empresas como *Microstrategy* (<https://www.microstrategy.com/es>). Aunque existen muchas herramientas que lo pretenden (aquí se puede ver un análisis de las 52 mejores <https://www.predictiveanalyticstoday.com/top-predictive-analytics-software/>), la única forma de hacerlo “a medida” para sistemas de ayuda a la decisión tan complejos es acudiendo a la figura del “científico de datos” (*data scientist*), que, como se describe en este documento, debe poseer conocimientos de computación, bases de datos, Inteligencia Artificial, Aprendizaje Automático, estadística, visualización, reconocimiento de patrones, KDD y Minería de Datos... y es una figura muy demandada y escasa en ambientes profesionales, científicos o académicos, que debe ser capaz de seleccionar y guiar las herramientas y técnicas más adecuadas para cada problema y objetivos concretos.




Figura 15.3: Relación/diferencias entre BI y Big Data.

Por último, es importante resaltar que en los entornos de Big Data se suelen usar tanto lenguajes de programación específicos (R, Scala, Python...) como librerías que permiten implementar todas las técnicas que se describen. Entre ellas, podemos destacar Mahout (*Scalable Machine Learning and data mining*, <http://mahout.apache.org/>), MLlib (*Apache Spark's scalable machine learning library* <https://spark.apache.org/mllib/>) o H2O (<https://www.h2o.ai/>).

Se profundiza en estos aspectos en otros temas/módulos de este Programa.

15.3. Cuadro de mandos.

Un cuadro de mando es un sistema computacional que recoge los principales indicadores de una compañía y los representa de una forma clara y útil. Esto permite mejorar el control y la toma de decisiones. Este tipo de herramientas son también conocidas con el nombre de *Dashboards* y se enmarcan en el *Business Intelligence* (BI).

Como se ha visto, los cuadros de mando deben mostrar sólo aquella información que sea necesaria, de una forma sencilla y por supuesto, sinóptica y resumida. El cuadro de mandos se guía y construye a partir de indicadores, habitualmente llamados KPIs (*Key Performance Indicators*). Estos indicadores deben ser adaptados expresamente para cada compañía para poder ser útiles a una empresa en concreto.

Algunos ejemplos de KPIs pueden ser:

- Finanzas: Márgenes, ROI, Rentabilidad etc..
- Producción: rendimientos por sección, defectos por millón, eficiencia de equipos etc..
- Logística: Rotación, rupturas de stock etc..

Los cuadros de mando son una herramienta de gestión que se utiliza para medir la situación y evolución sobre un tema determinado desde una perspectiva general. Se pueden utilizar para controlar las subvenciones, la evolución del presupuesto o la incidencia de una pandemia. El cuadro de mando ofrece una serie de indicadores numéricos y gráficos de forma objetiva y en tiempo real que, como ya hemos visto, puede ayudar a la toma de decisiones.

Características. Los cuadros de mando deberían tener unas características que permitieran a los diferentes actores que los usan dentro de una empresa:

- Tener una visión holística sobre el negocio.
- Procesar los datos para transformarla en información.
- De la información, obtener conocimiento para la toma de decisiones.
- Mostrar y procesar información de distintas fuentes de datos.
- Utilización de elementos de alto impacto visual: gráficos.

Ventajas de un cuadro de mando:

1. Muestra una visión completa de la situación actual.

Un cuadro de mando ofrece una visión global y detallada de la marcha del negocio, recogiendo distintos aspectos que son fundamentales para el buen desarrollo de la empresa. Esta visión global está basada en datos en tiempo real por lo que muestra una situación fidedigna en ese momento.

2. Facilita el diseño y planificación de estrategias.

La visión general y en tiempo real que se tiene a través de los indicadores de un cuadro de mando permite diseñar estrategias a medio y largo plazo, además de proporcionar información para la toma de decisiones rápidas (acciones a corto plazo).

La información que ofrece un cuadro de mando sobre las estrategias generadas, no solo se basa en los resultados, sino que tienen en cuenta otras variables importantes que tienen influencia.

3. Ofrece información inteligente

Un cuadro de mando ofrece información de forma completa de la cual se puede extraer conocimiento que es prácticamente imposible de obtener con los sistemas de información de los orígenes de los datos usados.

4. Reduce los posibles riesgos.

Con el uso de un cuadro de mando se tiene acceso a una visión de la evolución del tema de estudio, pudiendo analizar tendencias y adelantarse a acontecimientos, lo que reduce mucho los riesgos.

5. El cuadro de mando fomenta la visión estratégica de la organización.

El cuadro de mando incluye todos los indicadores y métricas necesarias para tener una visión holística del negocio, permitiendo cumplir los objetivos marcados en la estrategia de la organización.

De nada sirve la información que ofrece el cuadro de mando si los distintos departamentos no realizan una correcta implementación de los mismos, de ahí la gran importancia de involucrar a todo el personal con la estrategia de la organización.

6. Mejora la comunicación interna.

La implicación de todos los empleados en la estrategia de la empresa se traduce en una mejora en el conocimiento de los objetivos y la comunicación entre los empleados. Los canales de comunicación interna tendrán un mayor flujo en ambas direcciones.

7. Permite valorar el éxito de la estrategia.

El cuadro de mando muestra indicadores que ofrecen unos valores numéricos, a través de los cuales se puede apreciar si la estrategia que se está desarrollando está alcanzando los objetivos fijados previamente. El cuadro de mando ofrece información real y medible por lo que es una herramienta potente y concreta para diagnosticar el estado actual del negocio.

Desventajas de un cuadro de mando:

Utilizar un cuadro de mando tiene algunos riesgos que hay que tener en cuenta. Las empresas son entes dinámicos que evolucionan y cambian con el tiempo. Es por eso, que el desarrollo del cuadro de mando adecuado es importante, así como la actualización del mismo, añadiendo o quitando la información en los indicadores necesarios. Un software profesional para la gestión de un cuadro de mando tiene un coste económico. Es importante elegir una herramienta de cuadros de mando con un coste adecuado a las posibilidades de la organización, para que no represente un gasto desproporcionado. Una mala elección o interpretación de los indicadores del cuadro de mando puede llevar a la toma de decisiones erróneas o no favorables para la empresa. Por eso, lo más aconsejable es disponer de un asesoramiento profesional sobre la configuración e interpretación del cuadro de mando, o la contratación de profesionales cualificados para ello.

15.3.1. Tipos de cuadros de mandos.

Según la estructura y el flujo de la información se suelen diferenciar dos tipos de cuadros de mando (Figura 15.4), según manejen un flujo lineal de datos e información basado en la lógica tradicional soportada en los propios datos, por ejemplo aquellos basados en los sistemas de almacenamiento de datos de tipo *Data Warehouse*, como pueden ser los cubos OLAP, o si usan una lógica asociativa que permite una visión más global, multidimensional y rápida de la información que reflejan los datos, como el que usan algunas herramientas actuales como las del entorno Qlik.




Figura 15.4: Tipos de cuadros de mando según la estructura y el flujo de la información.

Desde la perspectiva de la finalidad hacia la que van enfocados, se suelen distinguir estos tres tipos de cuadro de mando:

- **Cuadro de Mando Integral (Balance Scorecard).** Se usa para ayudar a las compañías a definir sus objetivos en función de su formulación estratégica. Se basa en distintas perspectivas (financiera, de cliente, de procesos y de las personas y su aprendizaje).
- **Cuadro de Mandos Estratégico (CME).** Se trata de CME cuando la naturaleza del indicador utilizado es la estrategia de la compañía.
- **Cuadro de Mando Operativo (CMO).** Son herramientas de control empresarial orientadas a la monitorización de las diferentes áreas de negocio a través de indicadores. La periodicidad de los CMO es crítica y puede ser diaria, semanal o mensual. Es un buen punto de partida para las empresas que desean implantar un cuadro de mando integral.

Información que se suele mostrar en los cuadros de mando.

Un cuadro de mando puede mostrar visiones de los datos muy variadas. La figura 15.5 muestra los modos de visualización más usados actualmente.



Figura 15.5: Diferentes tipos de información que se suele mostrar en un cuadro de mando.

Las representaciones más directas y sencillas suelen mostrar relaciones numéricas entre elementos nominales, como puede ser la clasificación o *ranking* de dichos elementos en base a uno de sus valores (o la agregación de varios), la distribución de dichos valores, su valor relativo con respecto al total, la comparación de los elementos entre sí o la variación (desviación) con respecto a valores medios o umbrales prefijados.

Pero las dos representaciones que tienen más importancia desde mi punto de vista son, en primer lugar, las de las series temporales, que muestran la evolución de un fenómeno en el tiempo con respecto a una o varias variables que lo describen. Es razonable pensar que si nuestro objetivo es anticiparnos a cómo se comportará un determinado elemento en un instante futuro o cuál será su posible evolución, debemos tener una representación de este tipo.

Estrechamente vinculadas a las series temporales están las representaciones de las correlaciones o los ajustes de funciones. Su valor reside en que cuando nos queramos anticipar a un suceso futuro en un escenario de **pronóstico**, recordad, aquello que tiene que ver con la extrapolación, con la tendencia, el comportamiento regular de la evolución de un fenómeno, nos permiten visualizar dicha evolución temporal. Otra cosa es cuando estamos en un escenario de **predicción**, cuando la evolución del fenómeno no sigue una tendencia regular, está condicionada por elementos específicos. Es ahí donde el buen hacer del diseñador del cuadro de mando puede llevarnos de la información al conocimiento, como veremos en el ejemplo que se muestra al final de este capítulo.

15.3.2. Herramientas comerciales más utilizadas.

El “*Magic Quadrant for Analytics and Business Intelligence Platforms*” del *Gartner Group* (<https://www.gartner.com/>) es la referencia en cuanto a la clasificación de herramientas analíticas para BI. En la figura 15 podemos ver los resultados de 2021.

Se puede observar que la tendencia es similar a la iniciada en 2018. Apenas hay variaciones significativas en la terna de herramientas líderes: Power BI, Tableau y Qlik.

Muy pocas empresas se plantean la pregunta “¿Implanto SAP o Cognos?”, por ejemplo, pero sí se plantean “¿Power BI o Qlik?”. En la gran mayoría de casos, las empresas que trabajan con un BI que no es Power BI-Tableau-Qlik, es porque ya disponían previamente de la herramienta (Ej. SAP) y tienen muchas cosas desarrolladas para ese entorno. Cuando una empresa tiene que decidir qué nueva herramienta de BI va a usar, rara vez eligen alguna herramienta que no sea una de estas tres.



Figura 15.6: Cuadrado mágico de Gartner para 2021.

Teniendo en cuenta las ediciones de años anteriores, se puede observar que Power BI ha bajado muy ligeramente en cuanto a “completitud de visión” y “habilidad para ejecutar”. Tableau ha tenido un fuerte descenso en cuanto a “habilidad para ejecutar”, lo que la aleja del liderato con Power BI y la acerca bastante a Qlik, que ha mejorado en “completitud de visión” y ha empeorado muy ligeramente en “habilidad para ejecutar”. En resumen, Power BI se mantiene, Tableau empeora y Qlik mejora un poco. A continuación se muestran los puntos fuertes y débiles que Gartner resalta para cada una de estas herramientas.

Power BI ha tenido una implantación masiva en el mercado a través de Microsoft Office. Dispone de una hoja de ruta de producto completa y visionaria. Microsoft hace una actualización semanal de la versión cloud, añadiendo cientos de características. Sus principales fortalezas son su integración con Office 365 y Teams, la relación precio/prestaciones y la incorporación constante de nuevas funcionalidades (en particular en lo que concierne a IA y ML). Sus debilidades tienen que ver con que la versión local es mucho menos potente que la cloud que solo se ejecuta en Azure. Además, su administración es compleja cuando se manejan contenidos de Big Data grandes.

Tableau tiene una estrategia de marketing muy potente. Ha extendido sus capacidades como herramienta y ha mejorado la parte de preparación y gestión de los datos. Sus principales fortalezas son la experiencia de usuario para la analítica de datos, con unos gráficos de mucha calidad. Los usuarios de Tableau son muy fans de Tableau (en el mismo sentido que ocurre con los clientes fieles a Apple). Al ser Tableau propiedad de Salesforce y tener Salesforce una base de clientes tan grande, cuanto más se compenetre Tableau con Salesforce, más posibilidades tendrá de ampliar su cuota de mercado. Sus debilidades tienen que ver con que el diseño cloud tiene una gran herencia de su versión local, el precio es alto y hay problemas de integración con otras herramientas cercanas.

Qlik tiene una fuerte visión de producto en lo relativo a la integración con IA y ML y hay mucha flexibilidad para desplegar la herramienta, tanto en local como en la nube. Mejoró sus capacidades de alerta, inteligencia continua (análisis visual basado en búsquedas, analítica conversacional, conocimiento asociativo) e integración. Sus principales fortalezas son su flexibilidad para instalar el producto y que aumentó sensiblemente el alcance de sus capacidades. Además ayuda a sus clientes a usar los datos, a través de muy variados y abundantes programas de formación. Sus debilidades tienen que ver con la complejidad para el cálculo de precios, sobre todo cuando se añaden productos extra cuya licencia va aparte. Es la que menos usuarios tiene y hay cierta falta de cohesión de producto con nuevas utilidades que está incorporando de otras herramientas que ha comprado.

15.3.3. Pruebas y ejemplos.

Como muestra del uso y utilidad de los cuadros de mando se ha elegido el entorno Qlik, con sus principales variantes Qlikview y QlikSense.

QlikView permite a los usuarios acceder a conocimiento más profundo mediante la creación de sus propias pautas de análisis. Dispone de infinidad de opciones de personalización en objetos, tamaños, colores, etc. Además, permite personalizar el acceso y la seguridad de los informes a través de Windows. Por otro lado, posibilita el uso de Macros y Desencadenadores dentro de los objetos de QlikView, lo que permite acciones automáticas como por ejemplo hacer una selección al pulsar un botón o una imagen.

QlikSense es una herramienta de BI mucho más fácil de usar, intuitiva y adaptable a diferentes tamaños de pantalla y formas. Está pensada y preparada para dispositivos móviles y tabletas, y para que sea accesible desde cualquier ubicación. Permite que los usuarios finales sean capaces de generar sus propias gráficas y personalizaciones adaptadas a cada una de sus necesidades. También permite compartir estas personalizaciones con el resto de la organización, haciendo colaborativo el trabajo realizado. Dispone de una seguridad personalizable y una visualización atractiva e interactiva sin necesidad de parametrizaciones complejas.

Las dos herramientas tienen muchas cosas en común como por ejemplo:

- Las dos herramientas son capaces de conectarse a cualquier base de datos para analizarlos y visualizar la información lo que permite disponer de una única herramienta de análisis escalable a todos los sistemas de una organización.
- A nivel de script de carga de datos las dos herramientas son idénticas. Qlik dispone de webs de guía y ayuda tanto para Qlik Sense¹ como para QlikView², muy útiles para iniciarse en el manejo de estas herramientas.
- Ambas permiten una carga de datos rápida e inteligente con posibilidad de hacer cargas incrementales de datos mediante archivos QVD.
- Disponen de un motor con lógica asociativa, como hemos ya mencionado, lo que facilita el procesamiento en memoria, indexación automática y capacidad de ofrecer información “No relacionada” con los filtros seleccionados como, por ejemplo, ver los automóviles que he vendido este año, pero no vendí el año anterior.
- También permiten acometer búsquedas globales en todas las hojas del documento y poder analizar los datos y aplicar filtros.

Qlik sacó al mercado Qlik Sense en 2014 intentando que fuera un punto de inflexión en las herramientas de BI tradicionales, pensada para el autoservicio de cualquier persona de la Organización y complementaria a QlikView. Con ambas herramientas, se pretenden cubrir todas las necesidades del mercado.

Respecto a ejemplos hechos con QlikSense, en esta página del Reino Unido³ hay cinco ejemplos completos de cuadro de mando. Son ejemplos de de “Cadena de Suministro”, “Ventas”, “Marketing”... Hay que entrar en cada uno de ellos y pulsar sobre el botón “Launch demo”. Esto permite probar los cuadros de mando sin tener que instalar nada en el PC.

Por último, hay unas páginas específicas de ejemplos completos tanto para QlikSense⁴ como para Qlikview⁵ propuestos por la propia empresa.

15.4. Algoritmos y técnicas estadísticas en la minería de datos.

Como se ha visto, de forma general podemos decir que las tareas principales en un proceso de minería de datos podrían ser las siguientes:

1. Caracterización o resumen.

¹https://help.qlik.com/es-ES/sense/August2021/Content/Sense_Helpsites/Home.htm

²https://help.qlik.com/es-ES/qlikview/May2021/Content/QV_HelpSites/Home.htm

³<https://www.quickintelligence.co.uk/solutions/>

⁴<https://demos.qlik.com/qliksense>

⁵<https://demos.qlik.com/qlikview>

Como se ha comentado, la caracterización de datos a veces consiste en un resumen de las características generales de los objetos de una clase (cluster). Los datos correspondientes a una clase son normalmente recuperados por una consulta a la base de datos para extraer la esencia de esos registros para los distintos niveles de abstracción. Este resumen se puede formalizar en una tabla o estructura similar.

2. Discriminación o contraste.

La discriminación de datos produce lo que se denomina reglas discriminantes, que consisten básicamente en la comparación de las características generales de los objetos entre dos clases, referidas como clase de objetivo y clase de contraste.

3. Análisis de asociación.

Análisis de asociación es la búsqueda de lo que comúnmente se conoce como “reglas de asociación”. Se estudia la frecuencia con la que dos o más elementos aparecen juntos en las bases de datos, y se identifican los conjuntos de elementos frecuentes. Otro umbral, la confianza, que es la probabilidad condicional con la que un elemento aparece cuando otro elemento lo hace, se utiliza para determinar las reglas de asociación. Esta técnica es ampliamente usada, por ejemplo en empresas de comercio electrónico para analizar la cesta de la compra de sus clientes con el fin de identificar sus gustos y preferencias.

4. Clasificación/segmentación.

La segmentación se basa en el análisis de la organización de los datos dentro de clases o clusters.

Los principales métodos basados en estadística para la minería de datos y que suelen ser los más usados son los siguientes.

Las técnicas de Regresión expresan la formalización de una relación significativa entre dos o más variables para calcular pronósticos a partir del conocimiento de los valores en un individuo concreto. Entre otros tipos de Regresión, para el análisis de datos se suele usar:

- Lineal (aproximación de la dependencia entre una variable dependiente y variables independientes).
- Múltiple (para predecir el valor de una variable dependiente a partir de variables independientes).
- Logística (para predecir variables categóricas).
- CART (Classification And Regression Trees, Leo Breiman).
- Etc.

Además, también se suelen usar otras técnicas clásicas en el ámbito de la estadística, como:

- Técnicas de extrapolación de funciones.
- Técnicas de aproximación y ajuste de funciones.
- Técnicas de agrupamiento basadas en medidas estadísticas (clustering).
- Etc.

Dentro del análisis predictivo juega un papel fundamental el Análisis de Series temporales. Se suelen clasificar en:

- Estacionarias (medias y/o variabilidad se mantienen constantes).
- No Estacionarias (medias y/o variabilidad NO se mantienen constantes, cambios de varianza/tendencias).

También es importante señalar qué otros métodos se usan para otras diferentes necesidades en el análisis de series temporales:

- Tendencias: método de Mínimos cuadrados. Tendencias evolutivas. Diferenciación estacional.
- Predicción: alisadores exponenciales.
- Interpolación: Predecir datos faltantes.

Es importante reseñar que muchas se pueden englobar tanto en técnicas estadísticas como de *Machine Learning*, es decir, la mayoría de las técnicas de aprendizaje automático se basan en mecanismos estadísticos.

15.5. Conclusiones

En este tema se han presentado las principales formas de implantación de los conceptos de BI y se ha profundizado en las más básicas y más usadas, que son las orientadas a los cuadros de mandos o *Dashboards*. También se han citado las técnicas estadísticas más usadas en procesos de minería de datos, otra de las metodologías más usadas en la implantación de BI.

En el capítulo siguiente se presentará un mapa de las técnicas de Inteligencia Artificial que se pueden usar en la implantación actual de los modelos de Inteligencia de Negocios (aunque hasta el momento su implantación está menos extendida de lo que sería deseable), así como una introducción a las técnicas de validación de modelos de BI.

15.6. Bibliografía

1. Siegel, E. (2013). Análítica predictiva. Predecir el futuro utilizando Big Data. Anaya Multimedia-Anaya Interactiva.
2. Mayer-Schönberger, V., Cukier, K. (2013). Big data. La revolución de los datos masivos. Turner.