

SEMMA y P³TQ

KDD: *Knowledge Discovery in Databases*

José Angel Olivas Varela
Joseangel.olivas@uclm.es




Big_Data
Aplicado




Curso Especialización
Inteligencia_Artificial y
Big_Data

SEMMA



- SAMPLE, EXPLORE, MODIFY, MODEL, ASSESS.
- muestrea/selecciona, explora, modifica, modela y evalúa
- Propuesta por la empresa **SAS**, especialmente para trabajar con **su propio software** de minería de datos.

SEMMA



- Se propone que a partir de una **muestra representativa de los datos**, se apliquen técnicas **estadísticas de exploración y visualización**, se seleccionen y transformen variables, se modele con las variables para **predecir** y se **evalúe** la precisión del modelo

SEMMA

Etapas

Muestra (Sample):

- Extracción de una **muestra** del conjunto sobre la que se va a trabajar.
- debe ser un subconjunto **representativo** desde un punto de vista **estadístico**.
- datos que contengan **información relevante** para el objetivo y que a su vez sean **rápidos** de manipular.

SEMMA

Etapas

Muestra (Sample):

- Habitualmente selección al **azar**.
- Se debe asociar un **nivel de confianza**.
- La hipótesis es que si existen **patrones generales** en la base de datos, éstos serán detectados en la **muestra representativa**.
- Es equivalente a la de '**selección**' del proceso KDD.

SEMMA

Etapas

Exploración (Explore):

- Buscando **tendencias**, **valores atípicos** (*outliers*), etc. con el fin de hacerse una idea del contenido y estructura de estos datos seleccionados.
- Herramientas de **visualización** o **técnicas estadísticas** (incluyendo análisis factorial, análisis de correspondencias y la segmentación).
- Es equivalente a la de '**prospección**' del proceso KDD.

SEMMA

Etapas

Modificación (Modify):

- Manipulación y formateo de los datos.
- **Limpieza** de valores anómalos, se tratan los datos faltantes, y se **seleccionan, crean o modifican** las variables con las que se trabajará para dirigir el proceso de modelado.
- Es equivalente a la de **‘preproceso o limpieza de datos’** del proceso KDD.

SEMMA

Etapas

Modelado (Model):

- Creación del modelo que permitirá **predecir** el valor de las variables de respuesta a partir de las variables iniciales seleccionadas.
- Métodos **estadísticos** tradicionales, así como técnicas de **redes neuronales, árboles de decisión, regresión y series temporales** entre otras.
- Es equivalente a las de **'transformación/data mining'** del proceso KDD.

SEMMA


Etapas

Valoración (Assess):

- Se evalúa la **utilidad** y la **precisión** del modelo o modelos creados y usados.
- Es habitual que se use una **parte** de los datos no usados inicialmente, como se hace habitualmente cuando se usan los algoritmos de aprendizaje automático de forma aislada.

SEMMA

Etapas



P³TQ

- La metodología ***Catalyst***, comúnmente conocida como **P³TQ** (***Product, Place, Price, Time, Quantity***).
- Propuesta por **Dorian Pyle** en el año 2003.
- Se compone de dos modelos, el **Modelo de Negocio** y el **Modelo de Extracción de Información**.

P³TQ *Etapas*

- Se proponen cinco **situaciones o puntos de partida** diferentes para un proyecto:

Dato:

- Se exploran los datos en búsqueda de relaciones útiles e interesantes.

Problema / Oportunidad:

- Dado un problema u oportunidad de negocio, ver cómo el análisis de los datos puede colaborar para mejorarla.
- 

P³TQ ***Etapas***

- Se proponen cinco **situaciones** o **puntos de partida** diferentes para un proyecto:

Prospectiva:

- Proyecto diseñado para descubrir dónde el análisis de los datos puede aportar valor en la organización.

Modelo definido:

- Utilizar métodos o técnicas de Minería de Datos para construir un modelo específico para una situación determinada.
- 

P³TQ *Etapas*


- Se proponen cinco **situaciones** o **puntos de partida** diferentes para un proyecto:

Estrategia:

- Dada una situación estratégica, analizar si procesos de este tipo pueden ser útiles para explicar la situación actual y descubrir cuáles son las opciones para resolverla.




P³TQ **Modelo de Negocio**



P³TQ ***Modelo de Explotación de Información***

Modelo de Explotación de Información



SEMMA y P³TQ

KDD: Knowledge Discovery in Databases

José Angel Olivas Varela
Joseangel.olivas@uclm.es



Big_Data
Aplicado



Curso Especialización
Inteligencia_Artificial y
Big_Data