

Big Data Aplicado

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

Capítulo 14

KDD: Knowledge Discovery in Databases

Francisco P. Romero

Este capítulo está dedicado a describir en profundidad la metodología genérica comúnmente usada para el proceso de descubrimiento de conocimiento en bases de datos y la minería de datos (**KDD: Knowledge Discovery in Databases**), ilustrándolo con diversos casos y ejemplos muy variados, que permitan al lector entender la aplicación real de estas etapas y acciones metodológicas.

También se describen más superficialmente las metodologías **SEMMA** y **P³TQ**, que en el fondo no dejan de estar basadas en KDD y la metodología **CRISP-DM**, quizá la más usada hoy en día en entornos empresariales (pero también muy vinculada en su esencia al KDD) y metodologías directamente basadas en CRISP-DM como *Analytics Solutions Unified Method for Data Mining* (**ASUM-DM**) y metodologías “ágiles” como *Team Data Science Process* (**TDSP**) o **Scrum-DM**.

14.1. El proceso KDD (Knowledge Discovery in Databases).

Fayyad y sus colaboradores (Fayyad, Piatetsky-Shapiro, Smyth, [1]) definen el proceso KDD como “**El proceso no trivial de identificar válidos, nuevos, potencialmente útiles y comprensibles patrones en datos**”, utilizando técnicas multidisciplinarias y viendo cómo actúan juntas. El término proceso implica que hay varios pasos, como la preparación de datos o la búsqueda de patrones. El término patrón se puede referir al comportamiento regular de los datos, junto con una descripción y un modelo aplicable al mismo. Los patrones descubiertos deben ser válidos para nuevos casos con cierto grado de certeza. Se necesita que estos patrones sean nuevos, al menos para el sistema y preferiblemente para el usuario y potencialmente útiles.

Por último, estos patrones deben ser comprensibles, todo ello si no es inmediatamente, lo debe cumplir después de un postprocesado. Esta definición implica que deben definirse medidas de la bondad de los patrones, en muchos casos es posible definir medidas de certeza (capacidad de clasificación de nuevos datos) o utilidad (calidad de las predicciones en base a estos patrones). El proceso KDD descrito por Fayyad y sus colaboradores, interactivo e iterativo, es el que refleja la figura 14.1:




Figura 14.1: Proceso KDD, Knowledge Discovery in Databases. Adaptado de Fayyad et al. [1].

14.1.1. Selección: Datos objetivo / Tarjeta de Datos.

Consiste en seleccionar unos ‘datos de trabajo’. Aplicando el conocimiento del dominio y el conocimiento relevante a priori, teniendo en cuenta los objetivos del proceso global del KDD se crea una tarjeta de datos (datos objetivo) que incluirá conjuntos seleccionados de datos o subconjuntos de variables relevantes o ejemplos. Habitualmente se lleva a cabo un análisis previo, prospección para verificar la viabilidad de las hipótesis iniciales. Es decir, se comprueba que los datos de los que se dispone son adecuados para buscar los patrones que se pretende encontrar (hipótesis inicial). Si no se verifica este extremo no tiene sentido continuar con el proceso KDD bajo la hipótesis establecida.

Ejemplo:

Supongamos que disponemos de una base de datos de los clientes de una entidad bancaria de una determinada provincia española, y que nuestro objetivo es diseñar un sistema de ayuda a la decisión en la concesión de créditos bancarios para dicha entidad. Para la tarjeta de datos, se podrían seleccionar los clientes de algunas poblaciones significativas por su renta o el tipo de población, de diferentes rangos de edades, de diferente poder adquisitivo, o cualquier otra característica relevante para el fin que se ha propuesto. Siempre se debe recordar que para que los algoritmos de aprendizaje automático funcionen de la mejor manera posible, el conjunto de datos de entrenamiento debe cubrir razonablemente tanto los espacios de entrada como los de salida. Es decir, tanto los atributos de los ejemplos, como el atributo que permite clasificarlos deben tener un reparto homogéneo, y estará todos suficientemente representados.

14.1.2. Preproceso: Limpieza de Datos.

En esta etapa se procede a la limpieza de los datos, eliminación de ruidos, manejo de campos vacíos, datos perdidos (se suele hablar de datos ausentes o missing values y datos perdidos por el sistema o system missing values), valores desconocidos o por defecto, evolución de datos, outliers e inliers. Se aplican técnicas estándar de bases de datos.

En situaciones de incertidumbre, es decir, cuando faltan datos (en el sentido de valores en campos que hacen que los registros estén incompletos), se debe plantear la posibilidad de rellenarlos con valores prototípicos (por ejemplo, si la base de datos es de muebles y un campo es el número de patas, ante la ausencia de valores podría rellenarse con “4”, que es un número prototípico de patas para una silla) o valores por defecto (en una base de datos de pacientes-síntomas, ante la ausencia de valor para “fiebre” se podría asumir que el paciente NO tenía fiebre como valor por defecto). Esta decisión puede llevarnos a introducir valores erróneos (sillas de 3 patas o pacientes que tenían fiebre y les hemos puesto que no). Es tarea del analista de datos decidir si compensa el nivel de error añadido la ganancia que puede generar este relleno.

En la etapa de preproceso también se llevan a cabo las labores de agregación de datos. Por ejemplo, en la base de datos de clientes de un banco, ante el desarrollo del sistema de ayuda a la decisión en la concesión de créditos bancarios, es posible que convenga sumar los ingresos mensuales de los clientes (y los gastos) en vez de trabajar con todos los movimientos producidos en las cuentas. También es necesario eliminar algunos registros o datos que puedan contener errores, como por ejemplo fechas con formato no adecuado, edades que se salgan de rango, números introducidos como letras (por ejemplo, escribir con una ‘ó’ mayúscula el número cero).

14.1.3. Transformación: del Clustering a la Clasificación.

En esta etapa, se procede entre otras cosas a la reducción del número de variables, la localización de formas útiles para expresar los datos dependiendo del uso posterior que se les va a dar y de los objetivos del sistema. Se usa el conocimiento experto y técnicas de transformación e informes en bases de datos. Es quizá la fase más crítica y relevante de todo el proceso. Se suele usar inicialmente un algoritmo de *clustering* para agrupar elementos similares, normalmente buscando un número de *clusters* compatible (o coincidente) con la granularidad esperada en las decisiones a tomar.

Por ejemplo, ante la base de datos de clientes de un banco, con el objetivo de desarrollar un sistema de ayuda a la decisión en la concesión de créditos bancarios, es muy probable que lo más adecuado sea establecer tres grupos (*clusters*): el de los “buenos pagadores” a los que se les concedieron los créditos, el de los “malos pagadores”, que no se les concedió y los “dudosos” a los que se les piden mayores garantías.

Otro aspecto importante es que en muchos casos es necesaria una transformación grande de la base de datos, convertirla en otra totalmente diferente. Por ejemplo, en sistemas en los que se quiera predecir o pronosticar a través del uso de series temporales. Normalmente la base de datos inicial debe estar compuesta de registros individuales (por ejemplo, ocurrencias de terremotos) y nos puede interesar construir series temporales de terremotos anteriores a uno “grande” para tratar de encontrar patrones anteriores que permitan establecer un modelo de pronóstico. Esto supone haber partido de una base de datos donde cada registro era una ocurrencia y haberla transformado en otra en la que cada registro es una serie temporal. Aquí también se agruparían estas series temporales según su similitud con el fin de encontrar regularidades o patrones de “evolución sísmica previa a un gran terremoto”.

Por último, es importante señalar que una vez agrupados los elementos, se deben “etiquetar” estos *clusters*, con el fin de convertir este proceso de *clustering* en uno de clasificación. Es decir, en mi sistema de ayuda a la decisión en la concesión de créditos bancarios, al cluster3 que me generó el algoritmo de clustering usado, le asigno el nombre de “buenos pagadores”, al cluster2 el de “dudoso”, etc. con lo que podría transformar la base de datos inicial de clientes en otra con un campo más en cada registro que diga si ese cliente es “buen pagador”, “dudoso”... dependiendo del *cluster* al que pertenezca. Así, hemos convertido este proceso de *clustering* (no supervisado) en uno de clasificación (supervisado). Ahora, por ejemplo se podría generar un árbol de decisión que nos permitiese clasificar a un nuevo cliente según sus características en “buen pagador”, “dudoso”...

Esta idea tiene una repercusión importante: habitualmente (casi siempre, salvo raras excepciones) no basta con usar un único método o algoritmo para llevar a cabo un proceso completo de KDD. Es necesario primero usar *clustering*, no supervisado, para agrupar los datos según su similitud (y transformarlos) y después usar uno de clasificación supervisado (data mining) para poder usarlo en la toma de decisiones (segmentación, predicción...).



Figura 14.2: Proceso KDD, Knowledge Discovery in Databases, reformulado para los entornos Big Data, propuesta por el autor.

Como se puede ver en la figura 14.2, en entornos actuales Big Data se debería partir de un 'Data Lake', no de una única base de datos relacional y numérica. Esto dificulta enormemente el proceso, ya que todos los algoritmos/herramientas que conocemos solo admiten como entrada este tipo de datos, no la heterogeneidad de un lago de datos.

14.1.4. Minería de Datos.

En esta fase, se procede a la elección de los algoritmos de Minería de Datos. Se toman decisiones acerca del modelo que se deriva del algoritmo de Minería de Datos elegido (clasificación, resumen de datos, predicción). Se procede a la búsqueda de patrones de interés, en cuanto a clasificación, reglas o árboles, regresión, clasificación, dependencia, heurísticas, incertidumbre.

Conocimiento: formalización de patrones.

Dentro del proceso KDD descrito, adquiere especial relevancia el paso de Minería de Datos para determinar los patrones de los datos observados. La elección de los modelos a utilizar tiene una componente fundamental de conocimiento de los expertos, supervisado por el Ingeniero de Conocimiento y el analista de datos o científico de datos. En la literatura, véase por ejemplo (Berry y Linoff, [2]), se describe un gran número de algoritmos y técnicas de Minería de Datos. En este tema se introducen fundamentalmente los provenientes de la estadística y el aprendizaje automático. En particular, los algoritmos de Minería de Datos consisten en una mezcla específica de tres componentes (Fayyad et al., [1]):

El modelo

Un modelo contiene parámetros que son determinados a partir de los datos. Dos factores relevantes:

■ **La función**

En la práctica de la Minería de Datos se utilizan funciones de Regresión (comparan datos con valores reales de las variables establecidos mediante predicción), Dependencia (describen dependencias significativas entre variables), Análisis de relaciones entre campos de las bases de datos, pero las más relevantes para la predicción (como evaluación de una situación mediante la comparación de casos reales con situaciones prototípicas) son las siguientes:

- **Funciones de Clasificación:** categorizan un registro dentro de una de varias clases predefinidas.
- **Funciones de Clustering:** categorizan un registro dentro de una de varias clases (clusters), pero a diferencia de la clasificación, las clases las determinan los propios datos, mediante agrupamientos naturales basados en medidas de afinidad, similitud o probabilidad.

- **Funciones de Resumen:** generan una descripción compacta de un subconjunto de datos. Se puede usar un simple ejemplo como media y las desviaciones estándar para todos los campos.
- **Funciones de Análisis de secuencias:** modelizan patrones secuenciales, series temporales. El objetivo es generar la secuencia de estados del proceso que se trata de modelizar.

■ La representación

Se utilizan modelos clásicos, como árboles de decisión, reglas, modelos lineales y no lineales, métodos basados en ejemplos (razonamiento basado en casos), redes bayesianas, modelos borrosos, redes neuronales, algoritmos genéticos, etc. El modelo de representación determinará la flexibilidad de representación de los datos e interpretación del modelo desde el punto de vista humano. Normalmente, cuanto más complejo sea el modelo de representación, es posible que maneje mejor los datos, pero hará que sea mucho más difícil entenderlos. Aunque a nivel de investigación se tiende a utilizar modelos complejos, en aplicaciones reales se utilizan mayoritariamente modelos simples debido a su robustez e interpretabilidad.

El criterio de preferencia

Es aquel que permite seleccionar un modelo o conjunto de parámetros en función de unos datos determinados. Es, en cierto modo, una medida de bondad de la relación entre el modelo y los datos. Normalmente este criterio es explícito y cuantitativo en el algoritmo de búsqueda (por ejemplo, el criterio de encontrar los parámetros que maximizan la probabilidad de algunos datos observados). También suele haber un criterio subjetivo (por parte del Científico de datos o del Ingeniero de Conocimiento) implícito, sobre qué modelos se ha de tener en cuenta inicialmente.

El algoritmo de búsqueda

Es necesario especificar un algoritmo para encontrar modelos particulares y parámetros e incluso criterios de preferencia. En los de búsqueda de parámetros es frecuente que, dado un modelo, el problema de encontrar los mejores parámetros se reduzca a un problema de optimización. En Minería de Datos se suelen utilizar técnicas de optimización sencillas (por ejemplo, el descenso del gradiente) que presentan los problemas de máximos y mínimos locales y otros muy estudiados en el ámbito de la Inteligencia Artificial.

Para finalizar con el ejemplo de la segmentación de clientes para diseñar el sistema de ayuda a la decisión en la concesión de créditos bancarios, hacemos un pequeño resumen de todo el proceso. Se parte de un data lake constituido tanto por las bases de datos de los clientes que suministra la entidad financiera como por otros datos que se puedan añadir, como pueden ser comentarios en las redes sociales, historial de riesgo crediticio, datos poblacionales y de renta per cápita en las diferentes zonas, hábitos de consumo y precios de inmuebles en dichas zonas y un largo etcétera.

La primera acción sería la selección de la tarjeta de datos. Para ello, podríamos quedarnos con los clientes de tres pueblos representativos de la provincia por su actividad productiva, tipo de producción, y nivel de vida. A su vez se podría seleccionar a clientes de las ciudades grandes que vivan en determinados barrios y con diferentes rangos de edad. En cuanto a campos, se eliminarían campos como el DNI, teléfono, otros datos personales que debe ser anonimizado, etcétera. Una vez seleccionados estos datos objetivo, se procede a su preproceso y limpieza. Aquí se podría determinar el nivel de ruido, eliminar y/o rellenar campos vacíos mediante valores prototípicos o por defecto, corregir errores de números o fechas y agregar campos que no tenga sentido manejar de forma individual.

Posteriormente se procedería a la transformación de esos datos preprocesados. Para ello, aplicaríamos un algoritmo de clustering buscando agrupar a los clientes en tres clases: buenos pagadores, borderline, y malos pagadores. Este agrupamiento sería con una función de similitud que tuviera en cuenta un mayor peso en los factores más relevantes de cara a la resolución del problema, como por ejemplo, la capacidad de devolución económica mensual de cada cliente. Una vez agrupados los clientes, en la etapa de minería de datos ya se podría aplicar algún algoritmo de clasificación, puesto que los datos han sido etiquetados en el proceso de clustering anterior. Se podría aplicar por ejemplo un árbol de decisión, o hacer tres tablas resumen de los elementos de cada uno de los tres clusters descubiertos, que nos permitirían comparar un caso real a evaluar con cada una de estas tres tablas mediante una función de similitud y así poder tomar la decisión que suministre la tabla más afín con lo que ya habríamos obtenido conocimiento y lo habríamos plasmado en una aplicación.

14.2. La metodología CRISP-DM

Hay otras metodologías de minería de datos muy conocidas y usadas. Por ejemplo, como veremos más adelante, el *SAS Institute propuso SEMMA (Sample, Explore, Modify, Model, Assess)* y, mucho más conocida y usada, a comienzos de siglo se propuso el ***Cross-Industry Standard Process for Data Mining***, más conocido como ***CRISP DM***, un modelo estándar y abierto muy usado, sobre todo a nivel empresarial para el desarrollo de proyectos de Minería de Datos. Esta metodología es muy similar, en esencia, a la de KDD. Aunque han surgido muchas variaciones e instancias de estas metodologías, en lo esencial siguen siendo muy similares.

En el año 1999 un grupo de empresas europeas, NCR (Dinamarca), AG (Alemania), SPSS (Inglaterra) y OHRA (Holanda), desarrollaron esta metodología de libre distribución denominada CRISP-DM [94], que estructura el ciclo de vida de un proyecto de Ciencia de Datos en seis fases que interactúan entre sí de forma iterativa durante el desarrollo del proyecto (figura 14.3) [3]. Es de libre distribución, la más utilizada y recomendada para aplicar a procesos de este tipo en condiciones empresariales reales.




Figura 14.3: Proceso CRISP-DM, Cross-Industry Standard Process for Data Mining¹.

El estándar incluye un modelo y una guía estructurados en seis fases, algunas de estas fases son bidireccionales, lo que significa que permitirán revisar parcial o totalmente las fases anteriores. Sigue un proceso jerárquico, que tiene cuatro niveles de abstracción: Fase, tareas generales, tareas específicas e instancias de proceso. Cada fase consiste en llevar a cabo tareas generales, completas y estables. Las tareas especializadas describen las acciones de las tareas generales. Por ejemplo, en el segundo nivel (tareas generales) puede existir una tarea general llamada “limpieza de datos”. El tercer nivel describe cómo difiere esta acción de unas situaciones a otras, por ejemplo, la limpieza de datos numéricos y la de datos categóricos. En la práctica muchas tareas pueden llevarse a cabo en orden diferente, con frecuencia será necesario regresar a tareas previas y repetir otras. El cuarto nivel es un conjunto de acciones, decisiones y resultados sobre el proceso de Minería de Datos que se está desarrollando.




Figura 14.4: Otra forma de ver las fases de la metodología CRISP-DM.

Las relaciones pueden existir entre cualquier fase o tarea del proceso, variando de acuerdo con los objetivos, el contexto o por el interés del usuario sobre los datos. El conocimiento oculto que se ha descubierto durante el proceso y la propia solución puede provocar nuevas preguntas que llevan a reiniciar todas las fases en un proceso de mejora, por lo que los procesos de minería subsecuentes se beneficiarán de las experiencias previas. Las flechas internas de la figura 14.4 indican las relaciones más frecuentes entre las fases, aunque se pueden establecer relaciones entre cualquier fase. El círculo exterior simboliza la naturaleza cíclica del proceso de modelado. Las etapas de esta metodología son:

1. **Comprensión del negocio** Se trata de la presentación de los objetivos y requerimientos desde una perspectiva no técnica. También incluye la comprensión de los objetivos y requerimientos del proyecto desde una perspectiva empresarial, con el fin de convertirlos en objetivos técnicos y en una planificación. Se centra en el análisis de los objetivos y requisitos desde una perspectiva comercial, posiblemente también académica y se diseña un plan preliminar para su consecución. De una forma más detallada comprende las siguientes tareas:

- **Establecimiento de los objetivos del negocio:**

- Antecedentes.
- Contexto inicial.
- Objetivos del Negocio.
- Criterios de éxito.

- **Evaluación de la situación:**

- Inventario de requerimientos de Recursos, Hipótesis y Limitaciones.
- Riesgos y Contingencias.
- Terminología.
- Costos y Beneficios.

- **Establecimiento de los objetivos de la Minería de Datos:**

- Objetivos de Minería de Datos.
- Criterio de Éxito de la Minería de Datos.

- **Generación del plan del proyecto:**

- Plan de proyecto.
- Evaluación inicial de herramientas, equipo y técnicas.

2. **Comprensión de los datos.** Consiste esencialmente en familiarizarse con los datos teniendo presente los objetivos del negocio e identificar las características de calidad de los datos y los resultados iniciales obvios. Se pueden considerar varias dimensiones en la calidad de datos: **exactitud**, que se refleje lo que está pasando, **totalidad**, que se encuentren los datos completos en

el sistema, **oportunidad**, accesibles cuando sea necesario, **relevancia**, **nivel de detalle** y **consistencia**, mismos datos en todas las áreas o sistemas, etcétera, por lo que será necesario comprobar como son los datos en cada una de estas dimensiones. Comprende la recolección inicial de datos y permite establecer un primer contacto con el problema, estableciendo las relaciones más evidentes que permitan establecer las primeras hipótesis. De una forma más detallada comprende las siguientes tareas:

- **Obtener los datos iniciales:**
 - Informe de la obtención de los datos iniciales.
- **Descripción de los datos:**
 - Informe con la descripción de los datos.
- **Exploración de los datos:**
 - Informe de la exploración de datos.
- **Verificación de calidad de datos:**
 - Informe de la calidad de los datos.

3. **Preparación de Datos.** Es la selección y limpieza de datos para obtener un subconjunto o vista aprovechable. Incluye las tareas generales de selección de datos a los que se va a aplicar la técnica de modelado, limpieza de los datos, generación de variables adicionales, integración de diferentes orígenes de datos y cambios de formato. La fase de preparación de los datos está muy relacionada con la fase de modelado, puesto que en función de la técnica de modelado que se emplee, los datos requerirán ser preprocesados de diferentes formas. De una forma más detallada comprende las siguientes tareas:

- **Selección de los datos:**
 - Justificación de la inclusión/exclusión de determinados datos.
- **Limpieza de datos:**
 - Informe de la Limpieza de Datos.
- **Construcción de datos:**
 - Atributos derivados.
 - Registros generados.
- **Integración de datos:**
 - Datos combinados.
- **Formateo de datos:**
 - Datos Formateados.

4. **Modelado de Datos:** Consiste en aplicar las técnicas de minería de datos y en la implementación en herramientas. Implica la selección de técnicas de modelado más apropiadas para el proyecto de Ciencia de Datos. Las técnicas que se usan en esta fase se seleccionan en función de los siguientes criterios: ser apropiada al problema, disponer de datos adecuados, cumplir con los requerimientos, tiempo necesario para obtener un modelo y conocimiento de la técnica. De una forma más detallada comprende las siguientes tareas:

- **Selección de la técnica de modelado:**
 - Técnica de modelado
 - Modelado
 - Hipótesis
- **Diseño de la evaluación:**
 - Diseño de pruebas
- **Construcción del modelo:**
 - Configuración de los parámetros del Modelo
 - Descripción del Modelo
- **Evaluación del modelo:**
 - Evaluación del Modelo
 - Revisión de la configuración de los parámetros del modelo

5. **Evaluación:**

Consiste en determinar si los resultados coinciden con los objetivos del negocio e identificar los temas de negocio que deberían haberse abordado. En esta fase se evalúa el modelo, no desde el punto de vista de los datos sino desde el cumplimiento de los objetivos. Se debe revisar el proceso teniendo en cuenta los resultados obtenidos, para poder repetir algún paso en el que se haya podido cometer errores. Si el modelo generado es válido en función de los criterios establecidos en la fase inicial, se procede a su aplicación. De una forma más detallada comprende las siguientes tareas:

- **Evaluación de resultados:**
 - Hipótesis de Minería de Datos
 - Resultados.
 - Criterio de éxito del negocio
 - Modelos aprobados
- **Revisión del Proceso**
- **Establecimiento de los siguientes pasos o acciones:**
 - Lista de posibles acciones
 - Decisión

6. **Despliegue e interpretación:** El objetivo es explotar la utilidad de los modelos, integrándolos en las tareas de toma de decisiones de la organización. Requiere la configuración para minería de datos de forma repetida o continua. Esta última fase puede ser tan simple como la generación de un informe o tan compleja como la repetición periódica y quizás automatizada de un proceso de análisis de datos. Es fundamental documentar todo el proceso y presentar los resultados de manera comprensible. De una forma más detallada comprende las siguientes tareas:
- **Planificación de despliegue**
 - **Planificación de la monitorización y del mantenimiento**
 - **Generación del informe final**
 - **Revisión del proyecto:**
 - Documentación de las experiencias

En la Tabla 14.1 se detallan las tareas que componen cada una de las seis etapas.

Comprensión del negocio	Comprensión de los datos	Preparación de los datos
Determinar los objetivos del negocio: Antecedentes. Objetivos. Criterios de éxito	Recolección inicial de datos: Informe inicial de datos.	Selección de datos: Informe de Inclusión / exclusión.
Evaluar situación: Inventario de recursos, requerimientos, criterios, restricciones, riesgos, contingencias, Terminologías, costes y beneficios.	Descripción de datos: Informe inicial de la descripción de datos.	Limpieza de datos: Informe.
Determinar Metas: Metas de minería de datos y criterios de éxito.	Exploración de datos: Informe de exploración de datos.	Construcción de datos: Atributos derivados, generación de registros.
Generar plan de proyecto: Plan de proyecto, evaluación inicial de herramientas y técnicas.	Verificación de calidad de datos: Informe.	Integración de datos: Datos fusionados.
		Formato de datos: Datos reformateados Conjunto de datos y descripciones.

Modelado	Evaluación	Despliegue/Interpretación
Selección de técnicas:	Evaluar resultados:	Desarrollo del plan:
Técnicas de modelado, modelos supuestos.	Evaluación de datos, minería y criterios de éxito de negocio. Aprobación del modelo.	Desarrollar el plan.
Diseño de pruebas:	Revisión de procesos:	Plan de monitorización y mantenimiento:
Pruebas, Diseño de pruebas	Revisión de procesos.	Informe.
Construcción del modelo:	Determinar próximos pasos:	Generar informe final.
Ajuste de parámetros, modelos, descripciones.	Lista de posibles acciones. Decisión.	Informe final, presentación final.
Evaluar modelo:		Revisión del proyecto:
Evaluar. Revisión de parámetros.		Documentar experiencia.

Tabla 14.1: Tareas en cada fase de la Metodología CRISP-DM.

14.3. Metodología SEMMA.

La metodología SEMMA [4, 5], acrónimo de SAMPLE, EXPLORE, MODIFY, MODEL, ASSESS, que se podría traducir como muestrea/selecciona, explora, modifica, modela y evalúa, se refiere al proceso básico para llevar a cabo tareas de Minería de Datos. Esta metodología es propuesta por la empresa SAS, especialmente para trabajar con su propio software de minería de datos. El acrónimo SEMMA se corresponde a sus cinco fases (figura 14.5). Es frecuente el malentendido de referirse a SEMMA como una metodología para hacer Minería de Datos. En la página de SAS se detalla que SEMMA es una organización lógica de las diferentes funciones de las herramientas de SAS ENTREPISE MINER en relación a las tareas básicas de la Minería de Datos. Se propone que a partir de una muestra representativa de los datos, se apliquen técnicas estadísticas de exploración y visualización, se seleccionen y transformen variables, se modele con las variables para predecir y se evalúe la precisión del modelo.




Figura 14.5: Fases de la metodología SEMMA.

Visto con un poco más de detalle, estas etapas consisten en lo siguiente:

Muestra (Sample):

Extracción de una muestra del conjunto sobre la que se va a trabajar, debe ser un subconjunto representativo, desde un punto de vista estadístico, de datos que contengan información relevante para el objetivo y que a su vez sea rápido de manipular. La representatividad de la muestra es indispensable ya que de no cumplirse

invalida todo el modelo y los resultados dejan de ser admisibles. La forma más habitual de obtener esta muestra es la selección al azar, además para cada muestra a considerar se debe asociar un nivel de confianza en la misma. La hipótesis es que si existen patrones generales en la base de datos, éstos serán detectados en la muestra representativa. Puede verse como equivalente a la de ‘selección’ del proceso KDD.

Exploración (Explore):

Una vez seleccionada la muestra o conjunto de muestras representativas del conjunto inicial, la metodología SEMMA propone que se debe proceder a una exploración de la de esta selección, buscando tendencias, valores atípicos (outliers), etc. con el fin de hacerse una idea del contenido y estructura de estos datos seleccionados. Para ello se propone la utilización de herramientas de visualización o de técnicas estadísticas (incluyendo análisis factorial, análisis de correspondencias y la segmentación) que ayudan a detectar relaciones entre variables. De esta forma se pretende determinar cuáles son las variables esenciales que van a servir como entradas al modelo. Podríamos verla como equivalente a la acción de ‘prospección’ del proceso KDD.

Modificación (Modify):

Esta etapa consiste en la manipulación y formateo de los datos. En esta etapa se procede a la limpieza de valores anómalos, se tratan los datos faltantes, y se seleccionan, crean o modifican las variables con las que se trabajará para dirigir el proceso de modelado. Puede considerarse como equivalente a la de ‘preproceso o limpieza de datos’ del proceso KDD.

Modelado (Model):

Creación del modelo que permitirá predecir el valor de las variables de respuesta a partir de las variables iniciales seleccionadas. Incluye la utilización de métodos estadísticos tradicionales, así como técnicas de redes neuronales, árboles de decisión, regresión y series temporales entre otras. Es equivalente a las de ‘transformación/data mining’ del proceso KDD.

Valoración (Assess):

Se evalúa la utilidad y la precisión del modelo o modelos creados y usados. Es habitual que se use una parte de los datos no usados inicialmente, como se hace habitualmente cuando se usan los algoritmos de aprendizaje automático de forma aislada.

En la figura 14.6 se muestra un esquema de la dinámica general de la metodología.




Figura 14.6: Dinámica de la Metodología SEMMA.

14.4. 14.4. Metodología P³TQ.

La metodología *Catalyst*, comúnmente conocida como P³TQ [6] (*Product, Place, Price, Time, Quantity*), fue propuesta por Dorian Pyle en el año 2003. Se compone de dos modelos, el Modelo de Negocio (figura 14.7) y el Modelo de Extracción de Información (figura 14.8). El Modelo de Negocio propone una serie de pasos para el desarrollo y la construcción de un modelo que permita identificar un problema de negocio. El Modelo de Extracción de Información propone una serie de pasos para la preparación de los datos, selección de las herramientas y modelos iniciales, ejecución, evaluación y comunicación de los resultados. Se proponen cinco situaciones o puntos de partida diferentes para un proyecto:

Dato:

Se exploran los datos en búsqueda de relaciones útiles e interesantes.

Problema / Oportunidad:

Dado un problema u oportunidad de negocio, ver cómo el análisis de los datos puede colaborar para mejorarla.

Prospectiva:

Proyecto diseñado para descubrir dónde el análisis de los datos puede aportar valor en la organización.

Modelo definido:

Utilizar métodos o técnicas de Minería de Datos para construir un modelo específico para una situación determinada.

Estrategia:

Dada una situación estratégica, analizar si procesos de este tipo pueden ser útiles para explicar la situación actual y descubrir cuáles son las opciones para resolverla.



Figura 14.7: Modelo de negocio de la metodología P³TQ.

Tomando algunos de estos puntos o escenarios de partida, la metodología propone una serie de pasos y herramientas para llegar a descubrir el problema y los requerimientos organizacionales que abordará el proyecto, así como los datos necesarios para efectuar el análisis. Las figuras resumen las etapas de cada modelo. En el Modelo de Negocio se encuentran los posibles escenarios de partida, en el centro las herramientas principales que se pueden utilizar, y en la salida la definición de los datos necesarios y los requerimientos para el proyecto. En el Modelo de Explotación de Información se explicitan los pasos de esta metodología para el descubrimiento de patrones o relaciones, en base al problema de negocio identificado.




Figura 14.8: Modelo de Explotación de información de la metodología P³TQ.

14.5. TDSP

El proceso de Ciencia de Datos en equipo, del inglés *Team Data Science Process* (TDSP) es “una metodología de Ciencia de Datos ágil e iterativa para ofrecer soluciones de análisis predictivo y aplicaciones inteligentes de manera eficiente”², de esta manera lo describen en la web de Microsoft. Esta metodología pretende ayudar a mejorar la colaboración y el aprendizaje en equipos de Ciencia de Datos. TDSP propone mejores prácticas y estructuras de Microsoft, así como de otras empresas líderes de la industria, para ayudar en la implementación correcta de iniciativas de Ciencia de Datos. Sus principales componentes son:

1. Definición de un ciclo de vida de Ciencia de Datos.
2. Infraestructura y recursos recomendados para proyectos de Ciencia de Datos.
3. Herramientas y utilidades recomendadas para la ejecución de proyectos.

El ciclo de vida de TDSP es similar a CRISP-DM y su coordinación de procesos utiliza varios elementos de la metodología ágil Scrum, incluidos artefactos claramente definidos, *backlog*, *sprints* y roles de equipo. El ciclo de vida de la metodología TDSP comprende cinco fases principales por las que normalmente pasan los proyectos de este tipo, y a menudo de forma iterativa:

1. Comprensión del problema empresarial.

Esta etapa consiste en definir objetivos e identificar fuentes de datos. La definición de objetivos está orientada a identificar las variables comerciales o de negocio que se necesita predecir. Además, implica definir los objetivos del proyecto a través de preguntas precisas, tales como:

²<https://docs.microsoft.com/en-us/azure/architecture/data-science-process/overview>

- ¿Cuánto? Si el problema a resolver consiste en estimar la relación entre variables numéricas, seguramente será necesario analizar la aplicación de técnicas de regresión.
- ¿Qué categoría? Si el problema a resolver consiste en estimar o predecir una categoría o etiqueta, se necesitará aplicar técnicas de clasificación.
- ¿Qué grupo? Si los datos a tratar no cuentan con una etiqueta, se tendrá que evaluar y definir técnicas de clustering para extraer información oculta en los datos, mediante el análisis de grupos que cuenten con características o particularidades similares.
- ¿Es este caso raro? Ante la situación de eventuales casos, será necesario definir técnicas para la detección de anomalías (outliers).
- ¿Qué opción debería tomarse? Si el problema a abordar necesita proporcionar alguna recomendación, entonces será necesario definir técnicas para implementar sistemas de ayuda a la decisión.

Conjuntamente, en este paso se define el equipo interviniente, especificando roles y responsabilidades de los miembros y las métricas de éxito con las que se medirán los resultados del proyecto. El equipo se define mediante cuatro funciones (no necesariamente excluyentes entre sí:

- Administrador de grupo: supervisa toda la unidad de Ciencia de Datos.
- Líder de equipo: administra el equipo de Ciencia de Datos.
- Líder de proyecto: administra las actividades diarias en el proyecto especificado.
- Colaborador individual del proyecto: miembro del equipo de desarrollo (incluye científicos de datos, analistas de negocio, ingenieros o arquitectos de datos, especialistas, etc.).

En cuanto a las fuentes de datos, se identifican en función de los objetivos, las necesidades y las características de interés del dominio del problema.

2. Adquisición y comprensión de los datos.

El objetivo de esta etapa es generar un conjunto de datos limpio y de calidad. Además, desarrollar una arquitectura de solución a través de tres tareas de ingesta de datos, exploración de datos y una configuración para la canalización de los datos.

3. Modelado.

La meta de esta fase es identificar las características y crear un modelo de aprendizaje automático que sea óptimo, preciso y adecuado para la producción. Esta fase consta de tres tareas: ingeniería de características, entrenamiento de modelos y evaluación de los modelos.

4. Despliegue.

El único propósito de esta fase es la de implantar modelos en un entorno de producción o similar al de producción para la aceptación final del cliente, exponiendo los modelos a través de una interfaz abierta.

5. Aceptación del cliente.

La fase final permite verificar que se cumplan las necesidades de los clientes. Las dos tareas principales que incluye esta fase son: validar el sistema y transferir el proyecto. Finalmente, para el cierre y documentación del proyecto se emite un informe de salida para el cliente. Este informe es técnico y contiene todos los detalles del proyecto que son útiles para aprender a operar el sistema. TSDP proporciona plantillas de informes, los cuales pueden ser personalizados en funciones de las necesidades específicas del cliente. La figura 14.9 es una representación visual del ciclo de vida de la metodología TDSP propuesta por Microsoft.




Figura 14.9: Ciclo de vida de TDSP.

14.6. ASUM-DM

La metodología ASUM-DM, del inglés *Analytics Solutions Unified Method for Data Mining*, es un proceso iterativo para implementar proyectos de Minería de Datos basado en la metodología CRISP-DM. Es un proceso propuesto por IBM y hace énfasis en las nuevas prácticas de la Ciencia de Datos, como el uso de Big Data, análisis de texto, modelado predictivo y automatización de procesos. Fue diseñada para acelerar el tiempo de generación de valor y disminución del riesgo mediante el establecimiento de enfoques y procesos coherentes que aumentan la eficiencia de su implementación. Contiene pasos estructurados, actividades de desarrollo, roles y responsabilidades, plantillas y directrices. IBM define a ASUM como una guía de pasos para efectuar la implementación del ciclo de vida de soluciones de analítica de datos. Se proponen las siguientes seis fases:

1. **Analizar.** En esta fase se determinan los requisitos y necesidades del usuario, objetivos del proyecto, los entregables y se prevé de forma inicial las primeras soluciones posibles.
2. **Diseñar.** Incluye los procesos que tienden al desarrollo de la minería y análisis de datos. También se identifican los recursos y se instala el entorno de desarrollo.
3. **Configurar y construir.** Configurar, construir e integrar componentes basados en un enfoque iterativo e incremental. En esta fase se define un plan de pruebas y validación en múltiples entornos.
4. **Despliegue.** Esta fase establece el flujo de trabajo para implementar los resultados dentro de la empresa de forma que no afecte la actividad productiva normal de la misma. Debe incluir programas de apoyo y formación.
5. **Operar y optimizar.** Esta fase cumple el rol de controlador, analiza el proyecto implementado (el uso de la solución de IBM Analytics), determina la necesidad de aumentar el alcance del proyecto o de realizar pequeños ajustes o mantenimientos.
6. **Gestión de proyecto.** Adicionalmente, ASUM-DM incorpora una quinta fase paralela (figura 14.4), encargada de que las distintas fases del proyecto fluyan sin inconvenientes, esta labor es similar a la realizada por un Scrum Master, en la metodología Scrum. Esta fase ayuda a la gestión y la monitorización del progreso y mantenimiento del proyecto.

Una característica relevante de esta metodología es la carencia de detalle en los procesos que llevan a la minería y el análisis de datos. Además, incorpora una definición de los interesados del proyecto con las características de cada perfil y tareas típicas (como una matriz de asignación de tareas). Cabe resaltar que la guía para la implementación de ASUM-DM solo es accesible mediante un registro en el sitio web de IBM y mediante la instalación de archivos ejecutables que dan acceso a las guías en formato HTML, los cuales son compatibles solo con sistemas operativos Windows.




Figura 14.10: Ciclo de trabajo propuesto en la metodología ASUM-DM de IBM.

14.7. Scrum-DM

Scrum es una metodología de gestión de proyectos iterativa e incremental que involucra buenas prácticas, para controlar el riesgo y optimizar la gestión de un proyecto. En esta metodología los miembros del equipo deben trabajar juntos para entregar valor incremental (productos). En entornos de análisis de datos, Scrum requiere adaptaciones para funcionar con las características de proyectos de este tipo, como por ejemplo, los equipos deben definir *sprints* (iteraciones de duración fija). Así como las metodologías TDSP y ASUM-DM se basan en algunos conceptos de Scrum y CRISP-DM, existen otras propuestas donde se integran metodologías, una de ellas es la metodología Scrum integrada con CRISP-DM (Scrum-DM).

La metodología Scrum-DM utiliza elementos de la metodología ágil Scrum para la gestión del trabajo y CRISP-DM como estrategia para seguir el desarrollo del proyecto de Minería de Datos (figura 14.5). Esta metodología se inicia con la fase de comprensión o entendimiento del negocio de CRISP-DM donde se realiza el análisis de los objetivos y del problema y finaliza en la fase de despliegue donde se propone la integración de los resultados de la Minería de Datos. El desarrollo está en una fase intermedia, llamada Sprint, donde se concentran las demás fases de CRISP-DM. Esta metodología también se basa en la recomendación de Scrum, donde los equipos deben estar formados por 3 a 9 miembros de desarrollo y puntualiza los tres roles:

- Propietario del producto (Product Owner): establece la visión del producto y define los incrementos potenciales del producto (también conocidos como historias de usuario o características).
- Maestro de Scrum (Scrum Master): facilita el proceso Scrum (eliminando impedimentos) como líder del proyecto.
- Equipo de desarrollo (Development Team): formado por profesionales que entregan incrementos de producto. En el contexto de equipos de análisis de datos, serían los científicos de datos, ingenieros de datos, analistas de datos, analistas de sistemas e ingenieros de software, entre otros.




Figura 14.11: Pasos de la metodología Scrum-DM.

Como se aprecia en la figura 14.11, Scrum-DM divide el proyecto de Minería de Datos en pequeños proyectos, cada uno de una duración constante y fija que va de una semana a un mes (como la metodología Scrum). Cada ciclo de esos pequeños proyectos, llamado *Sprint*, comienzan con una reunión (planificación de sprint) donde el propietario del producto (*Product Owner*) define y explica las principales prioridades. El equipo de desarrollo define qué incrementos pueden ofrecer al final del sprint (*Product Backlog*), es decir que tareas de Minería de Datos y otros requerimientos van a desarrollar, y luego elabora un plan de sprint para desarrollar estos incrementos (*Sprint Backlog*), en base a las tareas de la metodología CRISP-DM.

Durante el *sprint*, se coordinan y desarrollan planes en las reuniones diarias (por ejemplo tipo de técnica a utilizar, métodos de visualización, etc.). Al final del *sprint*, el equipo demuestra los incrementos a las partes interesadas y solicita comentarios durante su revisión. Para cerrar un sprint, el equipo se examina a sí mismo y planifica cómo puede mejorar en el siguiente.

14.8. Comparación de Metodologías.

Las metodologías CRISP-DM, TDSP, ASUM-DM, Scrum-DM, SEMMA y P³TQ están compuestas por diversas fases relacionadas entre sí, con la finalidad de guiar el desarrollo de proyectos de Ciencia de Datos. A continuación, se resumen algunos puntos importantes de estas metodologías abordadas:

- El flujo de trabajo en CRISP-DM, TDSP, ASUM-DM, Scrum-DM y P³TQ es iterativo, exceptuando SEMMA.
- ASUM-DM se origina como una extensión del estándar abierto CRISP-DM, TDSP no detalla su origen.
- ASUM-DM si bien es iterativa, establece un orden secuencial de sus fases, mientras que TDSP dispone estados en paralelo con múltiples posibilidades de inter-comunicaciones. Como se expuso anteriormente, ambas metodologías persiguen la modalidad ágil, a pesar de sus diferentes formas de aplicación.
- ASUM-DM es más estructurada y detallista, mientras que TDSP es más flexible y abierta.
- ASUM-DM identifica los roles según las responsabilidades distribuidas a los fines del proyecto, mientras que TDSP organiza los roles en función de la gestión del equipo de trabajo en Ciencia de Datos, a través de distintos proyectos.
- En ASUM-DM la figura del cliente tiene mayor presencia, ya que se le atribuyen un conjunto de roles que TDSP no reconoce dentro de la metodología.
- Scrum-DM integra conceptos de la metodología Scrum y CRISP-DM.
- CRISP-DM, SEMMA y P³TQ son metodologías en cascada o tradicionales.
- La metodología SEMMA no proporciona una guía de actividades específicas a realizar en cada una de sus etapas y además, inicia su primera fase con el muestreo de datos, mientras que CRISP-DM y P³TQ se centran en el análisis de los requerimientos y el entendimiento del negocio.
- CRISP-DM, SEMMA y P³TQ contemplan la selección y preparación de los datos, pero SEMMA propone trabajar con una muestra de los datos originales (en caso de tener un gran volumen de datos).
- SEMMA interpreta y evalúa los resultados en base al desempeño del modelo, mientras que P³TQ realiza una validación en función de los objetivos del proyecto. Para el caso de CRISP-DM los resultados se evalúan en función del desempeño del modelo y el cumplimiento de los requerimientos iniciales del proyecto.

- Otra cosa a tener en cuenta en CRISP-DM, SEMMA y P³TQ es las herramientas que pueden emplear, por ejemplo, SEMMA está relacionada con productos comerciales de la empresa SAS, como *Enterprise Miner* y *Text Miner*, el análisis de los datos tiene que ajustarse a estas técnicas y herramientas. Sin embargo, CRISP-DM y P³TQ fueron diseñadas como metodologías de libre distribución, por lo que pueden adaptarse a cualquier herramienta ya sea libre o comercial.
- TDSP es una buena opción para equipos de Ciencia de Datos que aspiran a entregar productos de Ciencia de Datos a nivel de producción. Puede que no sea apropiado para científicos de datos de un solo equipo o para proyectos sin un objetivo de producción, como los académicos o científicos.
- ASUM-DM no precisa los detalles en los procesos de minería y el análisis de datos. La guía para la implementación de ASUM-DM solo es accesible mediante un registro en el sitio web de IBM y mediante la instalación de archivos ejecutables que dan acceso a las guías en formato HTML, los cuales son compatibles solo con sistemas operativos Windows.

14.9. Conclusiones.

Este capítulo se ha dedicado a describir en profundidad la metodología genérica comúnmente usada para el proceso de descubrimiento de conocimiento en bases de datos y la minería de datos (**KDD: Knowledge Discovery in Databases**). También se han descrito más superficialmente la metodología **CRISP-DM**, quizá la más usada hoy en día en entornos empresariales (pero también muy vinculada en su esencia al KDD), metodologías directamente basadas en CRISP-DM como *Analytics Solutions Unified Method for Data Mining* (**ASUM-DM**), metodologías “ágiles” como *Team Data Science Process* (**TDSP**) o **Scrum-DM** y otras dos metodologías derivadas del KDD, **SEMMA** y **P³TQ**. No se presentan herramientas concretas debido a la imposibilidad de profundizar mínimamente en el gran número de las disponibles actualmente y no haber un criterio robusto para elegir una u otra para estudiar en detalle. Es por ello queda fuera del alcance de estos dos capítulos metodológicos, pero si se verán en los siguientes.

14.10. Bibliografía.

1. Fayyad, U., Piatetsky-Shapiro, G., Smyth, P. (1996). The KDD Process for Extracting Useful Knowledge from Volumes of Data. Communications of the ACM, November 1996/ Vol 39, N° 11, 27–34.
2. Berry, M., Linoff, G. (1996). Data Mining Techniques. Wiley Computer Publishing. New York.
3. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T.P., Shearer, C., Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. Computer Science.

4. SAS Institute Inc., “Introduction to SEMMA,” (2020). [Online]. Available: <https://documentation.sas.com/?docsetId=emrefdocsetTarget=n061bzurmej4j3n1jn8bbjjr> [Último acceso: 02/10/2021].
5. SAS Institute Inc., “Data Mining and SEMMA,” (2020). [Online]. Available: <https://documentation.sas.com/?docsetId=emcsdocsetTarget=n0pejm83csbja4n1xueveo2u> [Último acceso: 02/10/2021].
6. Pyle D. (2003). Business Modeling and Data Mining. The Morgan Kaufmann Series in Data Management Systems.