

Big Data Aplicado

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

Capítulo 13

Monitorizacion: Herramientas

Francisco P. Romero

En este capítulo se va a explicar qué es *Business Intelligence* o Inteligencia de Negocio, qué herramientas de BI existen y en qué consiste, cuáles son los principales estados y como deben ser abordados los procesos de análisis de datos o *Business Analytics*.

Se presenta una crítica sobre cómo se suele afrontar habitualmente el análisis de datos, que nos permita reflexionar sobre en qué grado se suelen hacer las cosas de una forma adecuada. A continuación, se describen los diferentes tipos de análisis, distinguiendo por ejemplo entre conceptos como “predicción” y “pronóstico”. Se presenta el papel del “científico de datos” y se hace una descripción de qué métodos resultan más adecuados para afrontar cada uno de los diferentes tipos de retos que suelen presentarse, así como una estimación de cómo establecer el nivel de madurez de una entidad en estos ámbitos.

13.1. Inteligencia de Negocios y Analítica de Datos.

El término *Business Intelligence* (BI por sus siglas en inglés) hace referencia al uso de estrategias y herramientas que sirven para transformar datos en información y esta, a ser posible, en conocimiento, con el objetivo de mejorar el proceso de toma de decisiones en una empresa. En estos tiempos de generación e intento de aprovechamiento de grandes volúmenes de datos, Big Data, tomar decisiones bien informadas es uno de los principales factores de diferenciación de las compañías y entidades de diversos tipos. El concepto de *Business Intelligence* pretende propiciar el aprovechamiento de datos e información interna y externa a la entidad de muy diversa procedencia: los datos que recopila una empresa sobre su producción, por ejemplo, se contemplan dentro de la inteligencia de negocio. También, por ejemplo, una noticia en la prensa sobre los resultados de un competidor, un informe sobre un nuevo mercado o sector en el que la entidad quiere introducirse, o datos que

una empresa puede obtener de sus dispositivos de IoT o de las redes sociales. La complejidad en recopilar los datos, procesarlos, analizarlos y presentarlos de forma que sean comprensibles y puedan ser procesados es lo que ha hecho florecer el mercado de herramientas de *Business Intelligence*. La “analítica de datos” [1] se suele enmarcar como una parte esencial de la Inteligencia de Negocio [2] La BI se suele dividir en dos grandes grupos:

- **BI Operacional:** trata los informes estándar, descripciones de los datos (información), funciones al nivel operacional con los trabajadores, clientes, usuarios, socios...
- **BI Analítica y Táctica/Estratégica:** pretende dar soporte a los ejecutivos y a los gestores en niveles tácticos que contribuyen a la estrategia global de la empresa o institución. Suele contemplar análisis estadístico, modelos predictivos y de extrapolación, pronósticos, optimización...

Como ejemplos de soluciones BI se pueden mostrar las siguientes en diferentes ámbitos de las instituciones y empresas:

- **Gestión de la Información** (*Information Management*): calidad de datos, Gobierno del dato, ETL (Extraer, Transformar y Cargar)...
- **Informes** (*Reporting*): cuadros de Mando, visualización, movilidad...
- **Analítica avanzada** (*Advanced Analytics*): segmentación, mejor próxima oferta, mantenimiento preventivo, modelos de riesgo...
- **Gestión de proyectos de empresa** (*Enterprise Project Management*): presupuestación y planificación, consolidación financiera, rentabilidad, balances, costes...

13.1.1. ¿Qué se entiende habitualmente por analítica de datos?

La **analítica descriptiva** está orientada a la generación de un resumen claro y fácil de entender de una colección de datos. Este es el fundamento y concepto más básico de todas las estadísticas. Se centra en la Visualización de datos para entender el pasado y el presente. Se describen los datos con tablas o gráficos, mostrando descripciones numéricas de la variabilidad y la posición. También se suele llamar modelización descriptiva.




Figura 13.1: Tipos de analítica

Para el análisis predictivo se suele usar:

- Extrapolación de funciones (tendencia para el futuro, pero no hay capacidad de pronóstico, hechos/cambios puntuales).
- Correlaciones entre variables (demasiado evidente, no suele funcionar de forma muy fina).
- Encontrar patrones en los datos que puedan ser aplicados a situaciones futuras (*KDD Knowledge Discovery in Databases* y Minería de Datos) [3, 4, 5].
- Métodos de CLUSTERING Y CLASIFICACIÓN.
- Extrapolación de funciones (por ejemplo, estimaciones o líneas de tendencia).




Figura 13.2: Extrapolación de funciones (Por ejemplo: Estimaciones o Líneas de Tendencia).

Dentro del análisis predictivo juega un papel fundamental el **Análisis de Series temporales**. Se suelen clasificar en:

- Estacionarias (medias y/o variabilidad se mantienen constantes).
- No Estacionarias (medias y/o variabilidad NO se mantienen constantes, cambios de varianza/tendencias).

También es importante señalar qué otros métodos se usan para otras diferentes necesidades en el análisis de series temporales:

- Tendencias: método de Mínimos cuadrados. Tendencias evolutivas. Diferenciación estacional.
- Predicción: alisadores exponenciales.
- Interpolación: Predecir datos faltantes.



Figura 13.3: Ventajas competitivas de los diferentes tipos de analítica. Fuente: Davenport Harris (2007).

El análisis predictivo se centra en un escenario futuro. El prescriptivo se centra en múltiples alternativas. Por lo tanto, un modelo prescriptivo puede ser considerado como una combinación de modelos predictivos (uno por cada posible escenario) que se ejecutan en paralelo. El objetivo es encontrar la mejor opción posible: OPTIMIZACIÓN. Por ejemplo, la elección del tratamiento más adecuado en oncología. Las principales técnicas usadas son:

- Técnicas de Investigación Operativa
- Algoritmos Genéticos
- Técnicas estocásticas
- Metaheurísticas
- Etc.

13.2. Tipos de salidas: predicción, pronóstico...

Conviene distinguir entre **predicción** (*prediction*) y **pronóstico**. Aunque es frecuente su uso de forma inversa según los campos de aplicación, en estadística la segunda tiene que ver con la estimación, con la extrapolación, continuidad, por ejemplo, podemos estimar (pronosticar) cuántos habitantes tendrá Madrid en 2025 en base a la tendencia demográfica. En cambio, en otros dominios el pronóstico consiste en anticiparse a un hecho puntual en base a un conjunto pequeño de alternativas, por ejemplo, en el reverso del impreso de una quiniela de fútbol pone "marque con una X su pronóstico" y las alternativas son 1-X-2, o un terremoto se debe pronosticar en base a las alternativas SI-NO. Los sistemas para abordar una u otra opción son claramente distintos. Los primeros se basan en la extrapolación y

los segundos en una serie de características para anticiparse al hecho puntual (por ejemplo, en las quinielas saber si alguno de los equipos se juega algo importante como el descenso, si hay un jugador importante lesionado o quién va a ser el árbitro del partido).

Esta distinción tiene una fuerte repercusión en el tipo de sistemas inteligentes a desarrollar: los de estimación, cuando los fenómenos y los datos que los describen siguen una tendencia, es suficiente con el uso de técnicas estadísticas o de aprendizaje automático de las anteriormente citadas. En cambio, cuando debemos anticiparnos a hechos puntuales que suponen una ruptura de la tendencia es necesario el uso de técnicas más cognitivas, por ejemplo, acudir a conocimiento de expertos o métodos que consideren relaciones causales en fenómenos anteriormente descritos, por ejemplo electorales y sean capaces de extrapolar estas relaciones a situaciones futuras en las condiciones específicas actuales.

13.3. Adecuación de los métodos a los problemas

La **analítica descriptiva** está orientada a la generación de un resumen claro y fácil de entender de una colección de datos. Este es el fundamento y concepto más básico de todas las estadísticas. Se centra en la **Visualización** de datos para entender el pasado y el presente. Se describen los datos con tablas o gráficos, mostrando descripciones numéricas de la variabilidad y la posición. También se suele llamar **Modelización descriptiva** y se suele plasmar en los “cuadros de mando” o dashboards, que estudiaremos en el tema siguiente.

Para el **análisis predictivo** se suele usar:

- **Extrapolación de funciones** (tendencia para el futuro, pero no hay capacidad de predicción real, hechos/cambios puntuales), por ejemplo Estimaciones o Líneas de Tendencia.
- **Correlaciones** entre variables (demasiado evidente, no suele funcionar de forma muy fina).
- Encontrar **patrones** en los datos que puedan ser aplicados a situaciones futuras (KDD y Minería de Datos).
- Métodos de **CLUSTERING Y CLASIFICACIÓN**.

Dentro del análisis predictivo juega un papel fundamental el Análisis de Series temporales. Se suelen clasificar en:

- Tendencias: método de Mínimos cuadrados. Tendencias evolutivas. Diferenciación estacional.
- Predicción: alisadores exponenciales:
 - Alisado exponencial simple
 - Alisado exponencial lineal de Holt
 - Alisado exponencial estacional de Holt-Winters

- Interpolación: Predecir datos faltantes.
- Estacionarias (medias y/o variabilidad se mantienen constantes).
- No Estacionarias (medias y/o variabilidad NO se mantienen constantes, cambios de varianza/tendencias).

También es importante señalar qué otros métodos se usan para otras diferentes necesidades en el análisis de series temporales:

■

El análisis predictivo se centra en un escenario futuro. El prescriptivo se centra en múltiples alternativas. Por lo tanto, un modelo prescriptivo puede ser considerado como una combinación de modelos predictivos (uno por cada posible escenario) que se ejecutan en paralelo. El objetivo es encontrar la mejor opción posible: OPTIMIZACIÓN. Las principales técnicas usadas son:

Técnicas de Investigación Operativa
Algoritmos Genéticos
Técnicas estocásticas
Metaheurísticas
Etc.

13.4. Análítica de Datos y "Minerías de Datos".

Como se ha destacado en los capítulos anteriores el análisis de datos no suele ser una tarea sencilla. Se suelen designar las tareas de “minería” atendiendo al origen de los datos y a la intención del proceso. Según esto, entre otros tipos de minería, los más habituales son:

Minería de Datos: Se parte de datos estructurados y casi siempre numéricos. El objetivo es encontrar regularidades (“patrones”) que permitan establecer modelos normalmente de predicción o de clasificación.

Minería de Textos: Se parte de colecciones de documentos de texto. El objetivo es encontrar regularidades (“patrones”) semánticos (aunque normalmente solo se manejan desde el punto de vista lexicográfico) que permitan ayudar en tareas como el acceso, la búsqueda y la recuperación de información o la elaboración automática de resúmenes de dichos textos.

Minería de Opiniones: También se suele denominar “Análisis de Sentimientos” (Sentiment Analysis). Se parte de colecciones de documentos de texto, habitualmente pequeños, como los típicos mensajes en redes sociales. El objetivo es manifestarse sobre la “polaridad” (bueno o malo) de un mensaje con respecto a un determinado tema, encontrando regularidades (“patrones”) semánticas (aunque normalmente solo se manejan desde el punto de vista lexicográfico) que permitan ayudar en tareas como la percepción de un producto o un político a través de las opiniones de los usuarios de las redes sociales. Esto permite, por ejemplo, disponer de alertas tempranas (early warnings) sobre las críticas de los consumidores a un determinado producto.

Minería de Grafos: Se parte de grafos o redes, normalmente compuestas de términos/conceptos y sus relaciones. El objetivo es encontrar regularidades (“patrones”) en dichos grafos que permitan ayudar a describir y entender los fenómenos susceptibles de ser representados por redes o grafos, como las redes sociales, las relaciones lingüísticas entre conceptos, las redes de computadoras, las redes sociales, las estructuras químicas... Esto permite, por ejemplo, el aprovechamiento inteligente de ontologías o tesauros como Wordnet o como se pretende habitualmente en la denominada “Web Semántica”.

Como se puede observar en la figura 13.4, en la evolución de la profundidad del análisis tanto de datos estructurados como de no estructurados, en el primer caso el nivel más profundo se alcanza con la analítica predictiva y en el segundo con el análisis de sentimientos. A lo largo de este documento se ilustran diversos ejemplos, críticas, aplicaciones y particularidades de todas estas variantes.



Figura 13.4: Relación entre la amplitud y la profundidad en el análisis de datos estructurados y no estructurados¹.

Como ya se ha visto anteriormente, debemos distinguir claramente entre **datos** (contenido bruto), **información** (resúmenes, datos “presentables”) y conocimiento (mayor nivel de abstracción que nos permite tomar decisiones ante nuevas situaciones). Habitualmente hoy en día la gestión de datos se queda en un análisis descriptivo, es decir, la visualización de gráficos o lo que se suelen llamar “cuadros de mandos” o “dashboards”, que hemos visto detalladamente en el capítulo anterior, que ayudan a la persona responsable a tomar decisiones.

Por ejemplo, esto puede venir muy bien en un entorno médico, porque permite a los profesionales tener una información más completa y procesada de los pacientes, historias clínicas, pruebas... para poder tomar decisiones. Pero no debemos quedarnos ahí, se debe ir hacia la analítica predictiva y prescriptiva, modelos que permitan extraer conocimiento a partir de los datos y la información que podamos usar para mejorar sustancialmente la práctica clínica.

13.5. Herramientas de Inteligencia de Negocios.

Pese a ser de una variedad muy amplia, por ejemplo podría discutirse si los servicios de monitorización en redes sociales se consideran una herramienta de BI las herramientas de inteligencia de negocio se podrían clasificar en tres categorías:

Data management tools (Herramientas para la gestión de datos). Permiten desde la depuración y estandarización de datos de procedencia diversa hasta su extracción, transformación y carga en un determinado sistema.

Data discovery applications (Aplicaciones orientadas a descubrir nuevos datos). Permiten analizar y explotar datos (KDD, data mining o minería de datos), y aplicar sobre esa información generada o sobre la ya disponible técnicas de análisis predictivo para anticiparse a situaciones futuras.

Herramientas de visualización o reporting. Una vez recopilados y tratados todos esos datos preexistentes o nuevos, ayudan a las empresas a visualizarlos de manera gráfica e intuitiva, convirtiendo datos en información. También sirven para integrarla en cuadros de mando (*Dashboards*) que midan si se cumplen o no determinados indicadores clave (*KPIs*), o pueden incluso generar todo tipo de informes (*reporting*).

Las principales grandes ventajas que ofrece el uso de herramientas de inteligencia de negocios son:

1. La capacidad de analizar y explotar de forma combinada datos internos y externos, procedentes de distintas fuentes y sistemas.
2. Una mayor profundidad de análisis y una capacidad ampliada de generación de informes.
3. La posibilidad de remontar ese análisis hacia atrás en el tiempo mediante la representación y uso de series temporales históricas.
4. La capacidad de hacer proyecciones, predicciones y pronósticos de futuro en base a todos esos datos e información generada.

13.6. Críticas sobre la percepción habitual del análisis de datos: se debe ir hacia un análisis ‘inteligente’ de datos

Desde mi punto de vista, la visión habitual de las posibilidades y expectativas de la BI es demasiado restringida, y mucho más las prácticas habituales en las empresas e instituciones. Cuando se habla de “transformar datos en información”, “apoyen la toma de decisiones” son expresiones muy imprecisas y ¡hay muchas otras cosas que se pueden hacer!

Si nos fijamos en las posibles salidas propuestas, vemos que de nuevo es demasiado restringido. Normalmente la “información” es solo “visualización”, es decir, una forma de representar datos originales que están en bruto de una forma más ordenada y resumida, por ejemplo en un gráfico. Pero esto es muy poco “inteligente” y al final es el que lo hace el responsable de tomar las decisiones, basándose en esta información de la que dispone, y la calidad de estas decisiones dependerá exclusivamente de la capacidad y preparación del decisor.

Por ello, creo que se debe tender a generar y manejar “conocimiento” en el sentido anteriormente descrito. Se pueden diseñar sistemas sofisticados de muy diversos tipos, como los Sistemas de Ayuda a la Decisión (DSS), los Sistemas Recomendadores (*Recommender Systems*) o el Análisis de series temporales (Predicción vs Pronóstico), por ejemplo, para tareas automáticas de Segmentación, recomendación de otros productos, pronóstico de terremotos, incendios u otros fenómenos naturales, puntos de inflexión en la bolsa o el cambio de moneda... y solo las grandes empresas punteras se esfuerzan en diseñar sistemas de este tipo.

Todo ello pasa por encontrar regularidades en los datos o su evolución (¡patrones!), y ser capaz de formalizarlos o expresarlos de alguna forma computable para que puedan ser usados por estos sistemas. Las salidas esperadas deben condicionar todo el proceso de análisis de datos. Por ejemplo, no se diseña de la misma forma un sistema de predicción que uno de pronóstico. Pero la práctica habitual es ir “a ciegas” hacia delante, es decir, partir de los datos más o menos en bruto y aplicarles algún algoritmo o herramienta de análisis (por ejemplo: estadística o de aprendizaje automático) y tratar de interpretar la salida de este procedimiento por si puede ser útil. Creo que este es un enfoque erróneo del análisis y minería de datos y suele ser el más habitual.

13.7. Inteligencia de Negocios e Inteligencia Artificial.

Hoy en día es frecuente ver en todos los medios de comunicación y en otros ámbitos hablar a todas horas de inteligencia artificial, en la mayoría de los casos vinculándola únicamente al procesamiento y análisis de datos. Si se analizan con rigor lo que pretende y los orígenes de esta disciplina, esta concepción es una simplificación peligrosa que puede llevar a equívocos en la sociedad general. En primer lugar, en IA nada es tan nuevo como a veces se transmite o pueda parecer. Los modelos y técnicas más de moda en este momento surgen hace ya varias décadas y apenas han sufrido variaciones desde su concepción. Por ejemplo, los modelos basados en redes neuronales artificiales, en particular los denominados de “Deep learning”, tienen su origen en propuestas presentadas en los años siguientes a la segunda guerra mundial, y los algoritmos de aprendizaje que utilizan fueron desarrollados en las décadas de los 80 y 90 del siglo pasado. Los “Random Forest” son desarrollos de la misma época del profesor de estadística de la UC Berkeley, Leo Breiman (fallecido en 2005) y presentados en el año 2001. Realmente no hay nuevos paradigmas en la IA en los últimos 30 años. Lo que sí supone un cambio

sustancial es el aumento de la potencia computacional y la capacidad de manipular a grandes volúmenes de datos, el fenómeno en que nos centramos y que se suele denominar Big Data. Esto nos lleva a que estas técnicas, que en el momento de su presentación no eran tan eficientes ahora sí lo sean, lo que permite que puedan ser aplicadas a grandes volúmenes de datos o a sistemas muy complejos en tiempos de computación mucho más razonables.

Pero no sólo se hace IA a partir de datos. El “aprendizaje automático” (*Machine Learning*) es sólo una parte de la IA. Además, este “aprendizaje” poco tiene que ver con cómo aprendemos los humanos, simplemente suele consistir en escalar operaciones estadísticas básicas sencillas a un conjunto grande de datos (estructurados, numéricos y normalizados...) lo que permite generalizar regularidades numéricas entre los mismos, encontrar patrones de comportamiento. Esto nos lleva al gran el cuello de botella de los algoritmos de aprendizaje automático: no es fácil (ni posible) representar una situación real solamente con datos numéricos estructurados y normalizados, que es la única entrada que permiten estos métodos computacionales. Por lo tanto, no es equivalente IA a aprendizaje automático, y mucho menos a *deep learning*.

$$IA \neq ML \neq DL$$

Se deben tener en cuenta otros modelos de simulación de la inteligencia humana, provenientes de áreas como la lógica, la lingüística, la sociología, la antropología social, la filosofía o la psicología cognitiva, como por ejemplo modelos de:

- Razonamiento, inferencia.
- Incertidumbre, imprecisión.
- Causalidad, heurística, categorización conceptual, almacenamiento de experiencias.
- Abstracción, lenguaje natural.
- Sentimientos, emociones.

Por ello hay otras áreas de la IA (que se desarrollan en otros módulos y temas) en las que se debe profundizar y a las que se debe prestar más atención, y no solo a las que proceden de la matemática y la estadística:

- Ingeniería del conocimiento.
- Procesamiento de Lenguaje Natural, PLN.
- Reconocimiento de patrones.
- Razonamiento aproximado, inferencia.
- Modelos causales, heurísticas, representación del conocimiento, almacenamiento de experiencias.

...que no dejan de estar profundamente vinculadas con el ‘Big Data’ (aprovechamiento inteligente de datos masivos). Se deben desarrollar sistemas de IA que tengan en cuenta los datos existentes sobre el fenómeno a tratar (en el caso de existir, siempre incompletos y muchas veces inexactos, sesgados, con ruido...) pero también el conocimiento humano sobre ese dominio, las hipótesis, interpretaciones y heurísticas de los expertos en ese campo y otros muchos elementos ‘cognitivos’ más, crear sistemas ‘sofisticados’ que simulen el razonamiento humano, y no sólo aplicar técnicas estadísticas básicas que nos permitan distinguir automáticamente fotografías de “perritos” de las de “gatitos” con un alto porcentaje de aciertos, pero con un coste computacional muy alto, tarea que un niño de pocos años hace con una tasa nula de error y sin ser considerado especialmente “inteligente”.

Para profundizar en estos temas, pueden ser recomendables el libro de 2019 de Melanie Mitchell: *“Artificial Intelligence: A Guide for Thinking Humans”* [6], que habla por ejemplo de cómo la IA tuvo y sigue teniendo el problema del “burro y el palo con la zanahoria”, en los cincuenta la gente decía que en cuestión de 10, 15, 25 años íbamos a tener una inteligencia artificial completa y capaz de remplazar al ser humano en todos los empleos, y así sucesivamente, que la IA no es tan lista y que infravaloramos la complejidad de la mente humana, o el artículo de agosto de 2020 de investigadores de universidades de Finlandia y Austria titulado *“Artificial Intelligence: A Clarification of Misconceptions, Myths and Desired Status”* [7], en el que los autores presentan diversos mitos y errores en la concepción actual de la IA en esta línea, acerca de la imposibilidad real de crear máquinas que se comporten como humanos ‘óptimos’.

La **Inteligencia Artificial** (IA/AI -siglas en inglés-) se puede ver como la disciplina del ámbito de la computación y los sistemas de información que pretende simular computacionalmente comportamientos humanos que pueden ser considerados como inteligentes. Hay diversas ramas dentro de la IA, como la Visión Artificial o la Robótica, Aquí nos centramos en el análisis inteligente de datos en entornos Big Data, en el marco de la Inteligencia de Negocios (Business Intelligence).

Cuando se tienen en cuenta datos, por ejemplo historias clínicas de los pacientes, casos anteriormente tratados, registros de incidencias de enfermedades, datos de factores que pueden provocar determinadas dolencias (por ejemplo medioambientales, hábitos sociales...), entonces es necesario recurrir a lo que en IA se llaman técnicas de aprendizaje automático o **Machine Learning** y, por supuesto, técnicas provenientes de la matemática y la estadística, como por ejemplo las de Regresión (formalización de una relación significativa entre dos o más variables para calcular pronósticos a partir del conocimiento de los valores en un individuo concreto).

Muchas de estas técnicas se pueden englobar tanto en estadísticas como de Machine Learning: rama de la Inteligencia Artificial en la que se diseñan mecanismos para dotar a los sistemas computacionales de capacidad de aprendizaje, en el sentido de la capacidad de descubrir **regularidades (patrones)** en datos o situaciones anteriores y aplicarlos a nuevos problemas o situaciones análogas.

13.8. El científico de datos, la profesión más demandada.

Hoy en día el “científico de datos” (data scientist) es una figura muy demandada y escasa en ambientes profesionales, científicos o académicos que, como se esboza en este documento, debe poseer conocimientos de computación, bases de datos, Inteligencia Artificial, Aprendizaje Automático, estadística, visualización, reconocimiento de patrones, sociología, psicología, KDD y Minería de Datos... y que debe ser capaz de seleccionar y guiar las herramientas y técnicas más adecuadas para cada problema y objetivos concretos. Es por ello por lo que no es frecuente ni fácil encontrar profesionales con este perfil tan completo. La mejor forma de paliar esta dificultad debería ser la formación de equipos multidisciplinarios que cubran todas estas necesidades, pero esto tampoco es frecuente y por ello gran parte de los proyectos de análisis de datos que llevan a cabo diferentes instituciones y entidades no consiguen los resultados que podrían ser esperados.




Figura 13.5: El científico de datos

Otro problema frecuente e importante a la hora de desarrollar este tipo de proyectos es la tendencia a aplicar las herramientas, métodos o algoritmos que el equipo mejor conoce (“al que solo dispone de un martillo, todos los problemas le parecen clavos”) de una forma “ciega” sobre las bases de datos de las que se dispone (normalmente sólo sobre una), sin importar en principio cuál es el propósito final de ese análisis de datos. Esta aproximación errónea se podría mejorar en gran medida disponiendo de un buen “científico de datos”, en el sentido anteriormente descrito, capaz de guiar todo el proceso con criterios bien sustentados.

13.9. Modelo de Madurez de Business Intelligence (BI Maturity Model)

Como se ha visto, muchas entidades o empresas pueden tener una idea limitada de lo que es la Inteligencia de Negocios, al creer que es solo una solución de software diseñada para la publicación de su información en reportes y dashboards de gestión. Pero debe ser más que informes y visualización y puede generar diversos beneficios como:

- Desarrollar una cultura definiendo el nivel de responsabilidad y rendimiento de cada rol en la organización.
- Proporcionar la capacidad de evaluar el desempeño de las diferentes áreas, al crear una comparativa de los objetivos, permitiendo acciones correctivas y preventivas para minimizar los puntos negativos.
- A través de los resultados analíticos puede ayudar a las empresas a redefinir sus estrategias para que los objetivos alcanzados se acerquen lo mayor posible a los planteados.
- Permite mantener la calidad y coherencia en los productos y/o servicios de la empresa, minimizando la tasa de fallos o defectos.
- Ayuda a impulsar la rentabilidad de la empresa.
- Puede evaluar imparcialmente las fortalezas y debilidades de la empresa.
- Puede facilitar que la empresa pueda establecerse a la par o por delante de la competencia.

Conocer y aumentar el nivel de madurez de BI en una empresa propiciará que la toma de decisiones sea más inteligente, con un menor grado de incertidumbre, beneficiando todos los departamentos y en consecuencia haciéndola más productiva y rentable. El modelo de madurez de BI presentado por la consultora Gartner se trata en una escala de 5 niveles, que indican el grado de madurez de la estrategia de análisis de una determinada empresa²:

Nivel 1. Inconsciente (Unaware) Es el nivel básico de BI. Aquí las empresas se basan en la intuición creando análisis ad hoc. No cuentan con un proceso formal de toma de decisiones, su infraestructura de la información es mínima y no existe un proceso de análisis definido ni métricas para evaluarlo. Por lo regular este nivel es el que más prevalece en las pequeñas empresas al ser muy costoso iniciar la optimización. **Nivel 2. Oportunista (Opportunistic)** En este segundo nivel, ya existen proyectos o análisis de BI independientes para las unidades de negocio. Ayudan a la toma de decisiones tácticas. Los proyectos o análisis cuentan con:

- Infraestructura de datos propia
- Herramientas de BI

²<https://www.gartner.com/en/documents/3136418>

- Aplicación comercial
- Métricas de desempeño

Son guiados por un área de TI, personal de aplicaciones comerciales y gerentes operativos. Se cuenta con poco o nulo proceso estructurado de desarrollo de proyectos y se utilizan como recursos las herramientas de integración de datos, algunas capacidades analíticas, bases de datos y las capacidades de la plataforma de BI seleccionada.

Nivel 3. Estándar (Standards)

En este nivel ya se cuenta con una mayor coordinación del personal, procesos y tecnologías involucradas. Aquí los gerentes de procesos y líderes de TI se encargan de supervisar los proyectos. Los departamentos toman decisiones basadas en los datos. Para este nivel de BI muchas empresas u organizaciones optan por implementar un centro de competencia de BI (BICC) el cual cuenta con:

- Usuarios comerciales
- Profesionales de TI
- Analistas de datos

Los estándares tecnológicos se empiezan a visualizar dentro de la infraestructura de la información, Data Warehousing y en las plataformas de BI. Si bien estos estándares no son obligatorios, sí son recomendados para el escalado y mantenimiento. No obstante, los proyectos aún no son capaces de compartir información o modelos analíticos de forma consistente.

Nivel 4. Empresarial (Enterprise)

Dentro de este nivel, ya existen métricas definidas que apoyan el buen desarrollo de los procesos para lograr los objetivos de la empresa. Las decisiones tomadas se vuelven multifuncionales para las distintas áreas o toda la empresa. Los ejecutivos corporativos y operativos ya tienen visión de las relaciones de causa-efecto de las actividades clave. Y todos, desde analistas, hasta gerentes comerciales y altos ejecutivos, utilizan de forma conjunta los sistemas de análisis y BI. Otras características clave de este nivel son:

- Se cuenta con una arquitectura de información que guía el diseño de nuevos sistemas.
- Sistema de BI madura y recibe una financiación significativa.
- La empresa demuestra tener un alto grado en los proyectos analíticos y de BI.
- Se logran proyectos con procesos y habilidades sofisticadas para la definición de requisitos. El modelado y la gestión de programas incluyen un desarrollo ágil y creación rápida de prototipos.
- Los modelos de datos, reglas y análisis comunes minimizan el número de versiones de un conjunto de información determinado.

Nivel 5. Transformador (Transformative)

En este último nivel, BI y la analítica se han transformado en una iniciativa estratégica, administrada por la organización empresarial y TI; respaldada y gobernada por los niveles más altos de la organización. Dentro de la empresa ya se piensa en el aprovechamiento de los datos como un activo estratégico, utilizando las herramientas de BI y analítica para generar oportunidades de ingresos, lograr que las áreas operen de forma eficiente y brindar el mejor servicio a los clientes. En este nivel la empresa posee un marco de métricas completo donde se añaden indicadores para medir el rendimiento, comportamiento y beneficio de los socios y clientes. A diferencia de los primeros niveles que se centran en los procesos y mediciones internas, el enfoque para este último nivel se encuentra en el valor comercial. Todas las partes interesadas utilizan la información generada por los sistemas de análisis y BI para coordinar respuestas a las condiciones comerciales cambiantes en toda la cadena de valor y para tomar decisiones de transformación.

13.10. ¿Cómo subir el nivel de maduración de las empresas?

El modelo de madurez de BI ayuda a las empresas en un inicio a encontrar un equilibrio, sin embargo, las empresas según van madurando tendrán que aprender a equilibrarse por sí mismas. Para poder ascender el nivel de maduración de BI se podrían tener en cuenta las siguientes recomendaciones:

1. Estrategia a Corto Plazo Se recomienda establecer una estrategia a corto plazo con los hitos de ese periodo previamente definidos, así como la estimación de día y hora de fin de cada uno de ellos. Esta estrategia deberá centrar en las ganancias rápidas para la empresa y que demuestren el valor que la herramienta de BI le brinda por medio de sus datos. Las ganancias rápidas se incluyen en lo que Gartner llama un enfoque de modo 2 para los datos y el análisis: un enfoque rápido y ágil de BI es la forma en que las pequeñas empresas ya funcionan y la forma en que deben estructurar su estrategia de BI.

2. Equipo de BI Virtual En lugar de crear un departamento de BI el cual implica tiempo y dinero, se aconseja para un inicio crear un equipo de BI virtual, formado por las partes interesadas de todos los departamentos existentes y área de TI de la empresa. Tiene la función de establecer una estrategia de BI y ponerla en marcha. El propósito es asegurarse que el programa de datos y análisis satisfaga las necesidades de los departamentos de la empresa, de modo que los empleados estén dispuestos y puedan actuar de una manera basada en datos.

3. Marco de Gobernanza de Datos Escalable La configuración de un marco de gobierno de datos se inicia desde la determinación de los datos que contiene. Se requiere conocer qué datos se recopilan y donde están. A partir de ahí, la configuración de la estrategia de gobierno significa que se cuenta con un plan para asegurar

que los datos están limpios, son precisos, utilizables y seguros. Si no se tiene marco de gobierno establecido desde el principio, es difícil hacerlo en retrospectiva. Esto también puede significar configurar el software de BI para que los usuarios tengan acceso a lo que necesitan, pero no a todos los datos

Conclusiones

En este tema se ha tratado de plasmar una visión crítica sobre lo que se suele entender hoy en día por Inteligencia de Negocios. La necesidad de un análisis inteligente de datos en todas las empresas y entidades propicia que sean demandados diversos profesionales de múltiples ámbitos como se ha reflejado en el documento. En particular son especialmente requeridos titulados en matemáticas y estadística, por su formación y capacidad para entender los rudimentos formales de la mayoría de los algoritmos de aprendizaje automático y diseñar y modificar algoritmos de este tipo. Pero, desde mi punto de vista, los directores de proyectos de este tipo deben tener una formación más amplia, incluso más allá de la ciencia de datos. Deberían disponer de un “maletín de herramientas” que les permita seleccionar aquellas más adecuadas para cada problema específico, y no sólo en lo que concierne al análisis de datos. Por ejemplo, para un sistema de anticipación a un resultado electoral, no sólo se deben tener en cuenta los datos, sino que hay que considerar teorías e hipótesis que la sociología o la antropología social, como por ejemplo el efecto o teorema de Thomas. De la misma forma para la implementación de un sistema de análisis de sentimientos u opiniones, sería conveniente contar con expertos en lingüística computacional y en psicología clínica.

Esto significa que cada vez más se van a requerir profesionales de diversos ámbitos con formación orientada hacia los desarrollos en inteligencia artificial. Por otra parte, desde el punto de vista puramente de ingeniería, son necesarios profesionales capaces de mantener y diseñar sistemas robotizados o automáticos, que en muchos casos van a sustituir a otro tipo de mano de obra humana, lo que está provocando cambios sustanciales en los modelos sociales de trabajo.

13.11. Bibliografía

1. Siegel, E. (2013). *Analítica predictiva. Predecir el futuro utilizando Big Data*. Anaya Multimedia-Anaya Interactiva.
2. Mayer-Schönberger, V., Cukier, K. (2013). *Big data. La revolución de los datos masivos*. Turner.
3. Piatetsky-Shapiro, G., Frawley, W. (1991). *Knowledge Discovery in Databases*. AAAI/MIT Press, Cambridge MA.
4. Agrawal, D., Das, S., Abbadi, A. E. (2010). *Big Data and Cloud Computing: New Wine or Just New Bottles?*. Proc. of the VLDB 2010, Vol. 3, No. 2.
5. Agrawal, D., Das, S., Abbadi, A. E. (2011). *Big Data and Cloud Computing: Current State and Future Opportunities*. Proc. of the ETDB 2011, Uppsala, Sweden.

6. Mitchell, M. (2019). Artificial Intelligence: A Guide for Thinking. Penguin Books, London, UK.
7. Emmert-Streib, F., Yli-Harja, O., Dehmer, M. (2020). Artificial Intelligence: A Clarification of Misconceptions, Myths and Desired Status, *Frontiers in Artificial Intelligence* 3: 91.