

Big Data Aplicado

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

Capítulo 16

Técnicas de Inteligencia de Negocios y de Inteligencia Artificial.

José Angel Olivas Varela

Este capítulo se inicia con la continuación de la presentación de una enumeración y breve descripción de los “algoritmos de minería de datos”, que pretende ser un mapa completo de los objetivos, orientación y técnicas (tanto estadísticas como provenientes de la Inteligencia Artificial) para afrontar el análisis de datos en su estado actual desde el punto de vista de las Ciencias de la Computación en entornos Big Data.

Se verá que probar las aplicaciones de BI es diferente a probar las aplicaciones empresariales tradicionales. Para lograr resultados verdaderamente creíbles, cada etapa del ciclo de vida de los datos debe ser probada efectivamente: Recolección de Datos, Integración, Almacenamiento y Presentación, por lo que es importante disponer de técnicas de evaluación y validación de los modelos de BI que se propongan.

Por último, se describirán brevemente varios procedimientos de validación de modelos estadísticos y de aprendizaje automático, así como medidas de la bondad de ajuste y potencia predictiva.

16.1. Métodos basados en Inteligencia Artificial (Machine Learning) para la minería de datos.

La Inteligencia Artificial (IA/AI -siglas en inglés-) se puede ver como la disciplina del ámbito de la computación y los sistemas de información que pretende simular computacionalmente comportamientos humanos que pueden ser considerados como inteligentes.

Hay diversas ramas dentro de la IA, como la Visión Artificial o la Robótica, pero en este tema nos centramos en el aprendizaje automático (AA/ML Machine Learning). Cuando se tienen en cuenta datos, por ejemplo historias clínicas de los pacientes, casos anteriormente tratados, registros de incidencias de enfermedades, datos de factores que pueden provocar determinadas dolencias (por ejemplo medioambientales, hábitos sociales...), entonces es necesario recurrir a lo que en IA se llaman técnicas de aprendizaje automático o Machine Learning y, por supuesto, técnicas provenientes de la matemática y la estadística, como por ejemplo las de Regresión (formalización de una relación significativa entre dos o más variables para calcular pronósticos a partir del conocimiento de los valores en un individuo concreto).

Como se ha dicho, muchas de estas técnicas se pueden englobar tanto en estadísticas como de Machine Learning: rama de la Inteligencia Artificial en la que se diseñan mecanismos para dotar a los sistemas computacionales de capacidad de aprendizaje, en el sentido de la capacidad de descubrir regularidades (patrones) en datos o situaciones anteriores y aplicarlos a nuevos problemas o situaciones análogas. Se pueden considerar diversos paradigmas y grupos de técnicas en AA:

- **Paradigma Analógico (Aprendizaje por analogía).**

Se pretende encontrar una solución a un problema que se presenta ahora usando el mismo procedimiento utilizado en la resolución de uno similar que se presentó en otra ocasión anterior. Si dos problemas son similares en algún aspecto de su formulación entonces pueden serlo también en sus soluciones. Nuevos problemas pueden ser abordados reduciéndolos a problemas análogos resueltos. Ejemplos: analogía por transformación, analogía por derivación, razonamiento basado en casos, etc.

- **Paradigma Inductivo.**

Árboles de decisión, algoritmos de inducción pura, etc.

- **Paradigma Conexionista.**

Redes Neuronales Artificiales, etc.

- **Paradigma Evolutivo.**

Algoritmos Genéticos, otros métodos de optimización, colonias de insectos, descenso estocástico del gradiente, etc.

- **Modelos gráficos probabilistas.**

Bayesianos, cadenas de Markov, Filtros de Kalman, redes de creencia, Máquinas de Soporte Vectorial (SVM), Metaheurísticas, etc.

Técnicas de **Clustering** (aprendizaje no supervisado) consisten en agrupar los elementos de una colección en subconjuntos (clases, categorías, clusters), nítidos o borrosos, en base a su similitud. Es no supervisado porque las clases o categorías no se conocen a priori, las determinarán las propias similitudes entre los elementos. Por lo tanto, se centran en una “medida de similitud” entre elementos, de la que puede haber infinitud de variantes: estadísticas, distancias euclídeas, distancias vectoriales (coseno), distancias borrosas, etc. Ejemplos:

- **Paradigma Conexionista**

Redes Neuronales Artificiales: SOM (Self Organized Maps, Mapas de Kohonen). Toolbox de Matlab SOM, etc.

- **Modelos estadísticos y probabilistas**

K-means, c-means, K-nearest neighbours (KNN), Mean shift (ventanas circulares con un centroide), Dirichlet process (estocásticos basados en distribuciones de probabilidad), LDA (Latent Dirichlet Allocation), Modelos Gausianos, etc.

- **Extensiones basadas en Lógica Borrosa** (fuzzy logic)

Fuzzy K-means, Fuzzy c-means, Isodata, etc.

Técnicas de **Clasificación** (aprendizaje supervisado), consisten en asignar una clase a un nuevo elemento en base a un conjunto de categorías previamente establecidas (supervisado), por ejemplo, evaluar los síntomas de un nuevo paciente y decir que tiene gripe (clase previamente establecida). Se basan en un entrenamiento en base a ejemplos con la solución conocida (supervisado) para crear modelos que permitan clasificar nuevos casos análogos:

- **Paradigma Inductivo.**

Árboles de decisión: ID3, CART, C4.5, See5, Random Forest (de moda en Big Data, introducidos por Leo Breiman en 2001), etc.

- **Paradigma Conexionista.**

Redes Neuronales Artificiales: Perceptrón Multicapa (con backpropagation), Convolutivas, Neocognitrones, Redes de Hopfield, Redes recurrentes, Adaline, Deep Learning (de moda en Big Data), etc.

- **Modelos estadísticos y probabilistas.**

Redes Bayesianas, Naive-Bayes, Máquinas de Soporte Vectorial (SVM), Metaheurísticas, etc.

16.2. Evaluación de sistemas de IA.

La evaluación de un sistema de Inteligencia Artificial no es una tarea sencilla debido, entre otras, a las siguientes razones:

- Las expectativas con respecto a sus prestaciones son frecuentemente vagas y confusas.
- Muchas veces los casos típicos que debe resolver el sistema son los mismos que se han usado para su entrenamiento.
- No es posible en un caso real disponer de un juego de pruebas que pueda asegurar que el comportamiento del sistema es el ideal.

Además, comparándolo con la evaluación de un software convencional, la evaluación de un sistema de IA posee las siguientes características diferenciales:

- Los sistemas de IA no son por naturaleza objetivos.
- Los sistemas de IA gestionan habitualmente cierta cantidad de incertidumbre.
- En el software convencional puede usarse el juego de ensayo.
- En el software convencional normalmente no se cuestiona la corrección de los resultados.

Se muestra a continuación en qué consiste el proceso de evaluación en general [1]:

Quién hace la acción	Acciones		Qué usa la acción	Quién genera la entrada
Evaluador	Planteamiento de la evaluación		Información proceso de construcción	Constructor
	Objetivo			
	Criterios			
	Técnica de valoración			
	Carga de prueba			
	Patrón de referencia			
Evaluador	Realización de la evaluación			
	Examen o estudio del sistema		Sistema	Constructor
			Criterios	Evaluador
	Juicio de valor del aspecto a		Técnicas de valoración	Evaluador
Resultado de la evaluación: R				
Evaluador	Comparación del resultado con el patrón de referencia.		Patrón de referencia: P	Constructor
				Evaluador
	Toma de Decisión		Objetivo de la evaluación	Constructor
	R ≠ P	Volver a atrás: Modificar el sistema.		
	R = P	Seguir adelante con la construcción del sistema		

Figura 16.1: Proceso de evaluación de sistemas de IA.

16.2.1. Verificación del sistema

La verificación del sistema consiste en comprobar la corrección de los modelos conceptuales, formales y computables del sistema. La debe realizar un Ingeniero distinto al que desarrolló el sistema. Debe tratar de comprobar:

Redundancias:

- Identidad entre elementos.
- Elementos sin conocimiento.
- Circularidades.
- Partes innecesarias.

Compleitud:

- Elementos ausentes.
- Elementos inalcanzables.

Consistencia: (Depende de cada formalismo de representación utilizado, de los tipos de lógicas y de los mecanismos de gestión de incertidumbre).

- Elementos contradictorios.
- Incompatibilidades con las restricciones.

16.2.2. Validación del Sistema

La validación consiste en comprobar que el sistema responde adecuadamente a los fines para que fuera diseñado. La deben hacer expertos en el tema tratado, o utilizarse conjuntos de casos de prueba (existen indicaciones sobre el número de casos de prueba que deben usarse), pero en general, se deben llevar a cabo los siguientes procesos [1], tabla 16.2:

		Carga de Prueba	Patrón de referencia
Comparación frente a resultados conocidos		Casos históricos con solución conocida	Comparar resultado del sistema con el conocido
Comparación frente a modelos matemáticos	Modelo Teórico	Casos aleatorios	Comparar resultado del sistema con la solución del modelo para el caso
	Modelo lineal		
Comparación frente a expertos en el tema	Juego aleatorio	Casos aleatorios	Comparar resultado del sistema con el de los expertos en el tema
	Juego de ensayo	Casos seleccionados	
	Ensayo en paralelo	Casos reales	
Análisis de sensibilidad	Sensibilidad a variaciones en las entradas	Casos aleatorios donde se provocan variaciones en la entrada	Las salidas de los casos variados deben ser semejantes
	Sensibilidad a errores en las entradas	Casos con entradas inválidas	No debe producirse salida y debe dar mensaje de error

Figura 16.2: Proceso de validación de sistemas de IA.

También deben ser evaluadas la usabilidad y la utilidad del sistema, cuando el sistema está funcionando en condiciones reales.

16.3. Validación o 'testing' en BI

El testing es una actividad fundamental para cualquier proyecto de software de TI. Por ello, se le debe de dar la misma importancia en un proyecto de Business Intelligence (BI), pero las pruebas de las aplicaciones de Data Warehouse/Business Intelligence (DW/BI) son un poco diferentes a las pruebas de las aplicaciones transaccionales tradicionales, ya que requieren un enfoque totalmente centrado en los datos.

Si pensamos en todas las etapas que tiene una solución de BI, desde la extracción de datos hasta la presentación final al usuario, podemos ver que hay varias etapas en las que podríamos aplicar técnicas de testing tanto para validación como para control.

Como se ha visto, en entornos de bases de datos numéricas y relacionales como las que se suelen usar habitualmente, la finalidad de un proceso ETL es la de integrar. Para ello, se **extraen** datos de diferentes fuentes, **transformándolos** mediante unas reglas de negocio, y **cargándolos** en una base de datos unificada conocida

como *Data Warehouse* (pensemos en el concepto actual de *Data Lake...*). Para conseguir un *Data Warehouse* robusto, este proceso ETL debe estar verificado y validado, con un alcance bien planificado, bien definido y eficaz. Esto es lo que nos garantizará que ese proceso ETL pase a producción de una forma adecuada.

Por lo general, los controles que se hacen son en dichas etapas de extracción, transformación y carga, ETL (*Extract, Transform Load*). Se valida que los procesos no se “caigan”, y se envían avisos si esto sucede. No hay demasiados procesos encaminados al chequeo de la calidad de los datos, y pocas veces se hacen pruebas rutinarias de la estructura, verificando que no haya errores que puedan llevar a que la información que finalmente se muestra sea incorrecta.

Los desafíos típicos a los que se enfrentan las empresas al probar las implementaciones de DW/BI incluyen

- Volumen de datos, variedad y complejidad.
- Anomalías en los datos procedentes de fuentes de datos dispares.
- Pérdida de datos durante el proceso de integración de datos.
- Consumo de tiempo.
- Ausencia de pistas de auditoría, reutilización o metodología, lo que se traduce en un alto coste de calidad.
- Se requieren habilidades especializadas para ejecutar el proceso de validación y verificación de datos.

Para garantizar la integridad, la precisión, la coherencia, la seguridad y la fiabilidad de los datos a lo largo de todo el ciclo de vida, es importante comprobar todos estos aspectos en cada punto de entrada de datos en una arquitectura de BI y no sólo al final a través de los informes o cuadros de mando.



Figura 16.3: Evaluación de proyectos de BI¹.

En general, en la práctica los tests carecen de una estructura y se basan esencialmente en el instinto sobre lo que debería pasar, contrastando los datos que se devuelven a nivel usuario con los que se están en las bases de datos. Lo más normal es hacer comparaciones entre datos procedentes de hojas de cálculo mediante sentencias SQL. Esto tiene más inconvenientes que ventajas:

- Es difícil cubrir todas las pruebas necesarias.
- Es un proceso lento.
- Al ser un proceso manual y no automático, el índice de errores es elevado.

El objetivo de las pruebas de las aplicaciones de BI es conseguir finalmente datos veraces y creíbles. Y la credibilidad de los datos puede lograrse haciendo que el ciclo de pruebas sea eficaz. Una estrategia de pruebas exhaustiva es la esencia de un ciclo de pruebas eficaz. Debe abarcar la planificación de las pruebas para cada etapa, cada vez que los datos se muevan y establecer las responsabilidades de cada parte interesada, por ejemplo, los analistas de negocio, el equipo de infraestructuras, el equipo de control de calidad, los administradores de las bases de datos, los desarrolladores, los usuarios de negocio y, cada vez más, el equipo de ciencia de datos (aunque todavía lo que se hace es muy básico e incipiente). Para garantizar la preparación de las pruebas en todos los aspectos, la estrategia debe centrarse en:

- **El alcance de las pruebas:** Describir las técnicas y tipos de pruebas que se pondrán.
- **La configuración del entorno de pruebas.**
- **La disponibilidad de datos de prueba:** Se recomienda disponer de datos similares a los de producción que cubran todos los escenarios empresariales críticos.
- **La calidad de los datos** y criterios de aceptación del **rendimiento**.

Todos estos desafíos de incompatibilidades, duplicidades, volumen, complejidad en los datos... deben ser enfrentados para poder suministrar a la organización la información que necesita: exacta, consistente y fiable.

Pruebas habituales en BI

Hay muchos tipos de pruebas que pueden aplicarse al Data Warehouse y las bases de datos cuando se pretende garantizar que los procesos de analítica se llevan a cabo con ciertas garantías de calidad. Algunas de las más usadas son:

1. **Pruebas unitarias**, para validar cada uno de los componentes de una solución. Deben llevarse a cabo durante la etapa de desarrollo. Los elementos más críticos que deben someterse a este tipo de prueba son la lógica del propio proceso ETL, las reglas de negocio y cálculos implementados en la capa de OLAP y la lógica de KPIs. Este tipo de pruebas se hace en varias ocasiones a lo largo de un proyecto y puede automatizarse.

2. **Pruebas del sistema**, deben asegurar que se puede construir y desplegar con éxito. Hay que controlar que no surgen problemas durante su ejecución y por último confirmar que el sistema actúa del modo esperado con todas las partes constituyentes de la solución funcionando de forma conjunta.
3. **Pruebas de validación de datos**, se trata de validar los datos dentro del Data Warehouse. Estas pruebas debería proponerlas algún experto de la empresa, ya que son los que mejor conocen los datos y pueden validarlos con mayores garantías de éxito. Una forma habitual de hacerlas es usando una herramienta de consulta como Excel, que permita recuperar datos en un formato similar a los informes existentes. Cuando se detecta un vínculo entre los datos y el informe operacional, se demuestra que los datos son válidos, a menos que, por supuesto, el informe original sea erróneo.
4. **Pruebas de aceptación de usuario**, para garantizar que las informaciones y las herramientas que se proporcionen al usuario final cumplen con sus expectativas.
5. **Pruebas de rendimiento**, para validar las prestaciones de la solución en condiciones reales. Para ello, hay que tener en cuenta las arquitecturas de los datos, la configuración del hardware, la escalabilidad del sistema o la complejidad de las consultas.
6. **Pruebas de regresión**, para volver a probar la funcionalidad, garantizando que el desarrollo implementado no ha tenido impacto negativo en las bases de datos y que todo sigue funcionando en su conjunto.

La integración efectiva de las pruebas en el proceso de implementación permite generar mayor confianza entre los usuarios, ya que propicia tomar decisiones estratégicas cruciales basadas en una información generada más fiable.

Algunas recomendaciones para las pruebas de BI/Data Warehouse

La finalidad es generar unas buenas pruebas y tratar de tener el desarrollo en el entorno productivo en la fecha programada. Para ello, se presenta una serie de recomendaciones básicas que pueden ayudar a conseguir este objetivo:

1. Generar una pequeña prueba en las bases de datos a partir de datos reales.

Para ello, previamente habrá que identificar las distintas casuísticas que se pueden dar y qué resultados serán los esperados. Debe ser:

- Pequeña, para que la prueba se lleve a cabo rápidamente.
- Estática, para conocer de antemano esos resultados esperados.
- Derivada de datos reales. Esto implica añadir registros en la prueba de la base de datos para probar todos los posibles escenarios.

2. Comenzar a probar desde la primera fase y con frecuencia.

Las pruebas deben comenzar desde el momento en el que se añade un nuevo cambio en el proceso. Por lo tanto, se deben tener en cuenta las pruebas a hacer en cada fase para entender por qué se debe comenzar a probar desde el inicio:

- Base de desarrollo:
- Prueba unitaria: esta prueba asegura que el código desarrollado funciona tal y como se ha diseñado.
- Prueba de sistema: esta prueba asegura que el sistema completo funciona de acuerdo con las especificaciones. Esta fase debe iniciarse al principio del desarrollo, ya que todos los problemas se van a resolver mucho antes de comenzar con la fase de pruebas.
- Base de pruebas para la detección de problemas. Esta fase supone mayor presión para el funcionamiento correcto del sistema. Por ello es importante empezar con las pruebas en las fases iniciales y con regularidad.

3. Definir las pruebas del sistema. Usuario de negocio.

Definir pruebas basadas en lo que se cree que es necesario no bastaría. Se necesita la experiencia de los usuarios para definir buenas pruebas para el sistema. Por eso es necesario contar con los usuarios para saber si los datos son correctos, o el rendimiento de las consultas cumplen con sus expectativas. Contar con ellos asegura la calidad y proporciona mayor credibilidad.

4. El entorno de pruebas debe ser tan similar como sea posible al entorno de producción.

Lo ideal es tener un entorno de pruebas lo más parecido al de producción en cuanto a hardware, software y configuración. Por supuesto, teniendo en cuenta las posibilidades de cada organización, pero lo mínimo que hay que hacer coincidir entre ambos entornos sería:

- a) Tener configurados los nombres de las unidades. Es mejor empezar a hacerlo en el entorno de pruebas que al final, ya que puede suponer mucho trabajo al cambiar al entorno de producción.
- b) Compatibilidad total de las versiones de software del sistema operativo de la base de datos con la base de datos de los escritorios de los usuarios. Y todo aquello que los relacione.
- c) Diseño del servidor.
- d) Roles de seguridad y privilegios para las cuentas de mantenimiento.

Estrategia de pruebas de BI.

El siguiente diagrama representa los puntos de entrada de datos y enumera algunos ejemplos de comprobaciones en cada etapa: Recogida de datos, integración de datos, almacenamiento de datos y presentación de datos (Figura 16.2).




Figura 16.4: Puntos de chequeo y comprobaciones en cada etapa

Adquisición de datos

El objetivo principal de la completitud de los datos es garantizar que se extraigan todos los datos necesarios para el objetivo. Durante la fase de adquisición de datos es importante conocer las distintas fuentes de datos, los límites temporales de los datos seleccionados y cualquier otro caso especial que deba tenerse en cuenta. Las áreas clave en las que debe centrarse esta fase son:

- La validación de los datos necesarios y la disponibilidad de las fuentes de datos de las que hay que extraer estos datos.
- Perfilado de datos: La incorporación de la actividad de elaboración de perfiles de datos ayuda a comprender los datos, especialmente a identificar los diferentes valores de los datos, las condiciones de los valores límite o cualquier problema de los datos en las primeras fases. Como se ha dicho, la identificación de los problemas de datos en una fase temprana reducirá considerablemente el coste de su corrección en una fase posterior del ciclo de desarrollo.

Integración de datos

Las pruebas dentro de la fase de integración de datos son el quid de la cuestión, ya que la transformación de los datos tiene lugar en esta etapa. Los requisitos empresariales se traducen en lógica de transformación. Una vez transformados los datos, es necesario realizar pruebas exhaustivas para garantizar que los datos subyacentes cumplen con la lógica de transformación prevista. Las áreas clave en las que debe centrarse esta fase son:

- Validación del modelo de datos: Se trata de validar la estructura de los datos con las especificaciones del negocio. Esto puede hacerse comparando las columnas y sus tipos de datos con las especificaciones del negocio y los requisitos de las columnas de los informes, asegurando la cobertura de los datos en el origen.

- Revisión del diccionario de datos: Verificar los metadatos que incluyen restricciones como nulos, valores por defecto, claves primarias, restricciones de verificación, integridad referencial, claves sustitutas, cardinalidad (1:1, m: n), etc.
- Validación de la asignación de origen a destino: Asegurar la trazabilidad en todo momento ayudará a construir los aspectos de calidad como la consistencia, la precisión y la fiabilidad.

Almacenamiento de datos

La fase de almacenamiento de datos se refiere a la carga de datos dentro del almacén de datos/data marts o cubos OLAP. Las cargas de datos pueden ser únicas, incrementales o en tiempo real. Las áreas clave en las que debe centrarse esta fase son:

- Validación de las cargas de datos en función de los intervalos de tiempo.
- Rendimiento y escalabilidad: Las pruebas de las cargas iniciales y posteriores con el aspecto del rendimiento y la escalabilidad garantizan que el sistema está dentro de los límites de rendimiento aceptables y puede sostener un mayor crecimiento de los datos.
- Ejecución paralela y precedencia: Es importante verificar la ejecución paralela y la precedencia apropiadas durante el proceso ETL, ya que puede repercutir directamente en el rendimiento y la escalabilidad del sistema.
- Validación de la política de archivo y purga: Garantiza el historial de datos basado en los requisitos del negocio.
- Verificar el registro de errores, la gestión de excepciones y la recuperación de puntos de fallo.

Presentación de datos

Esta es la etapa final del ciclo de pruebas y tiene el privilegio de contar con una interfaz gráfica para probar los datos (cuadros de mando/dashboards). Las áreas clave en las que debe centrarse esta fase son:

- Validación del modelo de informe.
- Validación del diseño del informe según las maquetas y validación de los datos según los requisitos de la empresa.
- Pruebas de extremo a extremo: Aunque los componentes individuales del almacén de datos se comporten como se espera, no hay garantía de que todo el sistema se comporte igual. Por lo tanto, se recomienda la ejecución y validación de ejecuciones de extremo a extremo. Además de las discrepancias en la conciliación de datos, pueden surgir problemas como la contención de recursos o los bloqueos. Las ejecuciones de extremo a extremo ayudarán a garantizar el cumplimiento de los criterios de aceptación de la calidad de los datos y el rendimiento.

Casi todas las herramientas comerciales de BI tienen sistemas de validación y pruebas. Por ejemplo, son muy interesantes la Motio para Cognos de IBM, la de Microstrategy Reporting Suite o BitWise DW/BI Testing. La intención es casi siempre abordar la mayoría de los desafíos de las pruebas DW/BI:

- Trazabilidad de principio a fin, desde la extracción de la fuente hasta los informes.
- Cobertura del 100
- Automatización de los casos de prueba de las comprobaciones estándar consiguiendo un considerable ahorro de tiempo.
- Ahorro de tiempo gracias a la automatización de las pruebas de regresión.
- Seguimiento de defectos o errores con la participación de todas las partes interesadas.
- Mejora del tiempo del ciclo de pruebas gracias a la reutilización.
- Mejoras en el proceso con informes analíticos que muestran los datos de las pruebas, los casos de prueba y las tendencias de los defectos.

16.4. Evaluación de técnicas estadísticas y algoritmos de Aprendizaje Automático.

Validación de modelos en el análisis estadístico.

En el análisis de datos estadístico existen muchas aplicaciones y, por ello, hay muchas maneras de validar un modelo. La mayoría de las veces dependerá de lo que queramos medir para determinar la bondad del mismo. Comúnmente, a este conjunto de criterios se le llama Bondad de Ajuste o en inglés Goodness of Fit (GoF) [2]. Además, estas medidas no sólo evalúan la potencia de predicción del modelo, sino que también permiten validar las hipótesis iniciales. Hay que tener en cuenta que, en la mayoría de los casos, las hipótesis iniciales del modelo es lo primero en lo que se fija un Data Scientist. A veces podemos obtener un resultado absolutamente inesperado y, por tanto, no nos podemos fiar de las estimaciones del modelo en cuestión. A nivel industrial y empresarial esto se traduce en la robustez de las soluciones y riesgo de tomar decisiones basadas en estimaciones posiblemente erróneas. Algunas de las técnicas usadas son las siguientes:

- La prueba ² de Pearson se considera una prueba no paramétrica que mide la discrepancia entre una distribución observada y otra teórica (bondad de ajuste), indicando en qué medida las diferencias existentes entre ambas, de haberlas, se deben al azar en el contraste de hipótesis. También se utiliza para probar la independencia de dos variables entre sí, mediante la presentación de los datos en tablas de contingencia.

- El coeficiente de determinación, denominado R^2 , es usado en el contexto de un modelo estadístico cuyo principal propósito es predecir futuros resultados o probar una hipótesis. El coeficiente determina la calidad del modelo para replicar los resultados, y la proporción de variación de los resultados que puede explicarse por el modelo.
- (LR), conocido también en español como razón de verosimilitud, se define, por ejemplo en medicina, como la razón entre la posibilidad de observar un resultado en los pacientes con la enfermedad en cuestión versus la posibilidad de ese resultado en pacientes sin la patología.
- El criterio de Cramér-von Mises se emplea para juzgar la bondad de una función de distribución acumulada F^* comparada con una función de distribución empírica F_n , o para comparar dos distribuciones empíricas. También se utiliza como parte de otros algoritmos, tal como la estimación de la distancia mínima.
- En la teoría de la información, la entropía cruzada (cross-entropy) entre dos distribuciones de probabilidad p y q sobre el mismo conjunto subyacente de sucesos mide el número medio de bits necesarios para identificar un suceso extraído del conjunto si un esquema de codificación utilizado para el conjunto está optimizado para una distribución de probabilidad estimada q , en lugar de la verdadera distribución p .
- La desviación es una métrica asociada principalmente a los modelos de respuesta categórica, como un modelo de regresión logística cuando se trata de una variable aleatoria binomial Bernoulli, o una regresión Poisson que trata de datos de recuento multinomial. Esencialmente, la desviación mide la falta de ajuste entre un modelo y sus datos. Otra forma de pensar en ella es que es la desviación de sus datos del modelo. Se calcula como -2 veces la diferencia entre la log-verosimilitud del modelo de interés y la log-verosimilitud del modelo saturado

Criterios de potencial predictivo.

Los siguientes métodos no están relacionados con ningún modelo en particular ni asunciones iniciales, como por ejemplo la familia de distribuciones exponencial. Simplemente, nos fijamos en el tipo de la variable respuesta y aplicamos una función que mide la desviación entre la estimación y la realidad. En algunas ocasiones esta función coincidirá con la función error que naturalmente derivaría del modelo que se está utilizando y las restricciones aplicadas, pero no tiene por qué.

Por ejemplo, en el caso de respuesta continua existe NRMSE (Normalized Root Mean Square Error) donde el denominador puede ser la media, un intervalo, una cota superior, etc. A veces es conveniente usar el error absoluto en vez del cuadrático, cuando por ejemplo el objetivo es maximizar la distancia entre vectores de forma uniforme (en el espacio multi-dimensional). Incluso, dependiendo del problema, interesa usar el sumatorio absoluto en vez del promedio o ponderación. Otra

medida muy fácil de interpretar es el error relativo (absoluto o con signo), aunque tiene varios inconvenientes. MAPE sería el promedio del error relativo absoluto. A menudo se usan percentiles del error, en vez del promedio, ya que dan una noción de estabilidad.

Para datos categóricos, tenemos combinaciones de TP (true positive), TN (true negative), FP (false positive) y FN (false negative). Sobre estos indicadores se pueden construir muchas medidas de ajuste: Precisión (precision), Exhaustividad (recall), F-measure y otras muchas combinaciones:

La precisión (también llamada valor predictivo positivo) es la fracción de instancias relevantes entre las instancias recuperadas, mientras que la exhaustividad (también conocida como sensibilidad) es la fracción de instancias relevantes que se recuperaron. Por tanto, tanto la precisión como la exhaustividad se basan en la relevancia.

Consideremos un programa informático para reconocer perros (el elemento relevante) en una fotografía digital. Al procesar una fotografía que contiene diez gatos y doce perros, el programa identifica ocho perros. De los ocho elementos identificados como perros, sólo cinco son realmente perros (verdaderos positivos), mientras que los otros tres son gatos (falsos positivos). Siete perros no fueron detectados (falsos negativos) y siete gatos fueron excluidos correctamente (verdaderos negativos). La precisión del programa es entonces de $5/8$ (verdaderos positivos / elementos seleccionados), mientras que su exhaustividad es de $5/12$ (verdaderos positivos / elementos relevantes).

Cuando un motor de búsqueda devuelve 30 páginas, de las cuales sólo 20 son relevantes, mientras que no devuelve otras 40 páginas relevantes, su precisión es de $20/30 = 2/3$, lo que nos indica la validez de los resultados, mientras que su exhaustividad es de $20/60 = 1/3$, lo que nos indica lo completos que son los resultados.

Una medida que combina la precisión y la exhaustividad es la media armónica de la precisión y la exhaustividad, la tradicional F-measure o balanced F-score.

Una forma de resumir o contraponer estas medidas es construir una gráfica donde cada eje represente uno de estos indicadores. La curva ROC (Receiver Operating Characteristic) representa el FP y TP. Cada punto en el espacio 2-D es un clasificador y la envolvente convexa (ROCCH) de los puntos da la curva ROC que representa tanto clasificadores plausibles como puntos que forman dicha envolvente. La recta con la pendiente 1 y la ordenada de origen 0 representa respuesta aleatoria. Los puntos por debajo de esa recta son clasificadores sub-óptimos.




Figura 16.5: Envoltentes convexas ROC (ROCCH) de dos conjuntos de clasificadores

Esta gráfica da una idea del umbral de clasificación a elegir dependiendo del problema que se intenta resolver. Se puede calcular coste versus beneficio utilizando los valores de TP y FP que corresponden a cada clasificador (umbral de decisión). En la Fig. 16.3 se puede ver cómo las diferentes pendientes representan escenarios distintos según caso de uso.

Por último, la validación cruzada o cross-validation es una técnica utilizada para evaluar los resultados de un análisis estadístico y garantizar que son independientes de la partición entre datos de entrenamiento y prueba. Consiste en repetir y calcular la media aritmética obtenida de las medidas de evaluación sobre diferentes particiones. Se utiliza en entornos donde el objetivo principal es la predicción y se quiere estimar la precisión de un modelo que se llevará a cabo a la práctica. Es una técnica muy utilizada en proyectos de inteligencia artificial y minería de datos para validar modelos generados.

16.5. Conclusiones.

Inicialmente, y continuando con lo iniciado en el capítulo anterior, se ha presentado una enumeración y breve descripción de los que se consideran “algoritmos de minería de datos”, con una visión panorámica que pretende ser un mapa completo de los objetivos, orientación y técnicas (tanto estadísticas como provenientes de la Inteligencia Artificial) para afrontar el análisis de datos en entornos Big Data.

Se ha visto que probar las aplicaciones de BI es diferente a probar las aplicaciones empresariales tradicionales. Para lograr resultados verdaderamente creíbles, cada etapa del ciclo de vida de los datos debe ser probada efectivamente: Recolección de Datos, Integración, Almacenamiento y Presentación, por lo que es importante disponer de técnicas de evaluación y validación de los modelos de BI que se propongan.

Por último, se han presentado varios procedimientos de validación de modelos estadísticos y de aprendizaje automático, así como medidas de la bondad de ajuste y potencia predictiva. Se han proporcionado ejemplos y casos de uso para dichas medidas e indicadores. Este conjunto de herramientas ayuda a medir factores que no son directamente observables. Por ello, hay que tener en cuenta el sesgo que puede ser introducido a la hora de hacer dichas mediciones. Por ejemplo, a la hora de particionar los datos en conjuntos de aprendizaje y validación a menudo no basta con hacer una partición aleatoria. Esto sucede con frecuencia en modelos para marketing, en los cuales el comportamiento de clientes tiene un lapso y va asociado a unas acciones. Esta secuencia temporal se debe respetar a la hora de particionar datos y solamente introducir la aleatoriedad para tomar muestras.

16.6. Bibliografía

1. Gómez, A.; Juristo, N.; Montes C.; Pazos, J. (1997). Ingeniería del Conocimiento. Centro de Estudios Ramón Areces, Madrid.
2. Bowman, A. W. (1988). "Goodness-of-fit Techniques", Journal of the Royal Statistical Society Series A, Royal Statistical Society, vol. 151(1).