

Sistemas de Big Data

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

Presentación del módulo

Sistemas de Big Data

La creciente digitalización de nuestras sociedades está generando grandes volúmenes de datos. Los sistemas de Big Data (BD) están diseñados para procesar estos datos y obtener información relevante de ellos. Hoy en día existen aplicaciones de los sistemas BD en todos los sectores económicos y es por tanto un sector en continuo auge en el mercado laboral. Este módulo profesional contiene la formación necesaria para desempeñar las funciones de integrar, procesar y analizar la información de grandes volúmenes de datos, aplicando herramientas y técnicas de BD para su visualización, valoración y presentación de resultados en la toma de decisiones de las empresas y organizaciones.

Las funciones antes citadas incluye aspectos como:

1. Determinar herramientas necesarias de los sistemas Big Data.
2. Configurar cuadros de mando en diferentes entornos computacionales.
3. Gestionar y almacenar grandes volúmenes de datos para facilitar la búsqueda de respuesta.
4. Aplicar técnicas Big Data para integrar, procesar y analizar la información.
5. Visualizar datos para distintos escenarios.

Los **contenidos** básicos del curso y su planificación temporal se muestra en la tabla 1.1.

El módulo se desarrollará sobre varios tipos de herramientas. Para el procesamiento se emplearán *Google colab* y *Spark*, para las tareas de almacenamiento *Mongo DB* y *Flume* y para las tareas de visualización *Tableau*, *Data Studio* y *Qlik*.

Todos los módulos del curso de especialización en Inteligencia Artificial y Big Data comparten la misma metodología docente. La carga docente de cada semana del módulo es de 0,5 ECTS, desarrollándose los siguientes recursos/actividades didácticas:

Semana	Contenidos
SEMANA 1.	Complejidad computacional. Procesamiento de la información.
SEMANA 2.	Introducción a los sistemas Big Data.
SEMANAS 3. 4. y 5.	Minería de datos y cuadros de mando en entornos computacionales.
SEMANA 6.	Metaheurísticos.
SEMANAS 7. y 8.	Gestión y Almacenamiento de datos.
SEMANAS 9. y 10.	Aplicación de herramientas para el análisis de datos.
SEMANA 11. y 12.	Aplicación de herramientas para la visualización de datos.

Tabla 1.1: Planificación temporal de los contenidos

- **Clases teóricas y prácticas** mediante 8 vídeos de unos 5 minutos en los que se impartirán de forma no concurrente los contenidos básicos y ejemplos prácticos, con el código fuente para realizar las actividades.
- **Documentación.** Los contenidos de estos vídeos serán recogidos y complementados en un material escritos de aproximadamente 15 páginas/semana.
- **Ejercicios de autoevaluación HSP.** Cada semana los alumnos contendrán unos 4 ejercicios de autoevaluación.
- **Ejercicios propuestos complementarios.**
- **Tutorías.** Todas las semanas se dispondrá de una hora de tutorías para resolver las dudas sobre los materiales desarrollados en dicha semana.

Empleamos como principio metodológico para el módulo el de **aprender a hacer se aprende haciendo**. La evaluación se alinea a esta visión y se realiza a través de tres actividades relativas a: i) configuración de un cuadro de mando, ii) almacenamiento de grandes volúmenes de datos y iii) visualización y análisis de datos.

Complejidad computacional. Procesamiento de la información

1.1. Introducción

El objetivo de este capítulo es dar una visión general de las técnicas de integración, procesamiento y análisis de información en sistemas Big Data. El punto de partida es dar la definición más extendida de Big Data basada en las 3 Vs. Se continúa introduciendo el concepto de complejidad computacional y mostrando que las limitaciones actuales (y futuras) en las capacidades computacionales están originadas por la gran cantidad de datos (volumen) y por la complejidad algorítmica. Finalizaremos con un esquema conceptual para obtener información a partir de los datos que se implementa en los sistemas BD.

1.1.1. ¿Que es el Big Data? (3 Vs)

Los datos están adquiriendo un papel central en la toma de decisiones tanto en empresas como en instituciones públicas. La creciente digitalización de nuestras sociedades están generando grandes cantidades de datos, apareciendo el concepto de *Big Data*. No hay un consenso en la definición de este concepto, pero la más extendida es la definición de las 3 Vs dada en 2001 por Doug Laney, de la empresa de análisis Gartner, que define las dimensiones y propiedades de BD. Las Vs encapsulan la verdadera definición de BD y marcan el comienzo de un nuevo periodo en el que los BD puede considerarse una característica dominante del siglo XXI. Desde entonces se han añadido a la lista otras Vs, como veracidad, valor y variabilidad pero la definición original de las 3Vs sintetiza las características esenciales del concepto BD.

1. **Volumen.** La primera característica de estos sistemas es la inmensa cantidad de datos que puede variar de terabytes a petabytes, o incluso mayor (Ver la tabla 1.2 para tener en cuenta el orden de magnitud, notar que el número de átomos de hidrógeno en el universo es de 4×10^{79}). Por ejemplo Facebook

Tabla 1.2: Unidades de almacenamiento

Unidad	Cantidad de bytes
Gigabytes	10 ⁹ bytes
Terabytes	10 ¹² bytes
Petabytes	10 ¹⁵ bytes
Exabytes	10 ¹⁸ bytes
Zettabytes	10 ²¹ bytes
Yottabytes	10 ²⁴ bytes

almacenó 100 petabytes de fotos y videos en 2012 que fue almacenado por 845 millones de usuarios. La siguiente tabla recoge unidades de almacenamiento que son necesario usar en estos contextos. El *World Economic Forum* estima que en 44 zettabytes los datos disponibles en el año 2020.

- 2. **Velocidad.** Esta característica hace referencia a cómo el flujo de datos se está generando. Además, se impone en ciertos contextos ventanas temporales breves para procesar dichos datos. Por ejemplo, en Facebook se suben 900 millones de fotos cada día.
- 3. **Variedad.** Los datos son generados de una amplia cantidad de fuentes y formatos. Por ejemplo se emplean formatos como ficheros log, bases de datos, ficheros XML o pueden consistir en imágenes, vídeos, audio, etc.

Esta definición ha ido expandiéndose par incorporar nuevas dimensiones a la definición de BD como *veracidad*, *valor*, *variabilidad*, *visualización*, etc. Es gracioso el empeño forzado de encontrar palabras que empiecen por V, llegando a proponer *viscosidad* y *volatilidad*.

Todos estos datos, debido a técnicas de aprendizaje automático y de minería de datos tienen un valor comercial. El objetivo de estos sistemas no es solo el almacenamiento, sino aplicar técnicas analíticas que permitan extraer información relevante de los datos.

1.1.2. Modelos de negocio basado en datos

El modelo de negocio (BM, sus siglas en inglés) se refiere a como una organización crea y captura valor. Los modelos de negocios basados en Big Data (BDBM, su siglas en inglés) están en la infancia y están en un proceso de creación. [WSM20] hace una taxonomía de las empresas en función de su BDBM clasificándolas en: i) usuarias de datos, ii) proveedoras de datos y iii) facilitadoras de BD. El primer grupo son las empresas que capturan el valor de las aplicaciones de BD. Por ejemplo mejorando sus procesos internos a partir de aplicaciones de BD. El segundo grupo venden sus datos a terceros. Estas empresas van desde vendedoras de *Massive Open Online Course* (MOOC) hasta vendedores de indicadores de salud personal. El tercer tipo de empresas son las que facilitan la realización de las aplicaciones de BD alquilando la infraestructura (hardware y software) para implementar soluciones

Tabla 1.3: Tipología de BDBM (fuente [WSM20])

Tipo	Fuente de valor (ejemplo)
Usuarios de datos	• Analisis BD para apoyar la toma de decisiones estratégicas • Uso de BD para mejorar los procesos internos • Enriquecer productos, servicios y experiencia de clientes mediante BD • Desarrollo de nuevos productos y servicios mediante BD
Proveedoras de datos	• Recopilando datos primarios y vendiéndolos a terceros
Facilitadores de BD	• Agregando datos y empaquetando datos internos para la venta • Ofreciendo la infraestructura a las anteriores tipos de empresa necesaria para realizar BD • Consultoría relativa a BD • Subcontratación de técnicas analíticas para BD (ejemplo en la nube)

BD o prestando consultoría y servicios en BD. En la tabla 1.3 se muestran ejemplos de creación de valor. Las destrezas de un profesional de BD difieren del modelo de negocio de la empresa y este hecho se debe tener presente en la formación de los profesionales.

1.2. Complejidad computacional para el análisis de datos

[HFG⁺19] mostró un modelo de crecimiento digital (ver Figura 1.1) donde el crecimiento del volumen de datos y la capacidad computacional para procesarlos sigue un crecimiento exponencial pero con la diferencia esencial que el volumen de datos se duplica cada 12 meses mientras que los recursos computacionales cada 18 meses (Ley de Moore). Estos autores postulan que el crecimiento del coste de los procesos para analizar datos, aspecto que incluyen los algoritmos, tiene un crecimiento factorial cuyo consecuencia inmediata es una gran cantidad de datos que no podrán ser analizados. Esta complejidad explosiva impone un modelo de inteligencia distribuida para poder afrontar los retos del mundo y de nuestras sociedades. El objetivo de esta sección es evaluar la severidad del efecto de la complejidad algorítmica en la implantación y desarrollo de sistemas BD.

El coste computacional de la ejecución de un algoritmo es un factor limitante incluso cuando no se está ante grandes volúmenes de datos. Esto es lo que vamos a mostrar en esta sección. Supongamos que el número de datos disponibles es n . Es evidente que si el número de datos n aumenta entonces el tiempo de ejecución de un




Figura 1.1: Modelo de crecimiento digital, fuente [HFG⁺19].

algoritmo para procesarlos también aumente. Por tanto cualquier algoritmo tiene la propiedad que si n crece hacia infinito su coste computacional también crece hacia infinito. La cuestión esencial es que existen varias velocidades de crecer a infinito, unas significativamente más rápidas que otras. La relación matemática

$$\lim_{n \rightarrow +\infty} \frac{P(n)}{a^n} = 0 \quad (1.1)$$

para cualquier $a > 1$ y para cualquier polinomio $P(n)$ indica que aunque tanto el numerador como el denominador tienden a infinito el denominador crece muchísimo más rápido que el numerador

Se dice que un algoritmo tiene un **tiempo de ejecución polinomial** si el número de operaciones máximo que realiza para resolver un problema está acotado por un polinomio en el tamaño del problema. Para ciertos problemas el tamaño del mismo es el número de datos. Por ejemplo si queremos ordenar un vector mediante el algoritmo de la burbuja, lo denotamos por $\mathcal{A}$ el número de operaciones que realiza el algoritmo $\mathcal{A}$ está acotado por un polinomio cuadrático en función del número de datos n , diremos que el algoritmo $\mathcal{A}$ es polinomial. Mas concretamente diremos que la complejidad de $\mathcal{A}$ es $O(n^2)$. Según esta definición el problema de ordenar un vector es un problema de la clase $\mathcal{P}$.

Se dice que un problema está en la **clase de complejidad $\mathcal{P}$** si existe un algoritmo para resolver el problema que tiene un tiempo de ejecución polinomial. Si no se conoce ningún algoritmo que lo resuelva en tiempo polinomial (porque no exista o porque en este momento no se haya desarrollado) se dice que el problema está en la **clase de complejidad $\mathcal{NP}$** . Dentro de los problema $\mathcal{NP}$ existen un subconjunto de problemas llamados $\mathcal{NP}$ -**completos**. Si uno de estos problemas tuviera

un algoritmo de resolución polinomial entonces todos los problemas de la clase NP también tendrían un algoritmo polinomial y en dicho caso $\mathcal{P} = \mathcal{NP}$. El *Clay Mathematics Institute*  Link: <http://https://www.claymath.org/> ofrece un millón de dólares a quien sea capaz de responder a la pregunta ¿ $\mathcal{P} = \mathcal{NP}$?

ACTIVIDAD:

La siguiente actividad pone de manifiesto que cualquier problema que no esté en la clase $\mathcal{P}$ es intratable de forma exacta sean cuales sean los recursos computacionales disponibles.

El RSA (Rivest, Shamir y Adleman) es un sistema criptográfico de clave pública que permite firmar digitalmente documentos. Su seguridad se basa en el elevado coste computacional de factorizar en números primos un número dado. Uno de los algoritmos más rápidos para factorizar un entero de n cifras requiere del orden de

$$\star f_A(n) = 10^{\sqrt{n \cdot \log_{10}(n)}} \text{ operaciones. (El logaritmo es en base 10).} \quad (1.2)$$

Si deseamos analizar la complejidad de un algoritmo se puede recurrir a una forma visual consistente en representar la función $f_A(n)$. En el eje OY se considera una escala logarítmica y en el eje OX se representa la variable n . En la Figura 1.2 hemos representado $f_A(n)$ y la función polinomial $y = n^{10}$. Se observa que el aspecto de la gráfica polinomial coincide con una función cóncava, mientras que un comportamiento lineal (o incluso estrictamente convexa) representa crecimiento exponencial.




Figura 1.2: Crecimiento polinomial vs exponencial.

Supongamos que disponemos del ordenador de IBM *Roadrunner* que es capaz de superar un *petaflop* de operaciones por segundo. Es capaz de realizar $1,105 \cdot 10^{15}$ operaciones por segundo. ¿Cuánto tiempo emplearía en factorizar un número de 50 cifras?



$$\text{VelocidadCPU} = 1,105 \cdot 10^{15} \text{ operaciones / segundos}$$

$$\frac{f_A(50)}{\text{VelocidadCPU}} = 1,4907 \cdot 10^{-6} \text{ segundos}$$

El resultado muestra que tardaría menos de una milésima de segundo. Y si nos preguntamos cual es el máximo número de cifras n que *Roadrunner* puede factorizar durante un año. Planteamos el siguiente código (ver Listado 1.1) en Python para resolver la cuestión.

Listado 1.1: Código en python para calcular el máximo número de cifras de una clave RSA que se puede romper con el ordenador Roadrunner



```
1 # Carga de la libreria math para calcular log10
2 from math import *
3 # Operaciones/segundo realizadas por Roadrunner
4 VelocidadCPU = 1.105 * 10 ** 15
5 # número de dígitos
6 n=1
7 # número de operaciones
8 fA=1
9 # ¿ nº operaciones requeridas <nº operaciones en un año?
10 while fA <= (VelocidadCPU *24 * 60 * 60 *365):
11     n = n+1
12     fA = 10 ** ( pow( n * log(n,10) , 0.5 ) )
13
14 print('Numero maximo de cifras = ' , n-1)
```

El resultado de ejecutarlo es $n = 217$. Hemos pasado de factorizar un número de 50 cifras en una millonésima de segundo a necesitar un año para factorizar un número con un poco mas del cuádruple de cifras. Nos podemos plantear la cuestión de que pasaría si se duplicase la capacidad de cómputo de *Roadrunner*, esto es, la nueva capacidad de cómputo es $2 * \text{VelocidadCPU}$. ¿Se duplicaría el la longitud de cifras de los números que son factorizables en un año? ¿Cuántas cifras más se podrían abordar? Volviendo a ejecutar el código para esta nueva capacidad de cómputo comprobamos que el resultado ahora es de $n = 222$ cifras, la duplicación de la capacidad de cómputo ha aumentando solamente 5 nuevas cifras. La duplicación de los recursos computacionales no es una estrategia por si sola que sea capaz de abordar el coste computacional de los problemas.



Este ejemplo muestra que el un tiempo de ejecución exponencial es inabordable para cualquier máquina actual. De hecho a efectos prácticos una complejidad computacional superior a n^3 es dramática.

Actividad. Divide y vencerás. En esta actividad vamos a motivar como abordar los sistemas BD usando computación distribuida. Este enfoque es la base de tecnologías como MapReduce. Supongamos que tenemos un algoritmo $\mathcal{A}$ de complejidad $\mathcal{O}(n^2)$. Este algoritmo para un tamaño del problema $n = 1000$ (asumimos que n representa el número de datos) realizará una cantidad proporcional a 1000^3 operaciones, esto es, 1000 millones de operaciones. Supongamos que particionamos la base de datos en $k = 100$ grupos de 10 datos cada uno y aplicamos el algoritmo a cada uno de estos grupos. Este proceso se puede realizar de modo distribuido, como el mostrado en la Figura 1.3. Obtenemos como resultado de este proceso k salidas parciales que deben combinarse para obtener el resultado final. Obviamente en esta desagregación se pierde exactitud en el proceso. Si analizamos ahora el coste computacional tenemos que cada subtask se realiza ahora del orden de 10^3 operaciones, además estas operaciones se realiza de forma paralela. En una siguiente fase se deben combinar los resultados y estas operaciones supondrían un coste adicional de $f(k)$ operaciones. Pongamos un ejemplo sencillo para ilustrar este procedimiento de cálculo distribuido. Vamos a calcular la media de un conjunto de números $\bar{x} = \frac{x_1 + \dots + x_n}{n}$. Esta operación tiene un coste computacional $\mathcal{O}(n)$. Si particionamos los datos en grupos iguales de m elementos tal que $n = mk$ y calculamos la media en dichos grupos, el coste por subgrupo es $\mathcal{O}(m)$. El proceso para combinar medias es la media de la medias $\bar{x} = \frac{\bar{x}_1 + \dots + \bar{x}_k}{k}$, que tiene un coste $\mathcal{O}(k)$, por tanto, el resultado final es $\mathcal{O}(m) + \mathcal{O}(k)$. Además como los grupos son de igual tamaño el resultado es exacto. Como conclusión este esquema distribuido pasa de un coste computacional $\mathcal{O}(m.k)$ a uno $\mathcal{O}(m) + \mathcal{O}(k)$.




Figura 1.3: Computación distribuida.

1.3. Técnicas y procesos de extracción de la información de los datos

Supongamos que en una primera fase se ha adquirido un conocimiento previo del caso de estudio y se han establecido unos objetivos para el proyecto (Big Data). Este análisis inicial marcará los puntos desde donde se parte (datos) a donde se quiere llegar (información). El proceso mostrado en la Figura 1.4 establece las etapas a seguir para extraer la información a partir de los datos. Este proceso consta de las siguientes etapas:

1. **Identificación de datos:** En esta fase se identifican todas las fuentes generadoras de datos que están disponibles y son de utilidad para el objetivo del proyecto.
2. **Modelo de datos y Almacenamiento.** En la primera etapa de **preparación** o **pre-procesamiento los datos** se almacenan en *crudo*. Esto permite crear repositorios con grandes volúmenes de información sin invertir mucho tiempo en la definición de su estructura e implementación. El objetivo de esta etapa es mejorar la calidad de los datos. Se establecen modelos predictivos para los datos poco fiables, defectuosos, ausentes o desajustados en cuanto a atribuciones válidas.

En la siguiente etapa se define un **modelo de datos** con el objetivo de organizar, clasificar y especificar como se relacionan los datos existentes. También se establecen las condiciones que deben cumplir los datos para reflejar la realidad modelada y considerarlos válidos. También se definen las transformaciones necesarias que se deben realizar para poder ser utilizados. En la fase de **almacenamiento** se procede a la implementación del modelo en una base de datos.

3. **Proceso analítico.** En esta etapa mediante técnicas de aprendizaje automático se buscan patrones de interés, determinación de tendencias, identificación de anomalías, etc.
4. **Visualización.** En esta fase final se entregan los resultados obtenidos para su interpretación y documentación. En este punto, los datos finales han sido limpiados, convertidos, seleccionados en base a atributos relevantes y enmarcados en representaciones visuales para ayudar a los humanos en su toma de decisiones.

Un ejemplo notable de visualización son los **cuadros de mando integrales** que monitorizan en tiempo real la actividad de una empresa u organización y permiten tomar decisiones a corto plazo adecuadas a la estrategia marco adoptada. Estas herramientas emplean el uso de los **KPI** o **Indicadores Clave de Desempeño** (*Key Performance Indicators*, para las siglas en inglés) para cuantificar y evaluar el rendimiento de una estrategia de negocio en base a la consecución de los objetivos fijados por la misma.

En esta sección vamos a introducir estos elementos.




Figura 1.4: Proceso de extracción de información de los datos.

1.3.1. Identificación de datos y sus tipologías

El primer paso es determinar la fuentes de datos que pueden ser útiles. Estas fuentes abarcan los datos generados en el propio entorno empresarial (datos internos) como aquellas que son ajenas a la organización (datos externos), como redes sociales, web, bases de datos compradas a otras compañías, datos geográficos, datos económicos sectoriales, etc. Tras este proceso se dispondrá de un conjunto de datos que abarcarán una o varias de las siguientes tipologías:

- **Estructurados.** Los datos estructurado son aquellos que están bien definidos en cuanto su formato, longitud y significado. Ejemplos de este tipo de datos son magnitudes, fechas, cadenas de caracteres. Sus almacenamiento se registran en tablas. Si el volumen es grande se almacenan en *Data Warehouse*, en otros casos se emplean bases de datos relacionales o simples hojas de cálculo. En los modelos de bases de datos relacionales toda la información se almacena en tablas en las que se especifican el tipo de campos que tienen y cómo se relacionan entre ellas.
- **No estructurados.** Los datos no estructurados no tienen un formato ni un tamaño predefinido. Ejemplos de este tipo de datos son el texto, vídeo, audio e imágenes. Este tipo de datos se generan por múltiples fuentes como sensores, satélites, ordenadores, teléfonos inteligentes, redes sociales, por actividades en sitios webs, etc. Hoy en día este tipo de datos constituyen una fuente muy

importante para las empresas para obtener información de sus clientes, de sus procesos, de sus productos, etc. El almacenamiento de este tipo de datos debe realizarse de forma organizada a través de una base de datos no relacional (NoSQL).

- **Semi estructurados.** Este tipo de datos combinan datos estructurados y no estructurados. Estos datos tienen un esqueleto o estructura que organiza los inputs que deben contener y define las relaciones entre los textos y objetos que contienen. Este esqueleto puede evolucionar en el tiempo y convertirse en un protocolo aceptado. Este esqueleto se define en forma de árbol, con etiquetas para facilitarte el manejo.

Ejemplos de este tipo de datos son las páginas web o servicios de correos electrónicos donde se almacén los mensajes y ficheros adjuntos. Los meta-datos permiten clasificarlos y realizar búsquedas por palabras clave.

1.3.2. Modelos de datos y almacenamiento

El primer paso consiste en una recopilación en *bruto* de los datos y su **pre-procesamiento**. En la preparación de los datos se deben eliminar el mayor número posible de datos erróneos o inconsistentes (limpieza o depuración) e irrelevantes (criba). En esta fase se pueden emplear *métodos estadísticos* para detectar *outliers* o *seleccionar registros problemáticos*. Con estos datos se ignorarán, se filtrarán (eliminar o reemplazar el valor). También en esta fase se deben analizar los valores faltantes (*missing value*). Se puede reemplazar por la media, eliminar el registro, estimar a partir de otros datos, etc.

El **modelo de datos** puede ser visto como el lenguaje para describir el modo de almacenar los datos en una base de datos. El modelo de datos juega el papel de puente entre las áreas funcionales de la empresa y la parte de tecnologías de la información de la misma.

El modelo de datos es un conjunto de herramientas teóricas para describir las propiedades relevantes de los datos del sistema en consideración. Este contiene tres elementos:

- Una notación para la descripción de la estructura de los datos, el tipo de datos y cómo se relacionan.
- El conjunto de restricciones de integridad que deben cumplir los valores de los datos para ser considerados válidos, y
- Un conjunto de operaciones para la actualización y recuperación de los datos.

Existe tres niveles de abstracción a la hora de analizar un modelo de datos:

1. **Modelo de datos conceptual.** Es el nivel más alto de abstracción y en este nivel se define *lo que* el sistema contiene, estableciendo su organización, finalidad y reglas y conceptos del negocio.

2. **Modelo de datos lógico.** Está situado en el nivel intermedio de abstracción y define cómo el sistema debería estar implementado, independiente del tipo de base de datos que se empleará. El objetivo es desarrollar un mapa técnico para las reglas y la estructura de los datos.
3. **Modelo de datos físico.** Es el nivel más bajo de abstracción y describe como el sistema será implementado usando una base de datos específica.

La tabla 1.4 muestra una taxonomía de modelos de datos y ejemplos de la misma, así como las técnicas de modelización de datos empleadas. Estas técnicas de modelización son aplicables tanto a modelos relacionales como no relacionales, y se describe a continuación:

1. **Diagrama de entidades-relaciones (ERD)**, en su acrónimo en inglés). Esta técnica visual es la opción por defecto empleada en la modelización y diseño de bases de datos relacionales. Incorpora el uso de entidades, atributos, relaciones, cardinalidades, restricciones entre otros elementos, así como notación simbólica.
2. **Diagramas de clase Unified Modeling Language (UML)**. Este es una notación standard para modelizar y diseñar sistemas de información empresarial.
3. **Diccionario de datos.** Es una representación tabular de los conjuntos de datos y sus atributos, que contienen elementos como la descripción de los elementos, relaciones entre tablas, restricciones (unicidad, valores por defecto, valores válidos).

no funciona el entorno beginturn. Parece como si no cargara el paquetete rotating

1.3.3. Técnicas de aprendizaje automático para la extracción de información de los datos estructurados y no estructurados

Las técnicas de aprendizaje automático o *machine learning* se aplican al análisis de los datos. Las variables a analizar se clasifican en atributos (o también llamadas características) x y en variable respuesta (o también llamada etiqueta) y , que representa el fenómeno a analizar. Si la variable y aparece en los datos del estudio estamos ante un problema de **aprendizaje supervisado** y en caso de que no disponer de ella ante uno de **aprendizaje no supervisado**. Los tres tipos de problemas que aparecen son:

- **Clustering.** En este problema se busca patrones dentro de los datos. Esto es, encontrar subconjuntos de observaciones que son similares entre sí. Matemáticamente se formularía como determinar las etiquetas y de los datos de modo que si dos observaciones i y j son similares le asociemos la misma etiqueta, $y_i = y_j$. Una dificultad de este problema es que no se parte de un conjunto previo de etiquetas del cual aprender.

Tipo	Modelo de datos	Técnica
Basada en registros	●Jerárquico: Los datos se almacenan en registros. Los registros tienen estructura de árbol donde cada registro tiene un único <i>padre</i> (nodo superior) ● Red: Elaborado sobre un modelo jerárquico pero permitiendo que los registros tengan múltiples padres ● Registros: Se especifica la estructura de toda la base de datos, definiendo los tipos de registros. Tienen un número determinado de campos con una longitud fijada. ● Multidimensional: la estructura de datos contenida en la base de datos está mezclada con los propios datos. Es útil para fuentes de datos basadas en la web y para relacionar bases de datos de diferentes tipos.	ERD, Dic
Relacional	● Relacional: los datos están segmentados con la ayuda de tablas. Se emplea <i>Structured Query Language</i> (SQL) como su lenguaje canónico de base de datos. ● Modelo de entidades-relación: describe la relación entre cosas de interés en un dominio de conocimiento. Un modelo básico ER está compuesto por tipo de entidades y especifica las relaciones que pueden existir entre estas entidades. ● Modelo de datos relacional extendido (ERDM) es un híbrido del modelo relacional añadiendo funcionalidades de modelos orientados a objetos.	ERD, Dic
Basado en objetos	● Modelos orientados a objetos: consiste de objetos que poseen sus características y métodos. Estos modelos se pueden considerar que son post relacionales debido a que no se limitan a tablas aunque las empleen. ● Modelo dato por contexto: este modelo incorpora varios modelos de datos según se necesitan, como relacional, orientado a objetos, semi estructurado entre otros. Este modelo permite varios tipos de usuarios que se diferencia en el modo de interactuar con la base de datos	UML ER
NoSQL	● Modelo de grafo. Se emplea una estructura de grafo con nodos, aristas y propiedades para representar los datos almacenados. ● Modelo dato multievaluado: Este modelo permite respecto al modelo relacional que cada atributo en lugar de contener un dato unitario almacene una lista de datos. ● Modelo de datos documento: este tipo permite almacenar y gestionar documento o dato semi-estructurados mas que datos atómicos.	Diccionario

Tabla 1.4: Taxonomía de modelos de datos

- **Regresión.** En este problema se desea predecir el valor de una variable continua y conocido el valor de la variable x .
- **Clasificación.** En este problema se debe predecir el valor de la variable cualitativa y a partir de la variable x .

Las técnicas de aprendizaje automático se aplican tanto a datos estructurados como no estructurados. La diferencia esencial es que en los datos estructurados las características x están completamente definidas a partir de los datos iniciales mientras que en los datos no estructurados hay que recurrir a procedimientos para extraer automáticamente estas características. Por ejemplo una fotografía en formato RGB se almacena en tres matrices, las cuales deben ser sometidas a operaciones matemáticas, como la de convolución, para poder extraer las diferentes características a emplear.

Estos tres modelos matemáticos, en función del tipo específico de dato, representan una tipología de problema. Figura 1.5 sintetiza los principales tipos de extracción de información obtenidos de datos no estructurados. Estas técnicas se clasifican en función del tipo de dato usado: texto, imágenes, audio y vídeo. El análisis de cada tipo de dato no estructurado es en sí una disciplina distinta apareciendo el denominado procesamiento del lenguaje natural o minería de texto (texto), reconocimiento del habla (audio), reconocimiento de imágenes y procesamiento de vídeos.

- Aplicación en el análisis de **texto** incluyen:

1. **Análisis de sentimientos.** Estas técnicas analizan automáticamente el texto en busca del sentimiento de quien lo escribe (positivo, negativo, neutro, etc.) Estas técnicas permiten a las empresas analizar miles de reseñas en línea o comentarios en las redes sociales sobre ciertos productos en cuestión de minutos. En un primer paso clasifican los productos/servicios por categorías (características, envío, servicio de atención al cliente, etc.) y luego determinan si las opiniones de los clientes son positivas o negativas.
2. **El reconocimiento de entidades con nombre.** En esta tarea se busca localizar e identificar las entidades con nombre dentro de un texto en categorías predefinidas como organizaciones, lugares, valores monetarios, abreviaturas, etc.
3. **Extracción de eventos.** Ejemplos de estas tareas son detectar si los eventos del mundo real han sido reportados en artículos y posts o el seguimiento de acontecimientos similares en diferentes textos.
4. **Extracción de relaciones.** Aplicaciones de este problema es la construcción de una base de datos con las interacciones entre fármacos a partir del análisis de texto bruto, o la determinación de relaciones entre personas con el objetivo de construir una base de conocimiento.

- En el análisis de **imágenes** algunos de los problemas estudiados son:

- 1. *Extracción de textos y objetos*, como la matrícula de un vehículo o determinar la existencias de células cancerígenas en una imagen médica.
- 2. *Entendimiento de imágenes*. Ejemplos en esta categoría son la clasificación semántica de las imágenes.
- 3. *Análisis de imágenes geoespaciales* que van desde la distribución de cultivos a la localización de la pobreza.
- 4. *Reconocimiento facial*, permite identificar la persona de una fotografía.

• Respecto al **audio**:

- 1. *Sistemas de reconocimiento de audio* que transforme el audio a formato de texto. Sistemas como Google Assistant, Siri, Alexa, Cortana, etc. implementan este tipo de sistemas.
- 2. *Extracción de características*. El habla contiene características prosódicas como el tono, velocidad, calidad, etc y su extracción suministra información sobre el emisor del mensaje. Hay sistemas que extraen estas características de las conversaciones en tiempo real.

• En el análisis de **videos** destacan:

- 1. *Creación de resúmenes automáticos* en formato de texto o de imágenes en los que se identifican los momentos más destacados, por ejemplo, momentos en los el público aplaude o se pronuncian ciertas palabras clave. Estas técnicas permiten la navegación sobre los vídeos como si se trataran de colecciones de documentos escritos. También permiten la generación automática de subtítulos.
- 2. *Reconocimiento de lugares, objeto o acciones*. Ejemplos de esta categoría son el reconocimiento automático de una infracción de tráfico o el allanamiento de la morada en un sistema de videovigilancia.



Extracción de información			
Texto	Imágenes	Audio	Video
• Análisis de sentimientos • Entidades con nombre • Extracción eventos • Extracción de relaciones	• Extracción de textos y objetos • Entendimiento de imágenes • Análisis de imágenes geoespaciales • Reconocimiento facial	• Reconocimiento de audio • Extracción de características	• Creación de resúmenes automáticos • Reconocimiento de lugares, objetos o acciones

Figura 1.5: Clasificación de técnicas de extracción de información en datos no estructurados.

1.3.4. Visualización

En el proceso de obtener información de los datos, la última etapa es la llamada visualización, esta debe ser entendida como una capa entre los resultados obtenidos y el decisor de modo que se facilite la **interpretación** y **evaluación** de los resultados.

La visualización es mucho más que una herramienta para **comunicar** resultados de una forma rápida y objetiva, esta permite además **descubrir** y **comprender** los patrones que se encuentran detrás de un conjunto de datos.

Los métodos de visualización fueron originalmente usados en datos estructurados, correspondiendo cada dato a un único punto a visualizar. Muchos de estos conjuntos de datos eran el resultado de realización de encuestas las cuales eran realizadas para estudiar un determinado fenómeno. La visualización de datos era una parte más del proceso para corroborar hipótesis sobre fenómeno a estudiar, buscando fundamentalmente explicar los datos existentes y realizar predicciones sobre nuevos datos. Con la irrupción de BD, se ha expandido estos propósitos introduciendo aspectos exploratorios y descubrimiento de patrones, apareciendo aspectos como:

- **Resumir** bases de datos masivas para facilitar la toma de decisiones.
- **Identificación interactiva de patrones**, extrayendo de datos altamente dimensionales estructura simplificadas.
- **Identificación de datos** relevantes para un determinado fenómeno.

La aparición de los datos no estructurados en la era de BD ha conducido a que las técnicas de visualización deban abordar las características de las 3 Vs inherentes en su definición:

1. **Volumen.** La gran cantidad de datos requiere a los métodos tener la posibilidad de la **identificación** de datos relevantes al fenómeno en cuestión. Un aspecto esencial es determinar el nivel adecuado de agregación que visualice los aspectos esenciales.
2. **Variedad.** Debido a la existencia de datos no estructurados provenientes de múltiples fuentes se requiere la **integración** de los mismos en una visión de análisis.
3. **Velocidad.** Exige la recolección y análisis en tiempo real, exigiéndoles a los métodos la **inmediatez** pero a la vez generando información útil a la organización.

Los **cuadros de mando integrales** son visualizaciones que permiten monitorizar los parámetros esenciales de la empresa y disponer de una imagen en tiempo real de lo que ocurre dentro y fuera de la misma. Realmente son más que herramientas de visualización de datos, es una metodología de gestión estratégica utilizada para definir y hacer seguimiento a la estrategia de una organización, de tal forma que permita describir, comunicar y medir la estrategia y evaluar los resultados.

El método más sencillo para personalizar un cuadro de mando es el uso de asistentes de configuración que utilizan interfaces gráficas de usuario que facilitan la selección de los **widgets** y de los datos a mostrar, ver figura 1.6, de tal forma que mejor ajusten a las necesidades de los usuarios finales. Se podría llegar a pensar incluir los cuadros de mandos integrales como una herramienta de visualización de datos pero realmente la implementación de un cuadro de mando integral requiere seguir el proceso completo mostrado en la Figura 1.4. Una vez que la dirección de la organización traduce la estrategia en objetivos relacionados (factores clave del éxito), medidos a través de indicadores KPI y ligados a unos planes de acción, se comenzaría el análisis de todo el sistema informático para el diseño y construcción del cuadro de mando.

Las características esenciales para el diseño de un cuadro de mando son:

1. **KPIs:** se debe seleccionar los KPIs esenciales (entre 7 y 10) para el negocio.
2. **Visualización:** deben ser fácilmente interpretables, hablar el mismo lenguaje del decisor y su representación gráfica la adecuada para los datos que representa y visualmente atractivos.
3. **Análisis:** además de las KPIs el cuadro de mando debe acompañar de un análisis sobre lo ocurrido, recomendaciones y su potencial impacto sobre el negocio.




Figura 1.6: Flujo de trabajo para la elaboración de cuadros de mando

Bibliografía

- [HFG⁺19] Dirk Helbing, Bruno S Frey, Gerd Gigerenzer, Ernst Hafen, Michael Hagner, Yvonne Hofstetter, Jeroen van den Hoven, Roberto V Zicari, and Andrej Zwitter. *Will Democracy Survive Big Data and Artificial Intelligence?*, pages 73–98. Springer International Publishing, Cham, 2019.
- [McD09] John H. McDonald. *Handbook of Biological Statistics*. Sparky House Publishing, 2009.
- [WSM20] Martin Wiener, Carol Saunders, and Marco Marabelli. Big-data business models: A critical literature review and multiperspective research framework. *Journal of Information Technology*, 35(1):66–91, 2020.