

Sistemas de Big Data

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



**Sistemas de
Big_Data**

Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

3

Capítulo

Estructuración de datos para el análisis en entornos Big Data

José Ángel Olivas Orela

Hoy en día es frecuente ver en todos los medios de comunicación y en otros ámbitos hablar a todas horas de inteligencia artificial, en la mayoría de los casos vinculándola únicamente al procesamiento y análisis de datos. Si se analizan con rigor lo que pretende y los orígenes de esta disciplina, esta concepción es una simplificación peligrosa que puede llevar a equívocos en la sociedad general. En primer lugar, en IA nada es tan nuevo como a veces se transmite o pueda parecer. Los modelos y técnicas más de moda en este momento surgen hace ya varias décadas y apenas han sufrido variaciones desde su concepción. Por ejemplo, los modelos basados en redes neuronales artificiales, en particular los denominados de “Deep learning”, tienen su origen en propuestas presentadas en los años siguientes a la segunda guerra mundial, y los algoritmos de aprendizaje que utilizan fueron desarrollados en las décadas de los 80 y 90 del siglo pasado. Los “Random Forest” son desarrollos de la misma época del profesor de estadística de la UC Berkeley, Leo Breiman (fallecido en 2005) y presentados en el año 2001. Realmente no hay nuevos paradigmas en la IA en los últimos 30 años. Lo que sí supone un cambio sustancial es el aumento de la potencia computacional y la capacidad de manipular a grandes volúmenes de datos, el fenómeno en que nos centramos y que se suele denominar Big Data. Esto nos lleva a que estas técnicas, que en el momento de su presentación no eran tan eficientes ahora sí lo sean, lo que permite que puedan ser aplicadas a grandes volúmenes de datos o a sistemas muy complejos en tiempos de computación mucho más razonables.

Pero no sólo se hace IA a partir de datos. El “aprendizaje automático” (Machine Learning) es sólo una parte de la IA. Además, este “aprendizaje” poco tiene que ver con cómo aprendemos los humanos, simplemente suele consistir en escalar operaciones estadísticas básicas sencillas a un conjunto grande de datos (estructurados, numéricos y normalizados...) lo que permite generalizar regularidades numéricas entre los mismos, encontrar patrones de comportamiento. Esto nos lleva al gran el

cuello de botella de los algoritmos de aprendizaje automático: no es fácil (ni posible) representar una situación real solamente con datos numéricos estructurados y normalizados, que es la única entrada que permiten estos métodos computacionales. Por lo tanto, no es equivalente IA a aprendizaje automático, y mucho menos a deep learning.

$$IA \neq ML \neq DL \quad (3.1)$$

Se deben tener en cuenta otros modelos de simulación de la inteligencia humana, provenientes de áreas como la lógica, la lingüística, la sociología, la antropología social, la filosofía o la psicología cognitiva, como por ejemplo modelos de:

- Razonamiento, inferencia.
- Incertidumbre, imprecisión.
- Causalidad, heurística, categorización conceptual, almacenamiento de experiencias.
- Abstracción, lenguaje natural.
- Sentimientos, emociones.

Por ello hay otras áreas de la IA (que se desarrollan en otros módulos y temas) en las que se debe profundizar y a las que se debe prestar más atención, y no solo a las que proceden de la matemática y la estadística:

- Ingeniería del conocimiento.
- Procesamiento de Lenguaje Natural, PLN.
- Reconocimiento de patrones.
- Razonamiento aproximado, inferencia.
- Modelos causales, heurísticas, representación del conocimiento, almacenamiento de experiencias.

...que no dejan de estar profundamente vinculadas con el ‘Big Data’ (aprovechamiento inteligente de datos masivos). Se deben desarrollar sistemas de IA que tengan en cuenta las datos existentes sobre el fenómeno a tratar (en el caso de existir, siempre incompletos y muchas veces inexactos, sesgados, con ruido...) pero también el conocimiento humano sobre ese dominio, las hipótesis, interpretaciones y heurísticas de los expertos en ese campo y otros muchos elementos ‘cognitivos’ más, crear sistemas ‘sofisticados’ que simulen el razonamiento humano, y no sólo aplicar técnicas estadísticas básicas que nos permitan distinguir automáticamente fotografías de “perritos” de las de “gatitos” con un alto porcentaje de aciertos, pero con un coste computacional muy alto, tarea que un niño de pocos años hace con una tasa nula de error y sin ser considerado especialmente “inteligente”.

Para profundizar en estos temas, pueden ser recomendables el libro de 2019 de Melanie Mitchell: “*Artificial Intelligence: A Guide for Thinking Humans*” [1], que habla por ejemplo de cómo la IA tuvo y sigue teniendo el problema del “burro y el palo con la zanahoria”, en los cincuenta la gente decía que en cuestión de 10, 15, 25 años íbamos a tener una inteligencia artificial completa y capaz de remplazar al ser humano en todos los empleos, y así sucesivamente, que la IA no es tan lista y que infravaloramos la complejidad de la mente humana, o el artículo de agosto de 2020 de investigadores de universidades de Finlandia y Austria titulado “Artificial Intelligence: A Clarification of Misconceptions, Myths and Desired Status” [2], en el que los autores presentan diversos mitos y errores en la concepción actual de la IA en esta línea, acerca de la imposibilidad real de crear máquinas que se comporten como humanos ‘óptimos’.

La **Inteligencia Artificial** (IA/AI -siglas en inglés-) se puede ver como la disciplina del ámbito de la computación y los sistemas de información que pretende simular computacionalmente comportamientos humanos que pueden ser considerados como inteligentes. Hay diversas ramas dentro de la IA, como la Visión Artificial o la Robótica, En este tema nos centraremos en el análisis inteligente de datos en entornos Big Data, en el marco de la Inteligencia de Negocio (*Business Intelligence*)

Cuando se tienen en cuenta datos, por ejemplo historias clínicas de los pacientes, casos anteriormente tratados, registros de incidencias de enfermedades, datos de factores que pueden provocar determinadas dolencias (por ejemplo medioambientales, hábitos sociales...), entonces es necesario recurrir a lo que en IA se llaman técnicas de aprendizaje automático o *Machine Learning* y, por supuesto, técnicas provenientes de la matemática y la estadística, como por ejemplo las de Regresión (formalización de una relación significativa entre dos o más variables para calcular pronósticos a partir del conocimiento de los valores en un individuo concreto).

Muchas de estas técnicas se pueden englobar tanto en estadísticas como de Machine Learning: rama de la Inteligencia Artificial en la que se diseñan mecanismos para dotar a los sistemas computacionales de capacidad de aprendizaje, en el sentido de la capacidad de descubrir **regularidades (patrones)** en datos o situaciones anteriores y aplicarlos a nuevos problemas o situaciones análogas.

Se comienza por el origen, los datos, estableciendo inicialmente las diferencias entre datos, información y conocimiento, qué tipos de datos se suelen manejar, cómo se consiguen y dónde se almacenan habitualmente, introduciendo el concepto de “lago de datos”, y se enmarcan en lo que hoy se denomina “Inteligencia de Negocio”. Se presenta una crítica sobre cómo se suele afrontar habitualmente el análisis de datos, que nos permita reflexionar sobre en qué grado se suelen hacer las cosas de una forma adecuada. A continuación, se describen los diferentes tipos de análisis, distinguiendo por ejemplo entre conceptos como “predicción” y “pronóstico”. Se presenta el papel del “científico de datos” y se hace una descripción de qué métodos resultan más adecuados para afrontar cada uno de los diferentes tipos de retos que suelen presentarse.

3.1. Origen: Los Datos

3.1.1. Datos, información, conocimiento

Como ya se ha visto anteriormente, debemos distinguir claramente entre **datos** (contenido bruto), **información** (resúmenes, datos “presentables”) y **conocimiento** (mayor nivel de abstracción que nos permite tomar decisiones ante nuevas situaciones). Habitualmente hoy en día la gestión de datos se queda en un análisis descriptivo, es decir, la visualización de gráficos o lo que se suelen llamar “cuadros de mandos” o “*dashboards*”, que veremos detalladamente en el próximo tema, que ayudan a la persona responsable a tomar decisiones. Por ejemplo, esto puede venir muy bien en un entorno médico, porque permite a los profesionales tener una información más completa y procesada de los pacientes, historias clínicas, pruebas... para poder tomar decisiones. Pero no debemos quedarnos ahí, se debe ir hacia la analítica predictiva y prescriptiva, modelos que permitan extraer conocimiento a partir de los datos y la información que podamos usar para mejorar sustancialmente la práctica clínica.

3.1.2. Tipos de datos

Como hemos visto, de forma resumida las diferentes organizaciones y empresas suelen clasificar los datos según su origen y tipo de la siguiente forma:

- **Fuentes de datos:** Donde se originan los datos, habitualmente se consideran las siguientes:
 - *Externas:* no dependen directamente de la organización. Muchas veces puede haber problemas y limitaciones para su uso o acceso, y en otros casos pueden resultar caros.
 - *Internas:* dependen directamente de la organización, no suele haber problemas y limitaciones para su uso o acceso, y normalmente no suponen ningún tipo de coste para la organización.
- **Tipos de datos:** Normalmente se suele hablar de datos:
 - *Estructurados:* datos con formato o esquema fijo que poseen campos fijos. Por ejemplo las clásicas bases de datos relacionales. Suelen ser los más usados como origen de los procesos de Minería de datos.
 - *Semi-estructurados:* no tienen formato fijo pero contienen etiquetas u otros marcadores que permiten separar los diferentes elementos, por ejemplo: los Weblogs o algunos campos de tipo texto en muchas bases de datos.
 - *No estructurados:* también se suelen denominar desestructurados. Datos sin tipo predefinido. Se almacenan como documentos u objetos sin una estructura uniforme, por ejemplo: documentos de texto o multimedia.

Por lo tanto, se puede establecer una taxonomía básica inicial de los tipos de datos que suelen ser considerados en Inteligencia de Negocios (Business Intelligence), principalmente para los procesos de Análisis:

- **Datos Internos estructurados:** Suele ser la categoría más abundante y mejor entendida actualmente en las organizaciones, pero cada vez parece más necesario cambiar el enfoque hacia los datos externos desestructurados. Como ejemplos se pueden considerar los Perfiles Web, registros de clientes, usuarios, inventario, recursos humanos, financieros, ventas...
- **Datos Externos estructurados:** Extensión de los anteriores, pero con restricciones de existencia, disponibilidad y accesibilidad. Como ejemplos se pueden considerar los historiales de créditos o viajes, registros de morosos, censales, telefónicos...
- **Datos Internos no estructurados:** Pueden suponer una excelente fuente para extraer conocimiento y un buen campo de pruebas para las técnicas y herramientas analíticas. Como ejemplos se pueden considerar cualquier tipo de documentos de texto o multimedia, datos de sensores, foros, comentarios en las propias webs...
- **Datos Externos no estructurados:** La mayor área de estudio y oportunidad actualmente, sobre todo para recoger las opiniones de los consumidores y usuarios. Como ejemplos se pueden considerar los sensores externos, blogs y todas las consideradas “redes sociales” (social media): Twitter, Facebook, Instagram, Google+...

También hoy en día es frecuente hablar de Bases de datos relacionales o SQL frente a las No SQL. En las primeras, el volumen de los datos si crece lo hace poco a poco y de forma previsible y controlada, las necesidades de proceso se suelen poder asumir en un único servidor y no suele haber picos de uso del sistema imprevistos. En las segundas el volumen de los datos puede crecer puntualmente de forma descontrolada o no prevista, las necesidades de proceso tampoco se pueden prever y se pueden tener picos de uso del sistema en diferentes ocasiones.

3.1.3. Cómo se consiguen y dónde residen los datos

Los datos se pueden conseguir o generar de muy diferentes formas. Entre las más habituales podríamos destacar las siguientes:

- **Sistemas Transaccionales:** operadores que recogen las peticiones a través de Call-Centers...
- **Transacciones:** operadores que recogen las peticiones a través de Call-Centers...
- **Los sensores:** permiten capturar las magnitudes físicas o químicas y convertirlas en datos, por ejemplo: temperatura, luz, distancia, aceleración, inclinación, desplazamiento, presión, fuerza, humedad, sonido, movimiento o el pH.

■ **Redes sociales, etc.**

Es interesante destacar la relevancia actual de la adquisición, manejo, transmisión, uso y almacenamiento de lo que se suelen denominar **Datos en Tiempo Real** (Real Time Data). Se producen en tiempo inmediato, algunos provienen de sensores y muchos suelen ser no estructurados (por ejemplo, los provenientes de redes sociales), lo que provoca diversas necesidades específicas y problemas para su tratamiento.

Hasta hace muy pocos años, cuando se hablaba de “bases de datos”, los profesionales del ámbito podían tener una idea bastante aproximada y conocimiento sobre casi todos los soportes y herramientas existentes, porque eran relativamente pocas y conocidas. En los últimos años ha habido una explosión en tipos, herramientas y productos disponibles, los que imposibilita un conocimiento completo de los mismos y obliga a los profesionales a una actualización permanente y muy rápida en estas tecnologías. Cada día aparecen nuevos sistemas de soporte para diferentes bases de datos. Sirvan como ejemplos:

- **Bases de datos documentales** (*Document Databases*): *MarkLogic, Couchdatabase, MongoDB...*
- **Bases de datos de columna ancha** (*Wide Column Stores*): *Aerospike, Redis, Riak, Amazon DynamoDB...*
- **Bases de datos gráficas** (*Graph Databases*): *Neo4j, Infinite Graph...*
- **Bases de datos Valor-Llave** (*Key-Value Databases*): *Accumulo, Hypertable, Cassandra, Apache Hbase, Amazon SimpleDB...*




Figura 3.1: Diferentes tipos de Bases de Datos. Fuente: <http://www.aryannava.com>

Esta gran diversidad de sistemas de almacenamiento para los muy variados tipos de datos provoca que cada vez sea más importante y usado el concepto de **Lago de Datos** o *Data Lake*, que podríamos describir como un repositorio para grandes cantidades y variedades de datos, tanto estructurados como no estructurados. El lago acepta entradas desde diversas fuentes y puede preservar tanto la fidelidad de los datos originales como las diversas transformaciones que se les van haciendo, incluso simultáneamente desde diferentes departamentos, lo que puede generar diferentes evoluciones en paralelo de los mismos datos originales, por ejemplo desde el departamento de publicidad y del de ventas. Los programadores podrían actuar directamente sobre los datos que se están transmitiendo para una analítica en tiempo real. El lago puede servir como zona de montaje del *Data Warehouse*, la ubicación de los datos tratados con más cuidado para reportes y análisis en modo *Batch*.

Por lo tanto, se debe abandonar la forma clásica de partir únicamente de una base de datos relacional (y habitualmente numérica) para un determinado proceso de análisis de datos, que es lo que se hace casi en la totalidad de los casos en la actualidad, y comenzar a pensar en usar como origen un contenido más amplio y heterogéneo del *Data Lake*.




Figura 3.2: ¿Qué es un “Lago de datos”?

Esto, desde mi punto de vista, provoca la necesidad de evolucionar desde lo que se suele hacer ahora, un mero análisis estadístico o con una única técnica de aprendizaje automático sobre una única base de datos numérica hacia una Minería de Datos que parta de un conjunto de datos variado y heterogéneo y que use diversas técnicas en diferentes momentos con el objetivo de obtener un conocimiento común, según los objetivos que se pretendan conseguir. Pero esto no es una tarea fácil, requiere un extenso conocimiento sobre tipos de datos y su tratamiento, técnicas de análisis e Ingeniería del Conocimiento. Quizá esta debería ser la formación requerida para un auténtico “*Científico de Datos*” o en común del equipo de análisis. Pero creo que actualmente la realidad en las organizaciones dista mucho de esta concepción.

3.2. Analítica de Datos

3.2.1. ¿Qué se entiende habitualmente por analítica de datos?

La “analítica de datos” [3] se suele enmarcar como una parte esencial de lo que se denomina “Inteligencia de Negocio” (*Business Intelligence, BI*) y se suele definir como la capacidad de transformar datos [4] en información para ayudar a gestionar una empresa, que consiste en los procesos, aplicaciones y prácticas que apoyen la toma de decisiones ejecutivas. La BI se suele dividir en dos grandes grupos:

- **BI Operacional:** trata los informes estándar, descripciones de los datos (información), funciones al nivel operacional con los trabajadores, clientes, usuarios, socios...
- **BI Analítica y Táctica/Estratégica:** pretende dar soporte a los ejecutivos y a los gestores en niveles tácticos que contribuyen a la estrategia global de la empresa o institución. Suele contemplar análisis estadístico, modelos predictivos y de extrapolación, pronósticos, optimización...

Como ejemplos de soluciones BI se pueden mostrar las siguientes en diferentes ámbitos de las instituciones y empresas:

- **Gestión de la Información** (*Information Management*): calidad de datos, Gobierno del dato, ETL (Extraer, Transformar y Cargar)...
- **Informes** (*Reporting*): cuadros de Mando, visualización, movilidad...
- **Analítica avanzada** (*Advanced Analytics*): segmentación, mejor próxima oferta, mantenimiento preventivo, modelos de riesgo...
- **Gestión de proyectos de empresa** (*Enterprise Project Management*): presupuestación y planificación, consolidación financiera, rentabilidad, balances, costes...




Figura 3.3: Tipos de analítica.

La **analítica descriptiva** está orientada a la generación de un resumen claro y fácil de entender de una colección de datos. Este es el fundamento y concepto más básico de todas las estadísticas. Se centra en la Visualización de datos para entender el pasado y el presente. Se describen los datos con tablas o gráficos, mostrando descripciones numéricas de la variabilidad y la posición. También se suele llamar modelización descriptiva. Para el **análisis predictivo** se suele usar:

- Extrapolación de funciones (tendencia para el futuro, pero no hay capacidad de pronóstico, hechos/cambios puntuales).
- Correlaciones entre variables (demasiado evidente, no suele funcionar de forma muy fina).
- Encontrar patrones en los datos que puedan ser aplicados a situaciones futuras (KDD Knowledge Discovery in Databases y Minería de Datos) [5, 6, 7].
- Métodos de CLUSTERING Y CLASIFICACIÓN.
- Extrapolación de funciones (por ejemplo, estimaciones o líneas de tendencia).




Figura 3.4: Extrapolación de funciones (Por ejemplo: Estimaciones o Líneas de Tendencia).

Dentro del análisis predictivo juega un papel fundamental el **Análisis de Series temporales**. Se suelen clasificar en:

- Estacionarias (medias y/o variabilidad se mantienen constantes).
- No Estacionarias (medias y/o variabilidad NO se mantienen constantes, cambios de varianza/tendencias).

También es importante señalar qué otros métodos se usan para otras diferentes necesidades en el análisis de series temporales:

- Tendencias: método de Mínimos cuadrados. Tendencias evolutivas. Diferenciación estacional.
- Predicción: alisadores exponenciales.
- Interpolación: Predecir datos faltantes.



Figura 3.5: Ventajas competitivas de los diferentes tipos de analítica. Fuente: Davenport & Harris (2007).

El análisis predictivo se centra en un escenario futuro. El **prescriptivo** se centra en múltiples alternativas. Por lo tanto, un modelo prescriptivo puede ser considerado como una combinación de modelos predictivos (uno por cada posible escenario) que se ejecutan en paralelo. El objetivo es encontrar la mejor opción posible: OPTIMIZACIÓN. Por ejemplo, la elección del tratamiento más adecuado en oncología. Las principales técnicas usadas son:

- Técnicas de Investigación Operativa
- Algoritmos Genéticos
- Técnicas estocásticas
- Metaheurísticas
- Etc.

3.2.2. Tipos de salidas: predicción, pronóstico...

Conviene distinguir entre **predicción** (prediction) y **pronóstico**. Aunque es frecuente su uso de forma inversa según los campos de aplicación, en estadística la segunda tiene que ver con la estimación, con la extrapolación, continuidad, por ejemplo, podemos estimar (pronosticar) cuántos habitantes tendrá Madrid en 2025 en base a la tendencia demográfica. En cambio, en otros dominios el pronóstico consiste en anticiparse a un hecho puntual en base a un conjunto pequeño de alternativas, por ejemplo, en el reverso del impreso de una quiniela de fútbol pone “marque con una X su pronóstico” y las alternativas son 1-X-2, o un terremoto se debe pronosticar en base a las alternativas SI-NO. Los sistemas para abordar una u otra opción son claramente distintos. Los primeros se basan en la extrapolación y los segundos en una serie de características para anticiparse al hecho puntual (por ejemplo, en las quinielas saber si alguno de los equipos se juega algo importante como el descenso, si hay un jugador importante lesionado o quién va a ser el árbitro del partido).

Esta distinción tiene una fuerte repercusión en el tipo de sistemas inteligentes a desarrollar: los de estimación, cuando los fenómenos y los datos que los describen siguen una tendencia, es suficiente con el uso de técnicas estadísticas o de aprendizaje automático de las anteriormente citadas. En cambio, cuando debemos anticiparnos a hechos puntuales que suponen una ruptura de la tendencia es necesario el uso de técnicas más cognitivas, por ejemplo, acudir a conocimiento de expertos o métodos que consideren relaciones causales en fenómenos anteriormente descritos, por ejemplo electorales y sean capaces de extrapolar estas relaciones a situaciones futuras en las condiciones específicas actuales.

3.2.3. Adecuación de los métodos a los problemas

La **analítica descriptiva** está orientada a la generación de un resumen claro y fácil de entender de una colección de datos. Este es el fundamento y concepto más básico de todas las estadísticas. Se centra en la **Visualización** de datos para entender el pasado y el presente. Se describen los datos con tablas o gráficos, mostrando descripciones numéricas de la variabilidad y la posición. También se suele llamar **Modelización descriptiva** y se suele plasmar en los “cuadros de mando” o dashboards, que estudiaremos en el tema siguiente.

Para el **análisis predictivo** se suele usar:

- **Extrapolación de funciones** (tendencia para el futuro, pero no hay capacidad de predicción real, hechos/cambios puntuales), por ejemplo Estimaciones o Líneas de Tendencia.
- **Correlaciones** entre variables (demasiado evidente, no suele funcionar de forma muy fina).
- Encontrar **patrones** en los datos que puedan ser aplicados a situaciones futuras (**KDD** y Minería de Datos).

- Métodos de **CLUSTERING Y CLASIFICACIÓN**.

Dentro del análisis predictivo juega un papel fundamental el **Análisis de Series temporales**. Se suelen clasificar en:

- **Estacionarias** (medias y/o variabilidad se mantienen constantes).
- **No estacionarias** (medias y/o variabilidad NO se mantienen constantes, cambios de varianza/tendencias).

También es importante señalar qué otros métodos se usan para otras diferentes necesidades en el análisis de series temporales:

- **Tendencias:** método de Mínimos cuadrados. Tendencias evolutivas. Diferenciación estacional.
- **Predicción:** alisadores exponenciales:
 - Alisado exponencial simple
 - Alisado exponencial lineal de Holt
 - Alisado exponencial estacional de Holt-Winters
- **Interpolación:** Predecir datos faltantes.

3.2.4. Herramientas actuales (en entornos Big Fata) para implementar estas soluciones

El crecimiento exponencial de generación de datos en todos los ámbitos de la ciencia y la sociedad ha dado lugar al fenómeno denominado Big Data: capacidad de gestionar (almacenar, acceder, procesar, interpretar, transmitir, analizar. . .) grandes volúmenes de datos que exceden las capacidades de lo que podríamos denominar “software convencional” para hacerlo. Estos datos pueden proceder de muy diversas fuentes como sensores (*IoT Internet of Things, Smart Cities. . .*), redes sociales, bases de datos de pacientes, estudios epidemiológicos. . . Son de naturaleza heterogénea, lo que hace necesario usar nuevas herramientas para poder gestionarlos, frente a lo que habitualmente se almacenaba en bases de datos relacionales (estructuradas) tradicionales. Como se ha comentado, se suele hablar de “data lake” refiriéndose a un repositorio para grandes cantidades y variedades de datos, tanto estructurados como no estructurados. Consisten en nuevos modelos de bases de datos, como *mongoDB, InfiniteGraph, amazonDynamoDB, apacheHBASE, Cassandra, etc.* que permiten cumplir estas funciones.

Para ello, hoy en día hay diversos “ecosistemas” Big Data, como *Spark* (apache) o los de Google, IBM, amazon o Microsoft, que permiten combinar bases de datos avanzadas con herramientas de procesado. Para visualización son muy usadas herramientas como QlikView (<http://global.qlik.com/>), Microsoft Power BI (<http://powerbi.microsoft.com/>) o Tableau (<http://www.tableau.com>). Pero, como

se ha dicho, se debe tender a la predicción y prescripción, como proponen empresas como Microstrategy (<https://www.microstrategy.com/es>). Aunque existen muchas herramientas que lo pretenden (aquí se puede ver un análisis de las 52 mejores <https://www.predictiveanalyticstoday.com/top-predictive-analytics-software/>), la única forma de hacerlo “a medida” para sistemas de ayuda a la decisión tan complejos es acudiendo a la figura del “científico de datos” (data scientist), que, como se describe en este documento, debe poseer conocimientos de computación, bases de datos, Inteligencia Artificial, Aprendizaje Automático, estadística, visualización, reconocimiento de patrones, KDD y Minería de Datos... y es una figura muy demandada y escasa en ambientes profesionales, científicos o académicos, que debe ser capaz de seleccionar y guiar las herramientas y técnicas más adecuadas para cada problema y objetivos concretos.



Figura 3.6: Relación/diferencias entre BI y Big Data.

Por último, es importante resaltar que en los entornos de Big Data se suelen usar tanto lenguajes de programación específicos (R, Scala, Python...) como librerías que permiten implementar todas las técnicas que se describen. Entre ellas, podemos destacar Mahout (Scalable Machine Learning and data mining, <http://mahout.apache.org/>), MLlib (Apache Spark's scalable machine learning library <https://spark.apache.org/mllib/>) o H2O (<https://www.h2o.ai/>).

Se profundiza en estos aspectos en otros temas/módulos de este Programa.

3.2.5. Críticas sobre la percepción habitual del análisis de datos: se debe ir hacia un análisis ‘inteligente’ de datos

Desde mi punto de vista, la visión habitual de las posibilidades y expectativas de la BI es demasiado restringida, y mucho más las prácticas habituales en las empresas e instituciones. Cuando se habla de “transformar datos en información”, “apoyen la toma de decisiones” son expresiones muy imprecisas y ¡hay muchas otras cosas que se pueden hacer!

Si nos fijamos en las posibles salidas propuestas, vemos que de nuevo es demasiado restringido. Normalmente la “información” es solo “visualización”, es decir, una forma de representar datos originales que están en bruto de una forma más ordenada y resumida, por ejemplo en un gráfico. Pero esto es muy poco “inteligente” y al final es el que lo hace el responsable de tomar las decisiones, basándose en esta información de la que dispone, y la calidad de estas decisiones dependerá exclusivamente de la capacidad y preparación del decisor.

Por ello, creo que se debe tender a generar y manejar “conocimiento” en el sentido anteriormente descrito. Se pueden diseñar sistemas sofisticados de muy diversos tipos, como los Sistemas de Ayuda a la Decisión (DSS), los Sistemas Recomendadores (Recommender Systems) o el Análisis de series temporales (Predicción vs Pronóstico), por ejemplo, para tareas automáticas de Segmentación, recomendación de otros productos, pronóstico de terremotos, incendios u otros fenómenos naturales, puntos de inflexión en la bolsa o el cambio de moneda... y solo las grandes empresas punteras se esfuerzan en diseñar sistemas de este tipo.

Todo ello pasa por encontrar regularidades en los datos o su evolución (¡patrones!), y ser capaz de formalizarlos o expresarlos de alguna forma computable para que puedan ser usados por estos sistemas. Las salidas esperadas deben condicionar todo el proceso de análisis de datos. Por ejemplo, no se diseña de la misma forma un sistema de predicción que uno de pronóstico. Pero la práctica habitual es ir “a ciegas” hacia delante, es decir, partir de los datos más o menos en bruto y aplicarles algún algoritmo o herramienta de análisis (por ejemplo: estadística o de aprendizaje automático) y tratar de interpretar la salida de este procedimiento por si puede ser útil. Creo que este es un enfoque erróneo del análisis y minería de datos y suele ser el más habitual.

3.2.6. El científico de datos, la profesión más demandada.

Hoy en día el “científico de datos” (*data scientist*) es una figura muy demandada y escasa en ambientes profesionales, científicos o académicos que, como se esboza en este documento, debe poseer conocimientos de computación, bases de datos, Inteligencia Artificial, Aprendizaje Automático, estadística, visualización, reconocimiento de patrones, sociología, psicología, KDD y Minería de Datos... y que debe ser capaz de seleccionar y guiar las herramientas y técnicas más adecuadas para cada problema y objetivos concretos. Es por ello por lo que no es frecuente ni fácil encontrar profesionales con este perfil tan completo. La mejor forma de paliar esta dificultad debería ser la formación de equipos multidisciplinarios que cubran todas estas necesidades, pero esto tampoco es frecuente y por ello gran parte de los proyectos de análisis de datos que llevan a cabo diferentes instituciones y entidades no consiguen los resultados que podrían ser esperados.




Figura 3.7: El científico de datos.

Otro problema frecuente e importante a la hora de desarrollar este tipo de proyectos es la tendencia a aplicar las herramientas, métodos o algoritmos que el equipo mejor conoce (“al que solo dispone de un martillo, todos los problemas le parecen clavos”) de una forma “ciega” sobre las bases de datos de las que se dispone (normalmente sólo sobre una), sin importar en principio cuál es el propósito final de ese análisis de datos. Esta aproximación errónea se podría mejorar en gran medida disponiendo de un buen “científico de datos”, en el sentido anteriormente descrito, capaz de guiar todo el proceso con criterios bien sustentados.

3.2.7. Aplicaciones de Procesamiento de Lenguaje Natural y Minería de texto: Análisis de Sentimientos.

Como ejemplo de **Minería de Texto**, quizá el más relevante es el que tiene que ver con el acceso y la **Recuperación de Información**, tema actualmente muy destacado en las aplicaciones del análisis inteligente de datos en uno de los entornos más prototípicos de Big Data como puede ser Internet y la Web. Es el mejor ejemplo de tratamiento de **Datos No Estructurados**. Se pueden consultar más detalles en el libro “Búsqueda eficaz de información en la Web” [8].

3.2.8. El análisis de sentimientos y opiniones en redes sociales

El análisis de sentimientos o minería de opiniones (opinion mining) es uno de los temas de aplicación más recientes e importantes en el ámbito del análisis inteligente de datos en entornos Big Data. Hoy en día es uno de los campos más relevantes, difíciles y demandados por la repercusión que tiene tanto para las empresas como para la sociedad. El artículo “Sentiment analysis: A review and comparative analysis of web services” [9] ofrece una descripción del estado actual de la investigación y las aplicaciones en análisis de sentimientos y opiniones.

Las técnicas de recuperación de información textual, minería de textos o procesamiento de lenguaje natural (PLN) se suelen centrar en el procesamiento, la búsqueda o la extracción de información objetiva. Los hechos tienen un componente objetivo; sin embargo, también hay otros elementos textuales que expresan características subjetivas. Estos elementos son principalmente opiniones, sentimientos, valoraciones, actitudes y emociones, que son el foco del análisis de sentimientos. Todos ellos están estrechamente relacionados, aunque presentan ligeras diferencias. Esto implica el nacimiento de muchas tareas relacionadas en este nuevo campo de investigación, como la minería de opiniones, el análisis de subjetividad, la detección de emociones o la detección del spam de opinión, entre otros.

El análisis de sentimientos ofrece muchas oportunidades para desarrollar nuevas aplicaciones, especialmente debido al gran crecimiento de las herramientas disponibles, por ejemplo, las recomendaciones sobre los temas propuestos en fuentes como blogs y redes sociales. El sistema de recomendaciones puede funcionar teniendo en cuenta aspectos tales como las opiniones positivas o negativas sobre esos temas o productos. Los sitios web de opiniones pueden recopilar información de diferentes fuentes con el fin de resumir o componer una opinión global sobre un candidato, producto, etc., lo que puede sustituir a los sistemas que requieren explícitamente opiniones o resúmenes.

Los sistemas de pregunta y respuesta representan otro campo en el que las opiniones desempeñan un papel importante. La detección de preguntas sobre opiniones y sus posibles respuestas, así como su tratamiento, son esenciales para generar buenas respuestas. La detección de información subjetiva es realmente importante en campos relacionados con la argumentación en los que las frases objetivas suelen ser

más valiosas. Aun así, uno de los campos más importantes en los que el análisis de sentimientos tiene un mayor impacto es la industria. Pequeñas y grandes empresas, al igual que otras organizaciones, como los gobiernos, desean saber lo que la gente dice sobre sus marcas, productos o miembros.

Como se ha dicho, el análisis de sentimientos es un concepto que abarca muchas tareas, como la extracción de sentimientos, la clasificación de sentimientos, la clasificación de subjetividad, el resumen de opiniones o la detección de spam de opinión, entre otros. Para llevar a cabo cualquiera de estas actividades, el análisis de sentimientos tiene que lidiar con muchos desafíos.

El primero es la definición de los elementos que intervienen. Por lo tanto, es necesario definir claramente conceptos como opinión, subjetividad o emoción, pero esta tarea no es fácil. Por ejemplo, de una manera sencilla, la opinión de un usuario puede ser considerada como un sentimiento positivo o negativo acerca de una entidad o de un elemento de esa entidad. Por otro lado, la subjetividad no implica necesariamente un sentimiento, sino que permite expresar sentimientos o creencias y, específicamente, nuestros propios sentimientos, creencias y emociones.

Estas definiciones tienen que ser formalizadas mediante expresiones matemáticas que puedan ser calculadas y utilizadas como entradas para los algoritmos de IA. Por lo tanto, el éxito del análisis de sentimientos depende principalmente de la capacidad de extraer la información necesaria de esas definiciones a partir de los textos para llevar a cabo esas tareas.

A pesar de la complejidad y la dificultad de este problema, muchas empresas y universidades están desarrollando nuevas herramientas e instrumentos y servicios web que tratan varios de los temas mencionados. Estos servicios podrían incluirse, especialmente para la investigación, en otras aplicaciones o plataformas sin necesidad de ser experto en análisis de sentimientos.

Los términos **minería de opiniones**, **análisis de sentimientos** y **análisis de subjetividad** (opinion mining, sentiment analysis y subjectivity analysis respectivamente) se usan frecuentemente como sinónimos. Sin embargo, sus orígenes no son exactamente los mismos y algunos autores consideran que cada concepto presenta connotaciones diferentes, al igual que otros estrechamente relacionados, como el **análisis afectivo**.

Surgen muchas **tareas vinculadas al análisis de sentimientos**. Algunas de ellas están estrechamente relacionadas y es difícil separarlas claramente porque comparten muchos aspectos. Las más importantes son:

- **La clasificación de los sentimientos.** También llamada orientación de sentimientos, orientación de opinión, orientación semántica o polaridad de sentimientos. Se basa en la idea de que un documento o texto puede expresar una opinión de un titular sobre una entidad y trata de medir el sentimiento de ese titular hacia la entidad. Por lo tanto, consiste básicamente en clasificar las opiniones en tres categorías principales: positivo, negativo o neutro.

- **Clasificación de subjetividad.** Consiste principalmente en detectar si una frase dada es subjetiva o no. Una frase objetiva expresa información factual, mientras que una frase subjetiva puede expresar otro tipo de información personal, como opiniones, evaluaciones, emociones y creencias. Además, las frases subjetivas pueden expresar lo positivo o lo negativo, pero no todas lo hacen. Esta tarea puede ser vista como un paso previo a la clasificación de los sentimientos. Una buena clasificación de subjetividad puede asegurar una mejor clasificación de sentimientos. Incluso se considera como un proceso más difícil que el de distinguir entre sentimientos positivos, neutros o negativos.
- **Resumen de opiniones.** Se centra especialmente en la extracción de las características principales de una entidad compartida en uno o varios documentos y los sentimientos sobre ella. Por lo tanto, se pueden distinguir dos perspectivas en esta tarea: resumen de un solo documento o de varios documentos. La integración de documentos individuales consiste en analizar los hechos presentes en el documento analizado, por ejemplo, cambios en la orientación de los sentimientos a lo largo del documento o vínculos entre las diferentes entidades o características encontradas, y mostrando principalmente aquellos textos que mejor las describen. Por otro lado, en los resúmenes multidocumento, una vez detectadas las características y entidades, el sistema tiene que agrupar y/o ordenar las diferentes frases que expresan sentimientos relacionados con esas entidades o rasgos. Al final puede ser presentado como un gráfico o un texto que muestre las principales características o entidades y cuantifique el sentimiento de alguna manera en cada uno de ellos, por ejemplo, agregando intensidades de sentimientos o contando el número de sentimientos positivos o negativos.
- **Recuperación de opiniones.** Intenta recuperar documentos que expresan una opinión sobre una consulta determinada. En este tipo de sistemas, se necesitan dos puntuaciones para cada documento, la puntuación de relevancia frente a la consulta y la puntuación de opinión sobre la consulta. Normalmente se utilizan ambos para clasificar los documentos.
- **Sarcasmo e ironía.** Se centra en detectar afirmaciones con contenido irónico y sarcástico. Este es una de las tareas más complicadas en este campo, especialmente, debido a la falta de acuerdo entre los investigadores sobre cómo la ironía o el sarcasmo pueden ser formalmente representadas y definidas.
- **Otros.** Además de las actividades mencionadas anteriormente, se pueden destacar otras tareas relacionadas con el análisis de sentimientos, como la detección de género o autoría, que intenta determinar el género o la persona que ha escrito un texto u opinión, o la detección de spam de opinión, que trata de detectar opiniones o reseñas que contienen contenidos no confiables publicados para distorsionar la opinión pública hacia las personas, empresas o productos.

Las **técnicas de IA** que se usan habitualmente se suelen clasificar en cuatro tipos: de aprendizaje automático, basado en diccionarios, estadística y semántica.

Como se ha visto, las técnicas de aprendizaje automático se pueden agrupar en dos categorías principales: técnicas supervisadas y no supervisadas. El éxito de ambos se basa principalmente en la selección y extracción del conjunto apropiado de características utilizadas para detectar sentimientos. En esta tarea, las técnicas de procesamiento del lenguaje natural desempeñan un papel muy importante porque algunas de las características más importantes utilizadas son, por ejemplo:

- Los **términos** (palabras o n-gramas) y su frecuencia.
- La **información** de la **categoría gramatical**. Los adjetivos desempeñan un papel importante pero los sustantivos pueden ser significativos.
- Las **negaciones**, que pueden cambiar el significado de cualquier oración.
- Las **dependencias sintácticas** (análisis de árbol), que pueden determinar el significado de una oración.

Con respecto a las técnicas **supervisadas**, las máquinas de soporte vectorial (SVM), los clasificadores Bayes naïf y la máxima entropía son algunas de ellas, mientras que las técnicas **semisupervisadas y no supervisadas** se proponen cuando no es posible tener un conjunto inicial de documentos u opiniones etiquetados para clasificar el resto de los ítems.




Figura 3.8: Técnicas usadas habitualmente para el análisis de sentimientos. Fuente: [9].

Además, los enfoques híbridos, que combinan técnicas supervisadas y no supervisadas, o incluso técnicas semisupervisadas, pueden ser útiles para clasificar los sentimientos.

Otras se basan principalmente en un léxico de sentimientos, es decir, una colección de sentimientos conocidos y precompilados, términos, frases e incluso modismos, desarrollados para los géneros tradicionales de comunicación, como el Opinion Finder. Estructuras aún más complejas, como ontologías o diccionarios, que miden la orientación semántica de las palabras o frases, pueden ser usadas para este propósito. Aquí se pueden encontrar dos subclasificaciones: enfoques basados en diccionarios y en corpus.

Los enfoques basados en diccionarios se basan generalmente en el uso de un conjunto inicial de términos (semillas), que normalmente se recogen y anotan de forma manual. Este conjunto crece buscando los sinónimos y antónimos en un diccionario. Un ejemplo de ese diccionario podría ser WordNet, que se utilizó para desarrollar un tesoro llamado SentiWordNet. El principal inconveniente de este tipo de enfoques es la incapacidad de hacer frente a orientaciones específicas de dominio y contexto. Aun así, podría ser una solución interesante dependiendo del problema.

Las técnicas basadas en corpus surgen con el objetivo de proporcionar diccionarios relacionados con un dominio específico. Estos diccionarios se generan a partir de un conjunto de términos de opinión de semillas que crecen a través de la búsqueda de palabras relacionadas mediante el uso de técnicas estadísticas o semánticas. En los métodos basados en estadística como el análisis semántico latente, simplemente se puede utilizar la frecuencia de aparición de las palabras dentro de una colección de documentos. Por otro lado, los métodos semánticos, como el uso de sinónimos y antónimos, o las relaciones de tesoro, como WordNet (www.wordnet.com), también pueden representar una solución interesante.

3.3. Conclusiones

En este tema se ha tratado de plasmar una visión crítica sobre lo que se suele entender hoy en día por inteligencia artificial y una visión general de lo que suele ser entendido por inteligencia artificial y no sólo en el sentido de aprendizaje automático y analítica de datos. Se ha presentado la aplicación a uno de los principales temas de interés y de preocupación en todas las empresas hoy en día como es el análisis de sentimientos y opiniones.

La necesidad de un análisis inteligente de datos en todas las empresas y entidades propicia que sean demandados diversos profesionales de múltiples ámbitos como se ha reflejado en el documento. En particular son especialmente requeridos titulados en matemáticas y estadística, por su formación y capacidad para entender los rudimentos formales de la mayoría de los algoritmos de aprendizaje automático y diseñar y modificar algoritmos de este tipo. Pero, desde mi punto de vista, los directores de proyectos de este tipo deben tener una formación más amplia, incluso más allá de la ciencia de datos. Deberían disponer de un “maletín de herramientas” que les permita seleccionar aquellas más adecuadas para cada problema específico, y no sólo en lo que concierne al análisis de datos. Por ejemplo, para un sistema de anticipación a un resultado electoral, no sólo se deben tener en cuenta los datos, sino que hay que considerar teorías e hipótesis que la sociología o la antropolo-

gía social, como por ejemplo el efecto o teorema de Thomas. De la misma forma para la implementación de un sistema de análisis de sentimientos u opiniones, sería conveniente contar con expertos en lingüística computacional y en psicología clínica.

Esto significa que cada vez más se van a requerir profesionales de diversos ámbitos con formación orientada hacia los desarrollos en inteligencia artificial. Por otra parte, desde el punto de vista puramente de ingeniería, son necesarios profesionales capaces de mantener y diseñar sistemas robotizados o automáticos, que en muchos casos van a sustituir a otro tipo de mano de obra humana, lo que está provocando cambios sustanciales en los modelos sociales de trabajo.

La inteligencia artificial está cambiando y cambiará todavía más nuestras vidas y un nuestro modo de desenvolvernó en el mundo. Pero hay que tener mucho cuidado con no trivializar y a cualquier automatismo sencillo llamarle de inteligencia artificial. Por ejemplo, que un reloj sea capaz de medir nuestras pulsaciones y generar un gráfico para estimar como se van a comportar en un futuro, es discutible que deba ser considerado inteligencia artificial, que un asistente de voz responda correctamente a la orden “mañana despiértame con música romántica” o que un sistema domótico abra las persianas a determinada hora o bajo determinadas condiciones.

Debemos pensar en una inteligencia artificial que emule en determinados aspectos el comportamiento racional humano y no sólo en sistemas que analicen unos datos numéricos desde un punto de vista estadístico.

3.4. Bibliografía

1. Mitchell, M. (2019). Artificial Intelligence: A Guide for Thinking. Penguin Books, London, UK.
2. Emmert-Streib, F., Yli-Harja, O., Dehmer, M. (2020). Artificial Intelligence: A Clarification of Misconceptions, Myths and Desired Status, *Frontiers in Artificial Intelligence* 3: 91.
3. Siegel, E. (2013). Analítica predictiva. Predecir el futuro utilizando Big Data. Anaya Multimedia-Anaya Interactiva.
4. Mayer-Schönberger, V., Cukier, K. (2013). Big data. La revolución de los datos masivos. Turner.
5. Piatetsky-Shapiro, G., Frawley, W. (1991). Knowledge Discovery in Databases. AAAI/MIT Press, Cambridge MA.
6. Agrawal, D., Das, S., Abbadi, A. E. (2010). Big Data and Cloud Computing: New Wine or Just New Bottles?. *Proc. of the VLDB 2010*, Vol. 3, No. 2.
7. Agrawal, D., Das, S., Abbadi, A. E. (2011). Big Data and Cloud Computing: Current State and Future Opportunities. *Proc. of the ETDB 2011*, Uppsala, Sweden.

8. Olivas, J. A. (2011). Búsqueda eficaz de información en la Web, Edulp, La Plata, Argentina. <http://hdl.handle.net/10915/18401>.
9. Serrano-Guerrero, J., Olivas, J. A., Romero, F. P., Herrera-Viedma, E. (2015). Sentiment analysis: A review and comparative analysis of web services. *Information Sciences* 311, 18–38.