

Sistemas de Big Data

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



**Sistemas de
Big_Data**

Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

5

Capítulo

Metodologías y algoritmos en la Minería de Datos (I)

José Ángel Olivas Varela

Este capítulo está dedicado a describir en profundidad la metodología genérica comúnmente usada para el proceso de descubrimiento de conocimiento en bases de datos y la minería de datos (**KDD: Knowledge Discovery in Databases**), ilustrándolo con diversos casos y ejemplos muy variados, que permitan al lector entender la aplicación real de estas etapas y acciones metodológicas. También se describe más superficialmente las metodologías **SEMMA** y **P³TQ**, que en el fondo no dejan de estar basadas en KDD.

También se presentará una clasificación de los diferentes **tipos de “minerías”**: **datos, textos, opiniones, gráficos...** Se continuará con la visión crítica sobre cómo se suele afrontar habitualmente el análisis de datos, que nos permita reflexionar sobre en qué grado se suelen hacer las cosas de una forma metodológicamente adecuada.

En la segunda parte del estudio de las Metodologías y algoritmos en la Minería de Datos que se presentará en el siguiente capítulo, se estudiará la metodología **CRISP-DM**, quizá la más usada hoy en día en entornos empresariales (pero también muy vinculada en su esencia al KDD), metodologías directamente basadas en CRISP-DM como Analytics Solutions Unified Method for Data Mining (**ASUM-DM**) y metodologías “ágiles” como Team Data Science Process (**TDSP**) o **Scrum-DM**.

Por último, para finalizar estos dos capítulos, se presentará una enumeración y breve descripción de los **“algoritmos de minería de datos”**, que pretende ser un mapa completo de los objetivos, orientación y técnicas (tanto estadísticas como provenientes de la Inteligencia Artificial) para afrontar el análisis de datos en su estado actual desde el punto de vista de las Ciencias de la Computación.

5.1. Analítica de Datos y Minería de Datos

Como se ha destacado en los capítulos anteriores el análisis de datos no suele ser una tarea sencilla. Se suelen designar las tareas de “minería” atendiendo al origen de los datos y a la intención del proceso. Según esto, entre otros tipos de minería, los más habituales son:

Minería de Datos:

Se parte de datos estructurados y casi siempre numéricos. El objetivo es encontrar regularidades (“patrones”) que permitan establecer modelos normalmente de predicción o de clasificación.

Minería de Textos:

Se parte de colecciones de documentos de texto. El objetivo es encontrar regularidades (“patrones”) semánticos (aunque normalmente solo se manejan desde el punto de vista lexicográfico) que permitan ayudar en tareas como el acceso, la búsqueda y la recuperación de información o la elaboración automática de resúmenes de dichos textos.

Minería de Opiniones:

También se suele denominar “Análisis de Sentimientos” (Sentiment Analysis). Se parte de colecciones de documentos de texto, habitualmente pequeños, como los típicos mensajes en redes sociales. El objetivo es manifestarse sobre la “polaridad” (bueno o malo) de un mensaje con respecto a un determinado tema, encontrando regularidades (“patrones”) semánticas (aunque normalmente solo se manejan desde el punto de vista lexicográfico) que permitan ayudar en tareas como la percepción de un producto o un político a través de las opiniones de los usuarios de las redes sociales. Esto permite, por ejemplo, disponer de alertas tempranas (early warnings) sobre las críticas de los consumidores a un determinado producto.

Minería de Grafos:

Se parte de grafos o redes, normalmente compuestas de términos/conceptos y sus relaciones. El objetivo es encontrar regularidades (“patrones”) en dichos grafos que permitan ayudar a describir y entender los fenómenos susceptibles de ser representados por redes o grafos, como las redes sociales, las relaciones lingüísticas entre conceptos, las redes de computadoras, las redes sociales, las estructuras químicas... Esto permite, por ejemplo, el aprovechamiento inteligente de ontologías o tesauros como Wordnet¹ o como se pretende habitualmente en la denominada “Web Semántica”.

Como se puede observar en la figura 1, en la evolución de la profundidad del análisis tanto de datos estructurados como de no estructurados, en el primer caso el nivel más profundo se alcanza con la analítica predictiva y en el segundo con el análisis de sentimientos. A lo largo de este documento se ilustran diversos ejemplos, críticas, aplicaciones y particularidades de todas estas variantes.

¹WordNet | A Lexical Database for English (princeton.edu): <https://wordnet.princeton.edu/>

5.2. El proceso KDD (Knowledge Discovery in Databases)




Figura 5.1: Relación entre la amplitud y la profundidad en el análisis de datos estructurados y no estructurados (<http://www.informationbuilders.com>).

Como ya se ha visto anteriormente, debemos distinguir claramente entre **datos** (contenido bruto), **información** (resúmenes, datos “presentables”) y **conocimiento** (mayor nivel de abstracción que nos permite tomar decisiones ante nuevas situaciones). Habitualmente hoy en día la gestión de datos se queda en un análisis descriptivo, es decir, la visualización de gráficos o lo que se suelen llamar “*cuadros de mandos*” o “*dashboards*”, que hemos visto detalladamente en el capítulo anterior, que ayudan a la persona responsable a tomar decisiones.

Por ejemplo, esto puede venir muy bien en un entorno médico, porque permite a los profesionales tener una información más completa y procesada de los pacientes, historias clínicas, pruebas... para poder tomar decisiones. Pero no debemos quedarnos ahí, se debe ir hacia la analítica predictiva y prescriptiva, modelos que permitan extraer conocimiento a partir de los datos y la información que podamos usar para mejorar sustancialmente la práctica clínica.

5.2. El proceso KDD (Knowledge Discovery in Databases)

Fayyad y sus colaboradores (Fayyad, Piatetsky-Shapiro, Smyth, [1]) definen el proceso KDD como “**El proceso no trivial de identificar válidos, nuevos, potencialmente útiles y comprensibles patrones en datos**”, utilizando técnicas multidisciplinarias y viendo cómo actúan juntas.

El término proceso implica que hay varios pasos, como la preparación de datos o la búsqueda de patrones. El término patrón se puede referir al comportamiento regular de los datos, junto con una descripción y un modelo aplicable al mismo. Los patrones descubiertos deben ser válidos para nuevos casos con cierto grado de certeza. Se necesita que estos patrones sean nuevos, al menos para el sistema y preferiblemente para el usuario y potencialmente útiles.

Por último, estos patrones deben ser comprensibles, todo ello si no es inmediatamente, lo debe cumplir después de un postprocesado. Esta definición implica que deben definirse medidas de la bondad de los patrones, en muchos casos es posible definir medidas de certeza (capacidad de clasificación de nuevos datos) o utilidad (calidad de las predicciones en base a estos patrones).

El proceso KDD descrito por Fayyad y sus colaboradores, interactivo e iterativo, es el que refleja la figura 2:




Figura 5.2: Proceso KDD, Knowledge Discovery in Databases. Adaptado de Fayyad et al. [1].

5.2.1. Selección: Datos objetivo/Tarjeta de Datos.

Consiste en seleccionar unos ‘datos de trabajo’. Aplicando el conocimiento del dominio y el conocimiento relevante a priori, teniendo en cuenta los objetivos del proceso global del KDD se crea una tarjeta de datos (datos objetivo) que incluirá conjuntos seleccionados de datos o subconjuntos de variables relevantes o ejemplos.

Habitualmente se lleva a cabo un análisis previo, prospección para verificar la viabilidad de las hipótesis iniciales. Es decir, se comprueba que los datos de los que se dispone son adecuados para buscar los patrones que se pretende encontrar (hipótesis inicial). Si no se verifica este extremo no tiene sentido continuar con el proceso KDD bajo la hipótesis establecida.

Ejemplo:

Supongamos que disponemos de una base de datos de los clientes de una entidad bancaria de una determinada provincia española, y que nuestro objetivo es diseñar un sistema de ayuda a la decisión en la concesión de créditos bancarios para dicha entidad. Para la tarjeta de datos, se podrían seleccionar los clientes de algunas poblaciones significativas por su renta o el tipo de población, de diferentes rangos de edades, de diferente poder adquisitivo, o cualquier otra característica relevante para el fin que se ha propuesto.

Siempre se debe recordar que para que los algoritmos de aprendizaje automático funcionen de la mejor manera posible, el conjunto de datos de entrenamiento debe cubrir razonablemente tanto los espacios de entrada como los de salida. Es decir, tanto los atributos de los ejemplos, como el atributo que permite clasificarlos deben tener un reparto homogéneo, y estará todos suficientemente representados.

5.2.2. Preproceso: Limpieza de Datos.

En esta etapa se procede a la limpieza de los datos, eliminación de ruidos, manejo de campos vacíos, datos perdidos (se suele hablar de datos ausentes o *missing values* y datos perdidos por el sistema o *system missing values*), valores desconocidos o por defecto, evolución de datos, *outliers* e *inliers*. Se aplican técnicas estándar de bases de datos.

En situaciones de incertidumbre, es decir, cuando faltan datos (en el sentido de valores en campos que hacen que los registros estén incompletos), se debe plantear la posibilidad de rellenarlos con valores prototípicos (por ejemplo, si la base de datos es de muebles y un campo es el número de patas, ante la ausencia de valores podría rellenarse con “4”, que es un número prototípico de patas para una silla) o valores por defecto (en una base de datos de pacientes-síntomas, ante la ausencia de valor para “fiebre” se podría asumir que el paciente NO tenía fiebre como valor por defecto). Esta decisión puede llevarnos a introducir valores erróneos (sillas de 3 patas o pacientes que tenían fiebre y les hemos puesto que no). Es tarea del analista de datos decidir si compensa el nivel de error añadido la ganancia que puede generar este relleno.

En la etapa de preproceso también se llevan a cabo las labores de agregación de datos. Por ejemplo, en la base de datos de clientes de un banco, ante el desarrollo del sistema de ayuda a la decisión en la concesión de créditos bancarios, es posible que convenga sumar los ingresos mensuales de los clientes (y los gastos) en vez de trabajar con todos los movimientos producidos en las cuentas. También es necesario eliminar algunos registros o datos que puedan contener errores, como por ejemplo fechas con formato no adecuado, edades que se salgan de rango, números introducidos como letras (por ejemplo, escribir con una ‘ó’ mayúscula el número cero).

5.2.3. Transformación: del Clustering a la Clasificación.

En esta etapa, se procede entre otras cosas a la reducción del número de variables, la localización de formas útiles para expresar los datos dependiendo del uso posterior que se les va a dar y de los objetivos del sistema. Se usa el conocimiento experto y técnicas de transformación e informes en bases de datos.

Es quizá la fase más crítica y relevante de todo el proceso. Se suele usar inicialmente un algoritmo de clustering para agrupar elementos similares, normalmente buscando un número de clusters compatible (o coincidente) con la granularidad esperada en las decisiones a tomar.

Por ejemplo, ante la base de datos de clientes de un banco, con el objetivo de desarrollar un sistema de ayuda a la decisión en la concesión de créditos bancarios, es muy probable que lo más adecuado sea establecer tres grupos (clusters): el de los “buenos pagadores” a los que se les concedieron los créditos, el de los “malos pagadores”, que no se les concedió y los “dudosos” a los que se les piden mayores garantías.

Otro aspecto importante es que en muchos casos es necesaria una transformación grande de la base de datos, convertirla en otra totalmente diferente. Por ejemplo, en sistemas en los que se quiera predecir o pronosticar a través del uso de series temporales. Normalmente la base de datos inicial debe estar compuesta de registros individuales (por ejemplo, ocurrencias de terremotos) y nos puede interesar construir series temporales de terremotos anteriores a uno “grande” para tratar de encontrar patrones anteriores que permitan establecer un modelo de pronóstico. Esto supone haber partido de una base de datos donde cada registro era una ocurrencia y haberla transformado en otra en la que cada registro es una serie temporal. Aquí también se agruparían estas series temporales según su similitud con el fin de encontrar regularidades o patrones de “evolución sísmica previa a un gran terremoto”.

Por último, es importante señalar que una vez agrupados los elementos, se deben “etiquetar” estos clusters, con el fin de convertir este proceso de clustering en uno de clasificación. Es decir, en mi sistema de ayuda a la decisión en la concesión de créditos bancarios, al cluster3 que me generó el algoritmo de clustering usado, le asigno el nombre de “buenos pagadores”, al cluster2 el de “dudoso”, etc. con lo que podría transformar la base de datos inicial de clientes en otra con un campo más en cada registro que diga si ese cliente es “buen pagador”, “dudoso”... dependiendo del cluster al que pertenezca. Así, hemos convertido este proceso de clustering (no supervisado) en uno de clasificación (supervisado).

Ahora, por ejemplo se podría generar un árbol de decisión que nos permitiese clasificar a un nuevo cliente según sus características en “buen pagador”, “dudoso”...

5.2. El proceso KDD (Knowledge Discovery in Databases)

Esta idea tiene una repercusión importante: habitualmente (casi siempre, salvo raras excepciones) no basta con usar un único método o algoritmo para llevar a cabo un proceso completo de KDD. Es necesario primero usar clustering, no supervisado, para agrupar los datos según su similitud (y transformarlos) y después usar uno de clasificación supervisado (data mining) para poder usarlo en la toma de decisiones (segmentación, predicción. . .).



Figura 5.3: Proceso KDD, Knowledge Discovery in Databases, reformulado para los entornos Big Data, propuesta por el autor.

Como se puede ver en la figura 3, en entornos actuales Big Data se debería partir de un 'Data Lake', no de una única base de datos relacional y numérica. Esto dificulta enormemente el proceso, ya que todos los algoritmos/herramientas que conocemos solo admiten como entrada este tipo de datos, no la heterogeneidad de un lago de datos.

5.2.4. Minería de Datos.

En esta fase, se procede a la elección de los algoritmos de Minería de Datos. Se toman decisiones acerca del modelo que se deriva del algoritmo de Minería de Datos elegido (clasificación, resumen de datos, predicción). Se procede a la búsqueda de patrones de interés, en cuanto a clasificación, reglas o árboles, regresión, clasificación, dependencia, heurísticas, incertidumbre.

Conocimiento: formalización de patrones.

Dentro del proceso KDD descrito, adquiere especial relevancia el paso de Minería de Datos para determinar los patrones de los datos observados. La elección de los modelos a utilizar tiene una componente fundamental de conocimiento de los expertos, supervisado por el Ingeniero de Conocimiento y el analista de datos o científico de datos.

En la literatura, véase por ejemplo (Berry y Linoff, [2]), se describe un gran número de algoritmos y técnicas de Minería de Datos. En este tema se introducen fundamentalmente los provenientes de la estadística y el aprendizaje automático. En particular, los algoritmos de Minería de Datos consisten en una mezcla específica de tres componentes (Fayyad et al., [1]):

El modelo

Un modelo contiene parámetros que son determinados a partir de los datos. Dos factores relevantes:

- **La función** En la práctica de la Minería de Datos se utilizan funciones de Regresión (comparan datos con valores reales de las variables establecidos mediante predicción), Dependencia (describen dependencias significativas entre variables), Análisis de relaciones entre campos de las bases de datos, pero las más relevantes para la predicción (como evaluación de una situación mediante la comparación de casos reales con situaciones prototípicas) son las siguientes:
 - **Funciones de Clasificación:** categorizan un registro dentro de una de varias clases predefinidas.
 - **Funciones de Clustering:** categorizan un registro dentro de una de varias clases (clusters), pero a diferencia de la clasificación, las clases las determinan los propios datos, mediante agrupamientos naturales basados en medidas de afinidad, similitud o probabilidad.
 - **Funciones de Resumen:** generan una descripción compacta de un subconjunto de datos. Se puede usar un simple ejemplo como media y las desviaciones estándar para todos los campos.
 - **Funciones de Análisis de secuencias:** modelizan patrones secuenciales, series temporales. El objetivo es generar la secuencia de estados del proceso que se trata de modelizar.
- **La representación** Se utilizan modelos clásicos, como árboles de decisión, reglas, modelos lineales y no lineales, métodos basados en ejemplos (razonamiento basado en casos), redes bayesianas, modelos borrosos, redes neuronales, algoritmos genéticos, etc. El modelo de representación determinará la flexibilidad de representación de los datos e interpretación del modelo desde el punto de vista humano. Normalmente, cuanto más complejo sea el modelo de representación, es posible que maneje mejor los datos, pero hará que sea mucho más difícil entenderlos. Aunque a nivel de investigación se tiende a utilizar modelos complejos, en aplicaciones reales se utilizan mayoritariamente modelos simples debido a su robustez e interpretabilidad.
- **El criterio de preferencia** Es aquel que permite seleccionar un modelo o conjunto de parámetros en función de unos datos determinados. Es, en cierto modo, una medida de bondad de la relación entre el modelo y los datos. Normalmente este criterio es explícito y cuantitativo en el algoritmo de bús-

queda (por ejemplo, el criterio de encontrar los parámetros que maximizan la probabilidad de algunos datos observados). También suele haber un criterio subjetivo (por parte del Científico de datos o del Ingeniero de Conocimiento) implícito, sobre qué modelos se ha de tener en cuenta inicialmente.

- **El algoritmo de búsqueda** Es necesario especificar un algoritmo para encontrar modelos particulares y parámetros e incluso criterios de preferencia. En los de búsqueda de parámetros es frecuente que, dado un modelo, el problema de encontrar los mejores parámetros se reduzca a un problema de optimización. En Minería de Datos se suelen utilizar técnicas de optimización sencillas (por ejemplo, el descenso del gradiente) que presentan los problemas de máximos y mínimos locales y otros muy estudiados en el ámbito de la Inteligencia Artificial.

Para finalizar con el ejemplo de la segmentación de clientes para diseñar el sistema de ayuda a la decisión en la concesión de créditos bancarios, hacemos un pequeño resumen de todo el proceso. Se parte de un data lake constituido tanto por las bases de datos de los clientes que suministra la entidad financiera como por otros datos que se puedan añadir, como pueden ser comentarios en las redes sociales, historial de riesgo crediticio, datos poblacionales y de renta per cápita en las diferentes zonas, hábitos de consumo y precios de inmuebles en dichas zonas y un largo etcétera.

La primera acción sería la selección de la tarjeta de datos. Para ello, podríamos quedarnos con los clientes de tres pueblos representativos de la provincia por su actividad productiva, tipo de producción, y nivel de vida. A su vez se podría seleccionar a clientes de las ciudades grandes que vivan en determinados barrios y con diferentes rangos de edad. En cuanto a campos, se eliminarían campos como el DNI, teléfono, otros datos personales que debe ser anonimizado, etcétera.

Una vez seleccionados estos datos objetivo, se procede a su preproceso y limpieza. Aquí se podría determinar el nivel de ruido, eliminar y/o rellenar campos vacíos mediante valores prototípicos o por defecto, corregir errores de números o fechas y agregar campos que no tenga sentido manejar de forma individual.

Posteriormente se procedería a la transformación de esos datos preprocesados. Para ello, aplicaríamos un algoritmo de clustering buscando agrupar a los clientes en tres clases: buenos pagadores, borderline, y malos pagadores. Este agrupamiento sería con una función de similitud que tuviera en cuenta un mayor peso en los factores más relevantes de cara a la resolución del problema, como por ejemplo, la capacidad de devolución económica mensual de cada cliente.

Una vez agrupados los clientes, en la etapa de minería de datos ya se podría aplicar algún algoritmo de clasificación, puesto que los datos han sido etiquetados en el proceso de clustering anterior. Se podría aplicar por ejemplo un árbol de decisión, o hacer tres tablas resumen de los elementos de cada uno de los tres clusters descubiertos, que nos permitirían comparar un caso real a evaluar con cada una de estas tres tablas mediante una función de similitud y así poder tomar la decisión que suministre la tabla más afín con lo que ya habríamos obtenido conocimiento y lo habríamos plasmado en una aplicación.

5.3. Metodología SEMMA.

La metodología SEMMA [3], [4], acrónimo de SAMPLE, EXPLORE, MODIFY, MODEL, ASSESS, que se podría traducir como muestrea/selecciona, explora, modifica, modela y evalúa, se refiere al proceso básico para llevar a cabo tareas de Minería de Datos.

Esta metodología es propuesta por la empresa SAS, especialmente para trabajar con su propio software de minería de datos. El acrónimo SEMMA se corresponde a sus cinco fases (figura 4). Es frecuente el malentendido de referirse a SEMMA como una metodología para hacer Minería de Datos. En la página de SAS se detalla que SEMMA es una organización lógica de las diferentes funciones de las herramientas de SAS ENTREPISE MINER en relación a las tareas básicas de la Minería de Datos.

Se propone que a partir de una muestra representativa de los datos, se apliquen técnicas estadísticas de exploración y visualización, se seleccionen y transformen variables, se modele con las variables para predecir y se evalúe la precisión del modelo.




Figura 5.4: Fases de la metodología SEMMA.

Visto con un poco más de detalle, estas etapas consisten en lo siguiente:

Muestra (Sample):

Extracción de una muestra del conjunto sobre la que se va a trabajar, debe ser un subconjunto representativo, desde un punto de vista estadístico, de datos que contengan información relevante para el objetivo y que a su vez sea rápido de manipular. La representatividad de la muestra es indispensable ya que de no cumplirse invalida todo el modelo y los resultados dejan de ser admisibles.

La forma más habitual de obtener esta muestra es la selección al azar, además para cada muestra a considerar se debe asociar un nivel de confianza en la misma. La hipótesis es que si existen patrones generales en la base de datos, éstos serán detectados en la muestra representativa.

Puede verse como equivalente a la de ‘selección’ del proceso KDD.

Exploración (Explore):

Una vez seleccionada la muestra o conjunto de muestras representativas del conjunto inicial, la metodología SEMMA propone que se debe proceder a una exploración de la de esta selección, buscando tendencias, valores atípicos (outliers), etc. con el fin de hacerse una idea del contenido y estructura de estos datos seleccionados.

Para ello se propone la utilización de herramientas de visualización o de técnicas estadísticas (incluyendo análisis factorial, análisis de correspondencias y la segmentación) que ayuden a detectar relaciones entre variables. De esta forma se pretende determinar cuáles son las variables esenciales que van a servir como entradas al modelo.

Podríamos verla como equivalente a la acción de ‘prospección’ del proceso KDD.

Modificación (Modify):

Esta etapa consiste en la manipulación y formateo de los datos. En esta etapa se procede a la limpieza de valores anómalos, se tratan los datos faltantes, y se seleccionan, crean o modifican las variables con las que se trabajará para dirigir el proceso de modelado.

Puede considerarse como equivalente a la de ‘preproceso o limpieza de datos’ del proceso KDD.

Modelado (Model):

Creación del modelo que permitirá predecir el valor de las variables de respuesta a partir de las variables iniciales seleccionadas. Incluye la utilización de métodos estadísticos tradicionales, así como técnicas de redes neuronales, árboles de decisión, regresión y series temporales entre otras.

Es equivalente a las de ‘transformación/data mining’ del proceso KDD.

Valoración (Assess):

Se evalúa la utilidad y la precisión del modelo o modelos creados y usados. Es habitual que se use una parte de los datos no usados inicialmente, como se hace habitualmente cuando se usan los algoritmos de aprendizaje automático de forma aislada.

En la figura 5 se muestra un esquema de la dinámica general de la metodología.




Figura 5.5: Dinámica de la Metodología SEMMA.

5.4. Metodología P³TQ.

La metodología Catalyst, comúnmente conocida como P3TQ [5] (Product, Place, Price, Time, Quantity), fue propuesta por Dorian Pyle en el año 2003. Se compone de dos modelos, el Modelo de Negocio (figura 6) y el Modelo de Extracción de Información (figura 7). El Modelo de Negocio propone una serie de pasos para el desarrollo y la construcción de un modelo que permita identificar un problema de negocio. El Modelo de Extracción de Información propone una serie de pasos para la preparación de los datos, selección de las herramientas y modelos iniciales, ejecución, evaluación y comunicación de los resultados. Se proponen cinco situaciones o puntos de partida diferentes para un proyecto:

Dato: Se exploran los datos en búsqueda de relaciones útiles e interesantes.

Problema / Oportunidad: Dado un problema u oportunidad de negocio, ver cómo el análisis de los datos puede colaborar para mejorarla.

Prospectiva: Proyecto diseñado para descubrir dónde el análisis de los datos puede aportar valor en la organización.

Modelo definido: Utilizar métodos o técnicas de Minería de Datos para construir un modelo específico para una situación determinada.

Estrategia: Dada una situación estratégica, analizar si procesos de este tipo pueden ser útiles para explicar la situación actual y descubrir cuáles son las opciones para resolverla.




Figura 5.6: Modelo de negocio de la metodología P³TQ.

Tomando algunos de estos puntos o escenarios de partida, la metodología propone una serie de pasos y herramientas para llegar a descubrir el problema y los requerimientos organizacionales que abordará el proyecto, así como los datos necesarios para efectuar el análisis. Las figuras resumen las etapas de cada modelo. En el Modelo de Negocio se encuentran los posibles escenarios de partida, en el centro las herramientas principales que se pueden utilizar, y en la salida la definición de los datos necesarios y los requerimientos para el proyecto. En el Modelo de Explotación de Información se explicitan los pasos de esta metodología para el descubrimiento de patrones o relaciones, en base al problema de negocio identificado.



Figura 5.7: Modelo de Explotación de información de la metodología P³TQ.

5.5. Conclusiones.

Este capítulo se ha dedicado a describir en profundidad la metodología genérica comúnmente usada para el proceso de descubrimiento de conocimiento en bases de datos y la minería de datos (**KDD: Knowledge Discovery in Databases**). También se han descrito más superficialmente otras dos metodologías derivadas del KDD, SEMMA y P³TQ.

También se ha presentado una clasificación de los diferentes tipos de “mine-rías”: datos, textos, opiniones, gráficos... y se han enmarcado dentro de lo que hoy se denomina “Inteligencia de Negocio”. Se ha continuado con la visión crítica sobre cómo se suele afrontar habitualmente el análisis de datos, que nos permita reflexionar sobre en qué grado se suelen hacer las cosas de una forma adecuada.

En la segunda parte del estudio de las Metodologías y algoritmos en la Mine-ría de Datos que se presentará en el siguiente capítulo, se estudiará la metodología **CRISP-DM**, quizá la más usada hoy en día en entornos empresariales (pero también muy vinculada en su esencia al KDD), metodologías directamente basadas en CRISP-DM como Analytics Solutions Unified Method for Data Mining (ASUM-DM) y metodologías “ágiles” como Team Data Science Process (**TDSP**) o **Scrum-DM**.

Por último, se presentará una enumeración y breve descripción de los que se consideran “algoritmos de minería de datos”. Esta visión panorámica pretende ser un mapa completo de los objetivos, orientación y técnicas (tanto estadísticas como provenientes de la Inteligencia Artificial) para afrontar el análisis de datos en su estado actual desde el punto de vista de las Ciencias de la Computación.

No se presentan herramientas concretas debido a la imposibilidad de profun-dizar mínimamente en el gran número de las disponibles actualmente y no haber un criterio robusto para elegir una u otra para estudiar en detalle. Es por ello que-da fuera del alcance de estos dos capítulos metodológicos, pero si se verán en los siguientes.

5.6. Bibliografía.

1. Fayyad, U., Piatetsky-Shapiro, G., Smyth, P. (1996). The KDD Process for Extracting Useful Knowledge from Volumes of Data. Communications of the ACM, November 1996/ Vol 39, N° 11, 27–34.
2. Berry, M., Linoff, G. (1996). Data Mining Techniques. Wiley Computer Pu-blishing. New York.
3. SAS Institute Inc., “Introduction to SEMMA,” (2020). [Online]. Available: <https://documentation.sas.com/?docsetId=emref&docsetTarget=n061bzurmej4j3n1jnj8bbjjm1> [Último acceso: 02/10/2021].
4. SAS Institute Inc., “Data Mining and SEMMA,” (2020). [Online]. Available: <https://documentation.sas.com/?docsetId=emcs&docsetTarget=n0pejm83csbja4n1xueveo2uou> [Último acceso: 02/10/2021].

5. Pyle D. (2003). Business Modeling and Data Mining. The Morgan Kaufmann Series in Data Management Systems.