

El proceso KDD: DATA MINING

Sistemas de Big Data

José Angel Olivas Varela
Joseangel.olivas@uclm.es




Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data

KDD

*Knowledge
Discovery in
Databases*



- Elección de los **algoritmos** de Minería de Datos.
- Decisiones acerca del **modelo** que se deriva del algoritmo de Minería de Datos elegido (**clasificación, resumen de datos, predicción**).
- Búsqueda de **patrones** de interés, en cuanto a **clasificación, reglas o árboles, regresión, clasificación, dependencia, heurísticas, incertidumbre**.

Conocimiento: formalización de patrones

El modelo:

- Un modelo contiene **parámetros** que son determinados a partir de los datos.
- Dos factores relevantes: la **función** y la **representación**.

La función

- En la práctica de la Minería de Datos se suelen usar funciones de:
 - **Regresión** (comparan datos con valores reales de las variables establecidos mediante predicción).
 - **Dependencia** (describen dependencias significativas entre variables).
 - **Análisis de relaciones** entre campos de las bases de datos.

La función:

- Pero las más relevantes para la predicción son:
 - **Clasificación:** categorizan un registro dentro de una de varias clases predefinidas.
 - **Clustering:** categorizan un registro dentro de una de varias clases (**clusters**), pero a diferencia de la clasificación, las clases las determinan los propios datos, mediante agrupamientos naturales basados en medidas de **afinidad**, **similitud** o **probabilidad**.

La función:

- Pero las más relevantes para la predicción son:
 - **Resumen:** generan una descripción compacta de un subconjunto de datos. Se puede usar un simple ejemplo como **media** y las **desviaciones estándar** para todos los campos.
 - **Análisis de secuencias:** modelizan patrones secuenciales, series temporales. El objetivo es generar la secuencia de estados del proceso que se trata de modelizar.

La representación

- Se utilizan modelos clásicos, como árboles de decisión, reglas, modelos lineales y no lineales, métodos basados en ejemplos (razonamiento basado en casos), redes bayesianas, modelos borrosos, redes neuronales, algoritmos genéticos, etc.
- El modelo de representación determinará la **flexibilidad** de representación de los datos e interpretación del modelo desde el punto de vista humano.

La representación

- Cuanto más complejo sea el modelo de representación, es posible que maneje mejor los datos, pero hará que sea **mucho más difícil entenderlos**.
- Aunque a nivel de investigación se tiende a utilizar modelos complejos, en aplicaciones reales se utilizan mayoritariamente modelos simples debido a su **robustez e interpretabilidad**.

El proceso KDD: DATA MINING

Sistemas de Big Data

José Angel Olivas Varela
Joseangel.olivas@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data