

La metodología SEMMA

Sistemas de Big Data

José Angel Olivas Varela
Joseangel.olivas@uclm.es




Sistemas de
Big_Data




Curso Especialización
Inteligencia_Artificial y
Big_Data

SEMMA



- SAMPLE, EXPLORE, MODIFY, MODEL, ASSESS.
- muestrea/selecciona, explora, modifica, modela y evalúa
- Propuesta por la empresa **SAS**, especialmente para trabajar con **su propio software** de minería de datos.

SEMMA



- Se propone que a partir de una **muestra representativa de los datos**, se apliquen técnicas **estadísticas de exploración y visualización**, se seleccionen y transformen variables, se modele con las variables para **predecir** y se **evalúe** la precisión del modelo

SEMMA

Etapas

Muestra (Sample):

- Extracción de una **muestra** del conjunto sobre la que se va a trabajar.
- debe ser un subconjunto **representativo** desde un punto de vista **estadístico**.
- datos que contengan **información relevante** para el objetivo y que a su vez sean **rápidos** de manipular.

SEMMA

Etapas

Muestra (Sample):

- Habitualmente selección al **azar**.
- Se debe asociar un **nivel de confianza**.
- La hipótesis es que si existen **patrones generales** en la base de datos, éstos serán detectados en la **muestra representativa**.
- Es equivalente a la de '**selección**' del proceso KDD.

SEMMA

Etapas

Exploración (Explore):

- Buscando **tendencias**, **valores atípicos** (*outliers*), etc. con el fin de hacerse una idea del contenido y estructura de estos datos seleccionados.
- Herramientas de **visualización** o **técnicas estadísticas** (incluyendo análisis factorial, análisis de correspondencias y la segmentación).
- Es equivalente a la de '**prospección**' del proceso KDD.

SEMMA

Etapas

Modificación (Modify):

- Manipulación y formateo de los datos.
- **Limpieza** de valores anómalos, se tratan los datos faltantes, y se **seleccionan, crean o modifican** las variables con las que se trabajará para dirigir el proceso de modelado.
- Es equivalente a la de **‘preproceso o limpieza de datos’** del proceso KDD.

SEMMA

Etapas

Modelado (Model):

- Creación del modelo que permitirá **predecir** el valor de las variables de respuesta a partir de las variables iniciales seleccionadas.
- Métodos **estadísticos** tradicionales, así como técnicas de **redes neuronales, árboles de decisión, regresión y series temporales** entre otras.
- Es equivalente a las de **'transformación/data mining'** del proceso KDD.

SEMMA


Etapas

Valoración (Assess):

- Se evalúa la **utilidad** y la **precisión** del modelo o modelos creados y usados.
- Es habitual que se use una **parte** de los datos no usados inicialmente, como se hace habitualmente cuando se usan los algoritmos de aprendizaje automático de forma aislada.

SEMMA

Etapas



La metodología SEMMA

Sistemas de Big Data

José Angel Olivas Varela
Joseangel.olivas@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data