

Sistemas de Big Data

*Conforme a contenidos del «Curso de Especialización
en Inteligencia Artificial y Big Data»*



Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

6

Capítulo

Metodologías y algoritmos en la Minería de Datos (II)

José Ángel Olivas Varela

En este capítulo se presenta la metodología CRISP-DM, quizá la más usada hoy en día en entornos empresariales (pero también muy vinculada en su esencia al KDD [1]), metodologías directamente basadas en CRISP-DM como Analytics Solutions Unified Method for Data Mining (ASUM-DM) y metodologías “ágiles” como Team Data Science Process (TDSP) o Scrum-DM.

Para finalizar se presentará una enumeración y breve descripción de los “algoritmos de minería de datos”, que pretende ser un mapa completo de los objetivos, orientación y técnicas (tanto estadísticas como provenientes de la Inteligencia Artificial) para afrontar el análisis de datos en su estado actual desde el punto de vista de las Ciencias de la Computación.

6.1. La metodología CRISP-DM

Hay otras metodologías de minería de datos muy conocidas y usadas. Por ejemplo, como hemos visto en el capítulo anterior, el SAS Institute propuso SEMMA (Sample, Explore, Modify, Model, Assess) y, mucho más conocida y usada, a comienzos de siglo se propuso el Cross-Industry Standard Process for Data Mining, más conocido como CRISP DM, un modelo estándar y abierto muy usado, sobre todo a nivel empresarial para el desarrollo de proyectos de Minería de Datos. Esta metodología es muy similar, en esencia, a la de KDD. Aunque han surgido muchas variaciones e instancias de estas metodologías, en lo esencial siguen siendo muy similares.

En el año 1999 un grupo de empresas europeas, NCR (Dinamarca), AG (Alemania), SPSS (Inglaterra) y OHRA (Holanda), desarrollaron esta metodología de libre distribución denominada CRISP-DM [94], que estructura el ciclo de vida de un proyecto de Ciencia de Datos en seis fases que interactúan entre sí de forma iterativa durante el desarrollo del proyecto (figura 1) [2].

Es de libre distribución, la más utilizada y recomendada para aplicar a procesos de este tipo en condiciones empresariales reales.




Figura 6.1: Proceso CRISP-DM, Cross-Industry Standard Process for Data Mining ¹.

El estándar incluye un modelo y una guía estructurados en seis fases, algunas de estas fases son bidireccionales, lo que significa que permitirán revisar parcial o totalmente las fases anteriores. Sigue un proceso jerárquico, que tiene cuatro niveles de abstracción: Fase, tareas generales, tareas específicas e instancias de proceso.

Cada fase consiste en llevar a cabo tareas generales, completas y estables. Las tareas especializadas describen las acciones de las tareas generales. Por ejemplo, en el segundo nivel (tareas generales) puede existir una tarea general llamada “limpieza de datos”. El tercer nivel describe cómo difiere esta acción de unas situaciones a otras, por ejemplo, la limpieza de datos numéricos y la de datos categóricos. En la práctica muchas tareas pueden llevarse a cabo en orden diferente, con frecuencia será necesario regresar a tareas previas y repetir otras. El cuarto nivel es un conjunto de acciones, decisiones y resultados sobre el proceso de Minería de Datos que se está desarrollando.




Figura 6.2: Otra forma de ver las fases de la metodología CRISP-DM.

Las relaciones pueden existir entre cualquier fase o tarea del proceso, variando de acuerdo con los objetivos, el contexto o por el interés del usuario sobre los datos. El conocimiento oculto que se ha descubierto durante el proceso y la propia solución puede provocar nuevas preguntas que llevan a reiniciar todas las fases en un proceso de mejora, por lo que los procesos de minería subsecuentes se beneficiarán de las experiencias previas.

Las flechas internas de la figura 2 indican las relaciones más frecuentes entre las fases, aunque se pueden establecer relaciones entre cualquier fase. El círculo exterior simboliza la naturaleza cíclica del proceso de modelado. Las etapas de esta metodología son:

1. **Comprensión del negocio.**

Se trata de la presentación de los objetivos y requerimientos desde una perspectiva no técnica. También incluye la comprensión de los objetivos y requerimientos del proyecto desde una perspectiva empresarial, con el fin de convertirlos en objetivos técnicos y en una planificación. Se centra en el análisis de los objetivos y requisitos desde una perspectiva comercial, posiblemente también académica y se diseña un plan preliminar para su consecución. De una forma más detallada comprende las siguientes tareas:

■ **Establecimiento de los objetivos del negocio:**

- Antecedentes.
- Contexto inicial.
- Objetivos del Negocio.
- Criterios de éxito.

■ **Evaluación de la situación:**

- Inventario de requerimientos de Recursos, Hipótesis y Limitaciones.
- Riesgos y Contingencias.
- Terminología.
- Costos y Beneficios.

■ **Establecimiento de los objetivos de la Minería de Datos:**

- Objetivos de Minería de Datos.
- Criterio de Éxito de la Minería de Datos.

■ **Generación del plan del proyecto:**

- Plan de proyecto.
- Evaluación inicial de herramientas, equipo y técnicas.

2. **Comprensión de datos.**

Consiste esencialmente en familiarizarse con los datos teniendo presente los objetivos del negocio e identificar las características de calidad de los datos y los resultados iniciales obvios. Se pueden considerar varias dimensiones en

la calidad de datos: **exactitud**, que se refleje lo que está pasando, **totalidad**, que se encuentren los datos completos en el sistema, **oportunidad**, accesibles cuando sea necesario, **relevancia**, **nivel de detalle** y **consistencia**, mismos datos en todas las áreas o sistemas, etcétera, por lo que será necesario comprobar como son los datos en cada una de estas dimensiones. Comprende la recolección inicial de datos y permite establecer un primer contacto con el problema, estableciendo las relaciones más evidentes que permitan establecer las primeras hipótesis. De una forma más detallada comprende las siguientes tareas:

- **Obtener los datos iniciales:**
 - Informe de la obtención de los datos iniciales.
- **Descripción de los datos:**
 - Informe con la descripción de los datos.
- **Exploración de los datos:**
 - Informe de la exploración de datos.
- **Verificación de calidad de datos:**
 - Informe de la calidad de los datos.

3. Preparación de Datos.

Es la selección y limpieza de datos para obtener un subconjunto o vista aprovechable. Incluye las tareas generales de selección de datos a los que se va a aplicar la técnica de modelado, limpieza de los datos, generación de variables adicionales, integración de diferentes orígenes de datos y cambios de formato. La fase de preparación de los datos está muy relacionada con la fase de modelado, puesto que en función de la técnica de modelado que se emplee, los datos requerirán ser preprocesados de diferentes formas. De una forma más detallada comprende las siguientes tareas:

- **Selección de los datos:**
 - Justificación de la inclusión/exclusión de determinados datos.
- **Limpieza de datos:**
 - Informe de la Limpieza de Datos.
- **Construcción de datos:**
 - Atributos derivados.
 - Registros generados.
- **Integración de datos:**
 - Datos combinados.
- **Formateo de datos:**
 - Datos Formateados.

4. **Modelado de Datos:**

Consiste en aplicar las técnicas de minería de datos y en la implementación en herramientas. Implica la selección de técnicas de modelado más apropiadas para el proyecto de Ciencia de Datos. Las técnicas que se usan en esta fase se seleccionan en función de los siguientes criterios: ser apropiada al problema, disponer de datos adecuados, cumplir con los requerimientos, tiempo necesario para obtener un modelo y conocimiento de la técnica. De una forma más detallada comprende las siguientes tareas:

- **Selección de la técnica de modelado:**

- Técnica de modelado.
- Modelado.
- Hipótesis.

- **Diseño de la evaluación:**

- Diseño de pruebas.

- **Construcción del modelo:**

- Configuración de los parámetros del Modelo.
- Descripción del Modelo.

- **Evaluación del modelo:**

- Evaluación del Modelo.
- Revisión de la configuración de los parámetros del modelo.

5. **Evaluación:**

Consiste en determinar si los resultados coinciden con los objetivos del negocio e identificar los temas de negocio que deberían haberse abordado. En esta fase se evalúa el modelo, no desde el punto de vista de los datos sino desde el cumplimiento de los objetivos. Se debe revisar el proceso teniendo en cuenta los resultados obtenidos, para poder repetir algún paso en el que se haya podido cometer errores. Si el modelo generado es válido en función de los criterios establecidos en la fase inicial, se procede a su aplicación. De una forma más detallada comprende las siguientes tareas:

- **Evaluación de resultados:**

- Hipótesis de Minería de Datos.
- Resultados.
- Criterio de éxito del negocio.
- Modelos aprobados.

- **Revisión del Proceso.**

- **Establecimiento de los siguientes pasos o acciones:**

- Lista de posibles acciones.
- Decisión.

6. Despliegue e interpretación:

El objetivo es explotar la utilidad de los modelos, integrándolos en las tareas de toma de decisiones de la organización. Requiere la configuración para minería de datos de forma repetida o continua. Esta última fase puede ser tan simple como la generación de un informe o tan compleja como la repetición periódica y quizás automatizada de un proceso de análisis de datos. Es fundamental documentar todo el proceso y presentar los resultados de manera comprensible. De una forma más detallada comprende las siguientes tareas:

- **Planificación de despliegue.**
- **Planificación de la monitorización y del mantenimiento.**
- **Generación del informe final.**
- **Revisión del proyecto:**
 - Documentación de las experiencias

En la Tabla 1 se detallan las tareas que componen cada una de las seis etapas.

Comprensión del negocio	Comprensión de los datos	Preparación de los datos	Modelado	Evaluación	Despliegue/ Interpretación
Determinar los objetivos del negocio: Antecedentes. Objetivos. Criterios de éxito. Evaluar situación: Inventario de recursos, requerimientos, criterios, restricciones, riesgos, contingencias, Terminologías, costes y beneficios. Determinar Metas: Metas de minería de datos y criterios de éxito. Generar plan de proyecto: Plan de proyecto, evaluación inicial de herramientas y técnicas.	Recolección inicial de datos: Informe inicial de datos. Descripción de datos: Informe inicial de la descripción de datos. Exploración de datos: Informe de exploración de datos. Verificación de calidad de datos: Informe.	Selección de datos: Informe de Inclusión / exclusión. Limpieza de datos: Informe. Construcción de datos: Atributos derivados, generación de registros. Integración de datos: Datos fusionados. Formato de datos: Datos reformateados Conjunto de datos y descripciones.	Selección de técnicas: Técnicas de modelado, modelos supuestos. Diseño de pruebas: Pruebas, Diseño de pruebas Construcción del modelo: Ajuste de parámetros, modelos, descripciones. Evaluar modelo: Evaluar. Revisión de parámetros.	Evaluar resultados: Evaluación de datos, minería y criterios de éxito de negocio. Aprobación del modelo. Revisión de procesos: Revisión de procesos. Determinar próximos pasos: Lista de posibles acciones. Decisión.	Desarrollo del plan: Desarrollar el plan. Plan de monitorización y mantenimiento: Informe. Generar informe final. Informe final, presentación final. Revisión del proyecto: Documentar experiencia.

Figura 6.3: Tareas en cada fase de la Metodología CRISP-DM.

6.2. TDSP

El proceso de Ciencia de Datos en equipo, del inglés Team Data Science Process (TDSP) es “una metodología de Ciencia de Datos ágil e iterativa para ofrecer soluciones de análisis predictivo y aplicaciones inteligentes de manera eficiente”², de esta manera lo describen en la web de Microsoft.

Esta metodología pretende ayudar a mejorar la colaboración y el aprendizaje en equipos de Ciencia de Datos. TDSP propone mejores prácticas y estructuras de Microsoft, así como de otras empresas líderes de la industria, para ayudar en la implementación correcta de iniciativas de Ciencia de Datos.

Sus principales componentes son:

²<https://docs.microsoft.com/en-us/azure/architecture/data-science-process/overview>

1. Definición de un ciclo de vida de Ciencia de Datos.
2. Estructura de proyecto estandarizada.
3. Infraestructura y recursos recomendados para proyectos de Ciencia de Datos.
4. Herramientas y utilidades recomendadas para la ejecución de proyectos.

El ciclo de vida de TDSP es similar a CRISP-DM y su coordinación de procesos utiliza varios elementos de la metodología ágil Scrum, incluidos artefactos claramente definidos, backlog, sprints y roles de equipo.

El ciclo de vida de la metodología TDSP comprende cinco fases principales por las que normalmente pasan los proyectos de este tipo, y a menudo de forma iterativa:

1. Comprensión del problema empresarial.

Esta etapa consiste en definir objetivos e identificar fuentes de datos. La definición de objetivos está orientada a identificar las variables comerciales o de negocio que se necesita predecir. Además, implica definir los objetivos del proyecto a través de preguntas precisas, tales como:

- ¿Cuánto? Si el problema a resolver consiste en estimar la relación entre variables numéricas, seguramente será necesario analizar la aplicación de técnicas de regresión.
- ¿Qué categoría? Si el problema a resolver consiste en estimar o predecir una categoría o etiqueta, se necesitará aplicar técnicas de clasificación.
- ¿Qué grupo? Si los datos a tratar no cuentan con una etiqueta, se tendrá que evaluar y definir técnicas de clustering para extraer información oculta en los datos, mediante el análisis de grupos que cuenten con características o particularidades similares.
- ¿Es este caso raro? Ante la situación de eventuales casos, será necesario definir técnicas para la detección de anomalías (outliers).
- ¿Qué opción debería tomarse? Si el problema a abordar necesita proporcionar alguna recomendación, entonces será necesario definir técnicas para implementar sistemas de ayuda a la decisión.

Conjuntamente, en este paso se define el equipo interviniente, especificando roles y responsabilidades de los miembros y las métricas de éxito con las que se medirán los resultados del proyecto. El equipo se define mediante cuatro funciones (no necesariamente excluyentes entre sí:

- Administrador de grupo: supervisa toda la unidad de Ciencia de Datos.
- Líder de equipo: administra el equipo de Ciencia de Datos.
- Líder de proyecto: administra las actividades diarias en el proyecto especificado.

- Colaborador individual del proyecto: miembro del equipo de desarrollo (incluye científicos de datos, analistas de negocio, ingenieros o arquitectos de datos, especialistas, etc.).

En cuanto a las fuentes de datos, se identifican en función de los objetivos, las necesidades y las características de interés del dominio del problema.

2. **Adquisición y comprensión de los datos.**

El objetivo de esta etapa es generar un conjunto de datos limpio y de calidad. Además, desarrollar una arquitectura de solución a través de tres tareas de ingesta de datos, exploración de datos y una configuración para la canalización de los datos.

3. **Modelado.**

La meta de esta fase es identificar las características y crear un modelo de aprendizaje automático que sea óptimo, preciso y adecuado para la producción. Esta fase consta de tres tareas: ingeniería de características, entrenamiento de modelos y evaluación de los modelos.

4. **Despliegue**

El único propósito de esta fase es la de implantar modelos en un entorno de producción o similar al de producción para la aceptación final del cliente, exponiendo los modelos a través de una interfaz abierta.

5. **Aceptación del cliente.**

La fase final permite verificar que se cumplan las necesidades de los clientes. Las dos tareas principales que incluye esta fase son: validar el sistema y transferir el proyecto. Finalmente, para el cierre y documentación del proyecto se emite un informe de salida para el cliente. Este informe es técnico y contiene todos los detalles del proyecto que son útiles para aprender a operar el sistema. TSDP proporciona plantillas de informes, los cuales pueden ser personalizados en funciones de las necesidades específicas del cliente. La figura 4 es una representación visual del ciclo de vida de la metodología TDSP propuesta por Microsoft.




Figura 6.4: Ciclo de vida de TDSP.

6.3. ASUM-DM

La metodología ASUM-DM, del inglés Analytics Solutions Unified Method for Data Mining, es un proceso iterativo para implementar proyectos de Minería de Datos basado en la metodología CRISP-DM. Es un proceso propuesto por IBM y hace énfasis en las nuevas prácticas de la Ciencia de Datos, como el uso de Big Data, análisis de texto, modelado predictivo y automatización de procesos ³.

Fue diseñada para acelerar el tiempo de generación de valor y disminución del riesgo mediante el establecimiento de enfoques y procesos coherentes que aumentan la eficiencia de su implementación. Contiene pasos estructurados, actividades de desarrollo, roles y responsabilidades, plantillas y directrices.

IBM define a ASUM como una guía de pasos para efectuar la implementación del ciclo de vida de soluciones de analítica de datos. Se proponen las siguientes seis fases:

1. Analizar.

En esta fase se determinan los requisitos y necesidades del usuario, objetivos del proyecto, los entregables y se prevé de forma inicial las primeras soluciones posibles.

2. Diseñar.

Incluye los procesos que tienden al desarrollo de la minería y análisis de datos. También se identifican los recursos y se instala el entorno de desarrollo.

³[ftp://ftp.software.ibm.com/software/data/sw-library/services/ASUM.pdf](http://ftp.software.ibm.com/software/data/sw-library/services/ASUM.pdf)

3. Configurar y construir.

Configurar, construir e integrar componentes basados en un enfoque iterativo e incremental. En esta fase se define un plan de pruebas y validación en múltiples entornos.

4. Despliegue.

Esta fase establece el flujo de trabajo para implementar los resultados dentro de la empresa de forma que no afecte la actividad productiva normal de la misma. Debe incluir programas de apoyo y formación.

5. Operar y optimizar.

Esta fase cumple el rol de controlador, analiza el proyecto implementado (el uso de la solución de IBM Analytics), determina la necesidad de aumentar el alcance del proyecto o de realizar pequeños ajustes o mantenimientos.

6. Gestión de proyecto.

Adicionalmente, ASUM-DM incorpora una quinta fase paralela (figura 4), encargada de que las distintas fases del proyecto fluyan sin inconvenientes, esta labor es similar a la realizada por un Scrum Master, en la metodología Scrum. Esta fase ayuda a la gestión y la monitorización del progreso y mantenimiento del proyecto.

Una característica relevante de esta metodología es la carencia de detalle en los procesos que llevan a la minería y el análisis de datos. Además, incorpora una definición de los interesados del proyecto con las características de cada perfil y tareas típicas (como una matriz de asignación de tareas). Cabe resaltar que la guía para la implementación de ASUM-DM solo es accesible mediante un registro en el sitio web de IBM y mediante la instalación de archivos ejecutables que dan acceso a las guías en formato HTML, los cuales son compatibles solo con sistemas operativos Windows.




Figura 6.5: Ciclo de trabajo propuesto en la metodología ASUM-DM de IBM.

6.4. Scrum-DM

Scrum es una metodología de gestión de proyectos iterativa e incremental que involucra buenas prácticas, para controlar el riesgo y optimizar la gestión de un proyecto. En esta metodología los miembros del equipo deben trabajar juntos para entregar valor incremental (productos).

En entornos de análisis de datos, Scrum requiere adaptaciones para funcionar con las características de proyectos de este tipo, como por ejemplo, los equipos deben definir sprints (iteraciones de duración fija). Así como las metodologías TDSP y ASUM-DM se basan en algunos conceptos de Scrum y CRISP-DM, existen otras propuestas donde se integran metodologías, una de ellas es la metodología Scrum integrada con CRISP-DM (Scrum-DM).

La metodología Scrum-DM utiliza elementos de la metodología ágil Scrum para la gestión del trabajo y CRISP-DM como estrategia para seguir el desarrollo del proyecto de Minería de Datos (figura 5). Esta metodología se inicia con la fase de comprensión o entendimiento del negocio de CRISP-DM donde se realiza el análisis de los objetivos y del problema y finaliza en la fase de despliegue donde se propone la integración de los resultados de la Minería de Datos. El desarrollo está en una fase intermedia, llamada Sprint, donde se concentran las demás fases de CRISP-DM.

Esta metodología también se basa en la recomendación de Scrum, donde los equipos deben estar formados por 3 a 9 miembros de desarrollo y puntualiza los tres roles:

- Propietario del producto (Product Owner): establece la visión del producto y define los incrementos potenciales del producto (también conocidos como historias de usuario o características).
- Maestro de Scrum (Scrum Master): facilita el proceso Scrum (eliminando impedimentos) como líder del proyecto.
- Equipo de desarrollo (Development Team): formado por profesionales que entregan incrementos de producto. En el contexto de equipos de análisis de datos, serían los científicos de datos, ingenieros de datos, analistas de datos, analistas de sistemas e ingenieros de software, entre otros.




Figura 6.6: Pasos de la metodología Scrum-DM.

Como se aprecia en la figura 6, Scrum-DM divide el proyecto de Minería de Datos en pequeños proyectos, cada uno de una duración constante y fija que va de una semana a un mes (como la metodología Scrum). Cada ciclo de esos pequeños proyectos, llamado Sprint, comienzan con una reunión (planificación de sprint) donde el propietario del producto (Product Owner) define y explica las principales prioridades. El equipo de desarrollo define qué incrementos pueden ofrecer al final del sprint (Product Backlog), es decir que tareas de Minería de Datos y otros requerimientos van a desarrollar, y luego elabora un plan de sprint para desarrollar estos incrementos (Sprint Backlog), en base a las tareas de la metodología CRISP-DM.

Durante el sprint, se coordinan y desarrollan planes en las reuniones diarias (por ejemplo tipo de técnica a utilizar, métodos de visualización, etc.). Al final del sprint, el equipo demuestra los incrementos a las partes interesadas y solicita comentarios durante su revisión. Para cerrar un sprint, el equipo se examina a sí mismo y planifica cómo puede mejorar en el siguiente.

6.5. Comparación de Metodologías.

Las metodologías CRISP-DM, TDSP, ASUM-DM, Scrum-DM, SEMMA y P3TQ están compuestas por diversas fases relacionadas entre sí, con la finalidad de guiar el desarrollo de proyectos de Ciencia de Datos. A continuación, se resumen algunos puntos importantes de estas metodologías abordadas:

- El flujo de trabajo en CRISP-DM, TDSP, ASUM-DM, Scrum-DM y P3TQ es iterativo, exceptuando SEMMA.
- ASUM-DM se origina como una extensión del estándar abierto CRISP-DM, TDSP no detalla su origen.
- ASUM-DM si bien es iterativa, establece un orden secuencial de sus fases, mientras que TDSP dispone estados en paralelo con múltiples posibilidades de inter-comunicaciones. Como se expuso anteriormente, ambas metodologías persiguen la modalidad ágil, a pesar de sus diferentes formas de aplicación.
- ASUM-DM es más estructurada y detallista, mientras que TDSP es más flexible y abierta.
- ASUM-DM identifica los roles según las responsabilidades distribuidas a los fines del proyecto, mientras que TDSP organiza los roles en función de la gestión del equipo de trabajo en Ciencia de Datos, a través de distintos proyectos.
- En ASUM-DM la figura del cliente tiene mayor presencia, ya que se le atribuyen un conjunto de roles que TDSP no reconoce dentro de la metodología.
- Scrum-DM integra conceptos de la metodología Scrum y CRISP-DM.
- CRISP-DM, SEMMA y P3TQ son metodologías en cascada o tradicionales.
- La metodología SEMMA no proporciona una guía de actividades específicas a realizar en cada una de sus etapas y además, inicia su primera fase con el muestreo de datos, mientras que CRISP-DM y P3TQ se centran en el análisis de los requerimientos y el entendimiento del negocio.
- CRISP-DM, SEMMA y P3TQ contemplan la selección y preparación de los datos, pero SEMMA propone trabajar con una muestra de los datos originales (en caso de tener un gran volumen de datos).

- SEMMA interpreta y evalúa los resultados en base al desempeño del modelo, mientras que P3TQ realiza una validación en función de los objetivos del proyecto. Para el caso de CRISP-DM los resultados se evalúan en función del desempeño del modelo y el cumplimiento de los requerimientos iniciales del proyecto.
- Otra cosa a tener en cuenta en CRISP-DM, SEMMA y P3TQ es las herramientas que pueden emplear, por ejemplo, SEMMA está relacionada con productos comerciales de la empresa SAS, como Enterprise Miner y Text Miner, el análisis de los datos tiene que ajustarse a estas técnicas y herramientas. Sin embargo, CRISP-DM y P3TQ fueron diseñadas como metodologías de libre distribución, por lo que pueden adaptarse a cualquier herramienta ya sea libre o comercial.
- TDSP es una buena opción para equipos de Ciencia de Datos que aspiran a entregar productos de Ciencia de Datos a nivel de producción. Puede que no sea apropiado para científicos de datos de un solo equipo o para proyectos sin un objetivo de producción, como los académicos o científicos.
- ASUM-DM no precisa los detalles en los procesos de minería y el análisis de datos. La guía para la implementación de ASUM-DM solo es accesible mediante un registro en el sitio web de IBM y mediante la instalación de archivos ejecutables que dan acceso a las guías en formato HTML, los cuales son compatibles solo con sistemas operativos Windows.

6.6. Algoritmos y técnicas en la minería de datos.

De forma general podemos decir que las tareas principales en un proceso de minería de datos podrían ser las siguientes:

1. **Caracterización o resumen.**

Como se ha comentado, la caracterización de datos a veces consiste en un resumen de las características generales de los objetos de una clase (cluster). Los datos correspondientes a una clase son normalmente recuperados por una consulta a la base de datos para extraer la esencia de esos registros para los distintos niveles de abstracción. Este resumen se puede formalizar en una tabla o estructura similar.

2. **Discriminación o contraste.**

La discriminación de datos produce lo que se denomina reglas discriminantes, que consisten básicamente en la comparación de las características generales de los objetos entre dos clases, referidas como clase de objetivo y clase de contraste.

3. **Análisis de asociación.**

Análisis de asociación es la búsqueda de lo que comúnmente se conoce como “**reglas de asociación**”. Se estudia la frecuencia con la que dos o más elementos aparecen juntos en las bases de datos, y se identifican los conjuntos

de elementos frecuentes. Otro umbral, la confianza, que es la probabilidad condicional con la que un elemento aparece cuando otro elemento lo hace, se utiliza para determinar las reglas de asociación. Esta técnica es ampliamente usada, por ejemplo en empresas de comercio electrónico para analizar la cesta de la compra de sus clientes con el fin de identificar sus gustos y preferencias.

4. Clasificación/Segmentación.

La segmentación se basa en el análisis de la organización de los datos dentro de clases o clusters.

6.6.1. Métodos basados en estadística para la minería de datos.

Las técnicas de Regresión expresan la formalización de una relación significativa entre dos o más variables para calcular pronósticos a partir del conocimiento de los valores en un individuo concreto. Entre otros tipos de Regresión, para el análisis de datos se suele usar:

- Lineal (aproximación de la dependencia entre una variable dependiente y variables independientes).
- Múltiple (para predecir el valor de una variable dependiente a partir de variables independientes).
- Logística (para predecir variables categóricas).
- CART (Classification And Regression Trees, Leo Breiman).
- Etc.

Además, también se suelen usar otras técnicas clásicas en el ámbito de la estadística, como:

- Técnicas de extrapolación de funciones.
- Técnicas de aproximación y ajuste de funciones.
- Técnicas de agrupamiento basadas en medidas estadísticas (clustering).
- Etc.

Dentro del análisis predictivo juega un papel fundamental el Análisis de Series temporales. Se suelen clasificar en:

- Es betacionarias (medias y/o variabilidad se mantienen constantes).
- No Estacionarias (medias y/o variabilidad NO se mantienen constantes, cambios de varianza/tendencias).

También es importante señalar qué otros métodos se usan para otras diferentes necesidades en el análisis de series temporales:

6.6. Algoritmos y técnicas en la minería de datos.

- Tendencias: método de Mínimos cuadrados. Tendencias evolutivas. Diferenciación estacional.
- Predicción: alisadores exponenciales.
- Interpolación: Predecir datos faltantes.

Es importante reseñar que muchas se pueden englobar tanto en técnicas estadísticas como de Machine Learning, es decir, la mayoría de las técnicas de aprendizaje automático se basan en mecanismos estadísticos.

6.6.2. Métodos basados en Inteligencia Artificial (Machine Learning para la minería de datos.)

La Inteligencia Artificial (IA/AI -siglas en inglés-) se puede ver como la disciplina del ámbito de la computación y los sistemas de información que pretende simular computacionalmente comportamientos humanos que pueden ser considerados como inteligentes.

Hay diversas ramas dentro de la IA, como la Visión Artificial o la Robótica, pero en este tema nos centramos en el aprendizaje automático (AA/ML Machine Learning). Cuando se tienen en cuenta datos, por ejemplo historias clínicas de los pacientes, casos anteriormente tratados, registros de incidencias de enfermedades, datos de factores que pueden provocar determinadas dolencias (por ejemplo medioambientales, hábitos sociales...), entonces es necesario recurrir a lo que en IA se llaman técnicas de aprendizaje automático o Machine Learning y, por supuesto, técnicas provenientes de la matemática y la estadística, como por ejemplo las de Regresión (formalización de una relación significativa entre dos o más variables para calcular pronósticos a partir del conocimiento de los valores en un individuo concreto).

Como se ha dicho, muchas de estas técnicas se pueden englobar tanto en estadísticas como de Machine Learning: rama de la Inteligencia Artificial en la que se diseñan mecanismos para dotar a los sistemas computacionales de capacidad de aprendizaje, en el sentido de la capacidad de descubrir regularidades (patrones) en datos o situaciones anteriores y aplicarlos a nuevos problemas o situaciones análogos. Se pueden considerar diversos paradigmas y grupos de técnicas en AA:

- **Paradigma Analógico (Aprendizaje por analogía).**

Se pretende encontrar una solución a un problema que se presenta ahora usando el mismo procedimiento utilizado en la resolución de uno similar que se presentó en otra ocasión anterior. Si dos problemas son similares en algún aspecto de su formulación entonces pueden serlo también en sus soluciones. Nuevos problemas pueden ser abordados reduciéndolos a problemas análogos resueltos. Ejemplos: analogía por transformación, analogía por derivación, razonamiento basado en casos, etc.

- **Paradigma Inductivo.**

Árboles de decisión, algoritmos de inducción pura, etc.

- **Paradigma Conexionista.**

Redes Neuronales Artificiales, etc.

- **Paradigma Evolutivo.**

Algoritmos Genéticos, otros métodos de optimización, colonias de insectos, descenso estocástico del gradiente, etc.

- **Modelos gráficos probabilistas.**

Bayesianos, cadenas de Markov, Filtros de Kalman, redes de creencia, Máquinas de Soporte Vectorial (SVM), Metaheurísticas, etc.

Técnicas de **Clustering** (aprendizaje no supervisado) consisten en agrupar los elementos de una colección en subconjuntos (clases, categorías, clusters), nítidos o borrosos, en base a su similitud. Es no supervisado porque las clases o categorías no se conocen a priori, las determinarían las propias similitudes entre los elementos. Por lo tanto, se centran en una “medida de similitud” entre elementos, de la que puede haber infinidad de variantes: estadísticas, distancias euclídeas, distancias vectoriales (coseno), distancias borrosas, etc. Ejemplos:

- **Paradigma Conexionista.**

Redes Neuronales Artificiales: SOM (Self Organized Maps, Mapas de Kohonen). Toolbox de Matlab SOM, etc.

- **Modelos estadísticos y probabilistas.**

K-means, c-means, K-nearest neighbours (KNN), Mean shift (ventanas circulares con un centroide), Dirichlet process (estocásticos basados en distribuciones de probabilidad), LDA (Latent Dirichlet Allocation), Modelos Gaussianos, etc.

- **Extensiones basadas en Lógica Borrosa (fuzzy logic).**

Fuzzy K-means, Fuzzy c-means, Isodata, etc.

Técnicas de **Clasificación** (aprendizaje supervisado), consisten en asignar una clase a un nuevo elemento en base a un conjunto de categorías previamente establecidas (supervisado), por ejemplo, evaluar los síntomas de un nuevo paciente y decir que tiene gripe (clase previamente establecida). Se basan en un entrenamiento en base a ejemplos con la solución conocida (supervisado) para crear modelos que permitan clasificar nuevos casos análogos:

- **Paradigma Inductivo.**

Árboles de decisión: ID3, CART, C4.5, See5, Random Forest (de moda en Big Data, introducidos por Leo Breiman en 2001), etc.

- **Paradigma Conexionista.**

Redes Neuronales Artificiales: Perceptrón Multicapa (con backpropagation), Convolutivas, Neocognitrone, Redes de Hopfield, Redes recurrentes, Adaline, Deep Learning (de moda en Big Data), etc.

- **Modelos estadísticos y probabilistas.**

Redes Bayesianas, Naive-Bayes, Máquinas de Soporte Vectorial (SVM), Metaheurísticas, etc.

6.7. Conclusiones.

Este capítulo se ha dedicado a describir en profundidad la metodología **CRISP-DM**, quizá la más usada hoy en día en entornos empresariales (pero también muy vinculada en su esencia al KDD), y otras metodologías directamente basadas en CRISP-DM como Analytics Solutions Unified Method for Data Mining (**ASUM-DM**) y metodologías “ágiles” como Team Data Science Process (**TDSP**) o **Scrum-DM**.

Se ha presentado una enumeración y breve descripción de los que se consideran “algoritmos de minería de datos”, con una visión panorámica que pretende ser un mapa completo de los objetivos, orientación y técnicas (tanto estadísticas como provenientes de la Inteligencia Artificial) para afrontar el análisis de datos en entornos Big Data.

6.8. Bibliografía.

1. Fayyad, U., Piatetsky-Shapiro, G., Smyth, P. (1996). The KDD Process for Extracting Useful Knowledge from Volumes of Data. Communications of the ACM, November 1996/ Vol 39, N° 11, 27–34.
2. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T.P., Shearer, C., Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. Computer Science.