

Introducción a Apache Flume

Sistemas de Big Data

Julio Alberto López Gómez
JulioAlberto.Lopez@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data

Apache Flume

Introducción

- **Necesidad:** inyección de datos no estructurados en HDFS
- *Servicio distribuido, disponible y fiable para recolectar, agregar y mover grandes cantidades de datos*
 - Extrayendo datos de diversas fuentes
 - Inyectándolos en HDFS



Apache Flume

Características:

- **Arquitectura sencilla**
 - Basada en flujos de datos stream
- **Robusto**
 - Recuperabilidad, cola de memoria
- **Fiable**
 - Garantiza la inyección de los datos
 - Tolerante a fallos



Apache Flume


Conceptos básicos:

- **Evento**
 - Unidad de flujo de datos básica
 - Carga útil de bytes
 - Atributos de tipo cadena (opcional)
- **Agente Flume**
 - Proceso JVM que almacena los componentes necesarios para que los datos viajen desde la fuente hacia su destino

Apache Flume

Agente Flume

■ Arquitectura:



Apache Flume

Agente Flume

- **Origen de datos**
 - Se corresponde con la fuente de la cual se pretende recolectar los datos para inyectarlos en HDFS
 - Servidor Web
 - Servidor Log
 - Datos provenientes de RRSS
 - Smartphones, smartwatches...

Apache Flume

Agente Flume

- **Fuente (Source)**
 - Extrae los datos no estructurados del origen de datos
 - Pueden provenir de una o más aplicaciones
 - A partir de los datos extraídos, obtiene los eventos que serán transmitidos a su destino



Apache Flume

Agente Flume

- **Canal (Channel)**
 - Búfer o espacio de almacenamiento entre la fuente y el sumidero
 - Existen distintos tipos de canales:
 - Memory Channel
 - File Channel
 - JDBC Channel



Apache Flume

Agente Flume

- **Sumidero (Sink)**
 - Última etapa antes de volcar/inyectar los datos
 - Los datos no tienen por qué volcarse en HDFS. Existen múltiples alternativas
 - Hbase
 - Hive
 - Elasticsearch
 - ...

Apache Flume

Agente Flume

- **HDFS**
 - Se trata del repositorio terminal en el que se inyectan los datos recolectados
 - Aunque existen multitud de alternativas
 - Un agente puede enviar los datos recolectados directamente al repositorio terminal (single-hop) o a otro agente

Introducción a Apache Flume

Sistemas de Big Data

Julio Alberto López Gómez
JulioAlberto.Lopez@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data