

Primeros pasos con Apache Flume

Sistemas de Big Data

Julio Alberto López Gómez
JulioAlberto.Lopez@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data

Apache Flume

Los comienzos...

- Estructura de directorios
 - Bin:
 - Contiene la utilidad `flume-ng`
 - Docs:
 - Documentación, guía de usuario...
 - Lib:
 - Librerías de conexión con otros servicios

Apache Flume


Los comienzos...

- Estructura de directorios
 - Conf:
 - `Flume-conf.properties.template`
 - Plantillas para la definición de agentes
 - `Flume-env.sh.template`
 - Definición del entorno de ejecución
 - `Log4j.properties`
 - Definición de propiedades de ejecución e integración con otros servicios

Apache Flume


Agentes

■ Arquitectura



Apache Flume

Agentes

- **Source**
 - Existen multitud de posibles orígenes de datos
 - **AVRO:**
 - Formato open-source para la serialización de datos
 - Definidos en JSON
 - **THRIFT:**
 - Permite la creación de servicios web, facilitando la recolección de datos
- 

Apache Flume

Agentes

- **Source**
 - **Exec:**
 - Genera datos a través de un comando Unix
 - **Netcat:**
 - Por cada línea de texto introducida genera un evento
 - **HTTP:**
 - Recolecta eventos mediante métodos GET y POST
- 

Apache Flume

Agentes

- **Canales:**
 - **Memory Channel:**
 - Utiliza una cola con tamaño prefijado para almacenar eventos
 - **DBC Channel:**
 - Los eventos se almacenan en una base de datos permanente (JDBC)
 - **File Channel:**
 - Almacena los eventos en ficheros temporales. Similar al anterior
- 

Apache Flume

Agentes

- **Sumideros:**
 - **HDFS:**
 - Escribe los datos en HDFS, indicando fichero, ruta, etc.
 - **Logger sink:**
 - Escribe los eventos en un log
 - **Avro sink**
 - **Thrift sink**
 - **Custom sink**
 - Sink implementado a medida

Primeros pasos con Apache Flume

Sistemas de Big Data

Julio Alberto López Gómez
JulioAlberto.Lopez@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data