

# Ingesta de datos en HDFS

## Sistemas de Big Data

Julio Alberto López Gómez  
JulioAlberto.Lopez@uclm.es



Sistemas de  
Big\_Data



Curso Especialización  
Inteligencia\_Artificial y  
Big\_Data

# Apache Flume

## Ingesta de datos:

- En ejemplos anteriores, los eventos se registraban en el terminal a modo de log.
  - Desbordamiento del canal
  - No es posible comunicar a la aplicación que no se ha podido enviar un evento
  - No hay confirmación de que los datos se han recibido



# Apache Flume

## HDFS:

- Ingestión de datos
  - Envío de datos desde sink a otro agente
  - Ingestión de datos en repositorio terminal
    - HDFS
    - Sincronización
    - Procesamiento distribuido
    - Replicación
    - Tolerancia a fallos

# Apache Flume


## Ejemplo:

- Agente que monitoriza cambios en un directorio.
  - Revisa los cambios del directorio `/tmp/logs`
  - Almacena los archivos agregados en el directorio correspondiente HDFS
    - `flume/events`

# Apache Flume

Ejemplo:


- Esquema de la arquitectura del agente



# Apache Flume

Ejemplo:

- Esquema de la arquitectura del agente



# Apache Flume


## Ejemplo:

### ■ Archivo de configuración (I)

```
#Definición del agente: nombre y
componentes
Agente_Dir.sources      = s1
Agente_Dir.sinks        = k1
Agente_Dir.channels     = c1

#Configuración source
Agente_Dir.sources.s1.type = spooldir
Agente_Dir.sources.s1.spoolDir = /tmp/logs
Agente_Dir.sources.s1.basenameHeader = true
Agente_Dir.sources.s1.basenameHeaderKey =
fileName

#Vincular source al canal
Agente_Dir.sources.s1.channels = c1
```



# Apache Flume

## Ejemplo:

### ■ Archivo de configuración (II)

```
# Configurar el tipo de canal
Agente_Dir.channels.c1.type = memory

# Configuración del sink
Agente_Dir.sinks.k1.type = hdfs
Agente_Dir.sinks.k1.hdfs.path =
/flume/events/%y-%m-%d/%H/
Agente_Dir.sinks.k1.hdfs.filePrefix =
%{fileName}
Agente_Dir.sinks.k1.hdfs.fileType =
DataStream
Agente_Dir.sinks.k1.hdfs.useLocalTimeSta
mp = true

#Vincular sink al canal
Agente_Dir.sinks.k1.channel = c1
```





# Apache Flume

## Ejemplo:

- Ejecución del agente

```
flume-ng -n Agente_Dir -f  
/home/cloudera/Downloads/apache-flume-  
1.9.0-bin/examples/ejemplo_hdfs.conf
```

- Resultado:

- Copia cualquier fichero al directorio que el agente monitoriza

```
cp [Ruta archivo a copiar] /tmp/logs
```

- Comprueba si ese archivo se ha cargado también en HDFS

```
hdfs -cat flume/events/21-10-  
15/11/log.txt.1554788567801
```

# Ingesta de datos en HDFS

## Sistemas de Big Data

Julio Alberto López Gómez  
JulioAlberto.Lopez@uclm.es



Sistemas de  
Big\_Data



Curso Especialización  
Inteligencia\_Artificial y  
Big\_Data