

Creación de un cluster Spark en Docker 1: Visión general

Sistemas de Big Data

José Ángel Martín Baos
JoseAngel.Martin@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data

Spark

Diferencias con Hadoop MapReduce

Factores	Hadoop MapReduce	Apache Spark
Velocidad	+ rápido que sistemas tradicionales	100 veces más rápido que MapReduce
Programado en	Java	Scala (interfaz para Java, Python y R)
Procesamiento de datos	Batch	Batch, Tiempo real, Iterativo o Grafos
Facilidad de uso	Largo y complejo	Compacto y + fácil
Caché	No soportado	Se cachean los datos en memoria (+ rendimiento)

Spark


Características principales



Batch/Streaming



Cluster



API de
programación






SQL



Bibliotecas


Spark

Características principales




Spark

Arquitectura de un cluster




Docker

Imagen vs Contenedor



Cluster Spark

Visión general



Creación de un cluster Spark en Docker 1: Visión general

Sistemas de Big Data

José Ángel Martín Baos
JoseAngel.Martin@uclm.es



Sistemas de
Big_Data



Curso Especialización
Inteligencia_Artificial y
Big_Data